

Авторские права

© Postgres Professional, 2019–2022

Авторы: Егор Рогов, Павел Лузанов, Павел Толмачев, Илья Баштанов

Использование материалов курса

Некоммерческое использование материалов курса (презентации, демонстрации) разрешается без ограничений. Коммерческое использование возможно только с письменного разрешения компании Postgres Professional. Запрещается внесение изменений в материалы курса.

Обратная связь

Отзывы, замечания и предложения направляйте по адресу: edu@postgrespro.ru

Отказ от ответственности

Компания Postgres Professional не несет никакой ответственности за любые повреждения и убытки, включая потерю дохода, нанесенные прямым или непрямым, специальным или случайным использованием материалов курса. Компания Postgres Professional не предоставляет каких-либо гарантий на материалы курса. Материалы курса предоставляются на основе принципа «как есть» и компания Postgres Professional не обязана предоставлять сопровождение, поддержку, обновления, расширения и изменения.

Темы



Общие соображения о соединениях

Соединение вложенным циклом

Модификации: левые, полу- и анти- соединения

Вычислительная сложность

Вложенный цикл в параллельных планах

2

Соединения



Способы соединения — не соединения SQL

inner/left/right/full/cross join, in, exists — логические операции способы соединения — механизм реализации

Соединяются не таблицы, а наборы строк

могут быть получены от любого узла дерева плана

Наборы строк соединяются попарно

порядок соединений важен с точки зрения производительности обычно важен и порядок внутри пары

3

Мало получать данные с помощью рассмотренных методов доступа, надо еще и уметь соединять их. Для этого PostgreSQL предоставляет несколько способов.

Способы соединения представляют собой алгоритмы для соединения двух наборов строк. С их помощью выполняются операции соединения в языке SQL (и другие синтаксические конструкции, например, EXISTS). Не стоит путать одно с другим: SQL-соединения — это логические операции с двумя множествами; способы соединения PostgreSQL — это возможные реализации таких соединений, учитывающие вопросы производительности.

Часто можно услышать, что соединяются *таблицы*. Это удобное упрощение, но на самом деле в общем случае соединяются *наборы строк*. Эти наборы действительно могут быть получены непосредственно из таблицы (с помощью одного из методов доступа), но с тем же успехом могут, например, являться результатом соединения других наборов строк.

Наконец, наборы строк всегда соединяются попарно. Порядок, в котором соединяются таблицы, не важен с точки зрения логики запроса (например, (a join b) join c или (b join c) join a), но очень важен с точки зрения производительности. Как мы увидим дальше, важен и порядок, в котором соединяются два набора строк (a join b или b join a).

Nested Loop SELECT a.title, s.name FROM albums a JOIN songs s ON a.id = s.album_id; индексный доступ или полное сканирование album id id title name vear 3 Let It Be 1970 A Day in the Life All Together Now 1 Yellow Submarine 1969 **Another Girl** 6 Abbey Road 1969 The Beatles 3 1968 Across the Universe All You Need Is Love Act Naturally для каждой строки одного набора перебираем подходящие строки другого набора 4


Начнем с соединения вложенными циклами (nested loop), как с самого простого. Его алгоритм таков: для каждой строки одного из наборов перебираем и возвращаем соответствующие ему строки второго набора. По сути, это два вложенных цикла, отсюда и название способа.

Заметим, что ко второму (внутреннему) набору мы будем обращаться столько раз, сколько строк в первом (внешнем) наборе. Если нет эффективного метода доступа для поиска соответствующих строк во втором наборе (то есть, попросту говоря, индекса на таблице), придется неоднократно перебирать большое количество строк, не относящихся к делу. Очевидно, это будет не лучший выбор, хотя для небольших наборов алгоритм и в этом случае может оказаться достаточно эффективным.

Рисунки иллюстрируют этот способ соединения. На них:


- серым показаны строки, к которым ранее уже был доступ;
- строки, доступ к которым выполняется на текущем шаге, выделены цветом;
- оранжевым контуром выделены строки, составляющие пару, подходящую по условию соединения (в данном примере по равенству числовых идентификаторов).

Сначала мы читаем первую строку первого набора и находим ее пару во втором наборе. Соответствие нашлось, и у нас уже есть первая строка результата, которую можно вернуть вышестоящему узлу плана: («Let It Be», «Across the Universe»).



Читаем вторую строку первого набора.

Для нее тоже перебираем пары из второго набора. Сначала возвращаем («Yellow Submarine», «All Together Now»)...



...затем вторую пару («Yellow Submarine», «All You Need Is Love»).

Nested Loop



SELECT a.title, s.name
FROM albums a JOIN songs s ON a.id = s.album_id;

id	title	year
3	Let It Be	1970
1	Yellow Submarine	1969
6	Abbey Road	1969
4	The Beatles	1968

all	oum_i	d name
	5	A Day in the Life
	1	All Together Now
	2	Another Girl
	3	Across the Universe
	1	All You Need Is Love
	2	Act Naturally

7

Переходим к третьей строке первого набора. Для нее соответствий нет.

Nested Loop SELECT a.title, s.name FROM albums a JOIN songs s ON a.id = s.album_id; id title album id year name 3 Let It Be 1970 A Day in the Life Yellow Submarine 1969 All Together Now Abbey Road 1969 2 Another Girl 6 The Beatles 1968 Across the Universe All You Need Is Love Act Naturally не все строки внутреннего набора рассматривались

Для четвертой строки тоже нет соответствий. На этом работа соединения заканчивается.

Часть строк второго набора мы вообще не рассматривали — на рисунке они остались белыми.

8

(С исходным кодом алгоритма можно познакомиться в файле src/backend/executor/nodeNestloop.c.)

Соединение вложенным циклом

=> EXPLAIN (analyze, summary off)

Так выглядит план для соединения вложенным циклом, которое оптимизатор обычно предпочитает для небольших выборок (смотрим перелеты, включенные в два билета):

Это параметризованное соединение. Для каждой строки внешнего набора (узел Index Scan по таблице билетов) выбираются строки из внутреннего набора (узел Index Scan по таблице перелетов), отвечающие условию соединения. На каждой итерации внешнего цикла условие индексного доступа для внутреннего набора имеет вид ticket no = константа.

Процесс повторяется до тех пор, пока внешний набор не исчерпает все строки.

Команда EXPLAIN ANALYZE позволяет узнать, сколько раз на самом деле выполнялся вложенный цикл (loops) и сколько в среднем было выбрано строк (rows) и потрачено времени (time) за один раз. Видно, что планировщик немного ошибся — получилось 8 строк вместо 6.

```
SELECT *
FROM tickets t
JOIN ticket_flights tf ON tf.ticket_no = t.ticket_no
WHERE t.ticket_no IN ('0005432312163','0005432312164');

OUERY PLAN

Nested Loop (cost=0.99..46.11 rows=6 width=136) (actual time=1.392..3.224 rows=8 loops=1)
-> Index Scan using tickets_pkey on tickets t (cost=0.43..12.89 rows=2 width=104) (actual time=1.054..1.066 rows=2 loops=1)
Index Cond: (ticket_no = ANY ('{0005432312163,0005432312164}'::bpchar[]))
-> Index Scan using ticket_flights_pkey on ticket_flights tf (cost=0.56..16.58 rows=3 width=32) (actual time=0.283..1.073 rows=4 loops=2)
Index Cond: (ticket_no = t.ticket_no)

(5 rows)
```

Предупреждение: вывод времени выполнения каждого шага, как в этом примере, может существенно замедлять выполнение запроса на некоторых платформах. Если такая информация не нужна, лучше указывать timing off.

Модификации

Существует несколько модификаций алгоритма. Для левого соединения:

Эта модификация возвращает строки, даже если для левого (а) набора строк не нашлось соответствия в правом (s) наборе.

Антисоединение возвращает строки одного набора, если только для них не нашлось соответствия в другом наборе. Такая модификация может использоваться для обработки предиката NOT EXISTS:

Та же операция антисоединения используется и для аналогичного запроса, записанного иначе:

```
=> EXPLAIN (costs off) SELECT *
FROM aircrafts a
LEFT JOIN seats s ON (a.aircraft_code = s.aircraft_code)
WHERE a.model LIKE 'A∋po6yc%'
AND s.aircraft_code IS NULL;
                          QUERY PLAN
 Nested Loop Anti Join
   -> Seq Scan on aircrafts_data ml
         Filter: ((model ->> lang()) ~~ 'Aəpoбyc%'::text)
      Index Scan using seats_pkey on seats s
         Index Cond: (aircraft_code = ml.aircraft_code)
(5 rows)
Для предиката EXISTS может использоваться полусоединение, которое возвращает строки одного набора, если для них нашлось хотя бы одно
соответствие в другом наборе:
=> EXPLAIN SELECT
FROM aircrafts a
WHERE a.model LIKE 'Aəpoбyc%'
AND EXISTS (
 SELECT * FROM seats s WHERE s.aircraft_code = a.aircraft_code
                                         QUERY PLAN
Nested Loop Semi Join (cost=0.28..4.02 rows=1 width=40)
   -> Seg Scan on aircrafts_data ml (cost=0.00..3.39 rows=1 width=72) Filter: ((model ->> lang()) -~ 'Aəpoбус%'::text)
      Index Only Scan using seats_pkey on seats s (cost=0.28..6.88 rows=149 width=4)
         Index Cond: (aircraft_code = ml.aircraft_code)
(5 rows)
Обратите внимание: хотя в плане для таблицы s указано rows=149, на самом деле достаточно получить всего одну строку, чтобы понять значение
предиката EXISTS.
PostgreSQL так и делает (actual rows):
=> EXPLAIN (analyze, costs off, timing off, summary off)
SELECT *
FROM aircrafts a
WHERE a.model LIKE 'Aэробус%'
AND EXISTS (

SELECT * FROM seats s WHERE s.aircraft_code = a.aircraft_code
):
                                  QUERY PLAN
 Nested Loop Semi Join (actual rows=3 loops=1)
   -> Seq Scan on aircrafts_data ml (actual rows=3 loops=1)
Filter: ((model ->> lang()) ~~ 'Aəpoбyc%'::text)
          Rows Removed by Filter: 6
      Index Only Scan using seats_pkey on seats s (actual rows=1 loops=3)
         Index Cond: (aircraft_code = ml.aircraft_code)
         Heap Fetches: 0
(7 rows)
```

Модификаций алгоритма вложенного цикла для правого (RIGHT) и полного (FULL) соединений не существует. Это связано с тем, что полный проход по второму набору строк может не выполняться.

Если пренебречь производительностью, полное соединение можно получить, объединив левое соединение и антисоединение. Такой способ может пригодиться, так как FULL JOIN (как мы увидим позже) работает только с эквисоединениями.

Вычислительная сложность Postgres



 $\sim N \times M$, где

N — число строк во внешнем наборе данных, M — среднее число строк внутреннего набора, приходящееся на одну итерацию

Соединение эффективно только для небольшого числа строк

10

Если принять за *N* число строк во внешнем наборе данных, а за *M* среднее число строк внутреннего набора, приходящееся на одну итерацию, то общая сложность соединения будет пропорциональна произведению $N \times M$.

Из-за этого метод соединения вложенным циклом эффективен только для небольшого числа строк.

В частности, такой метод (в сочетании с индексным доступом) характерен для OLTP-запросов, в которых надо очень быстро вернуть очень небольшое число строк.

Стоимость соединения вложенным циклом

Посмотрим на стоимость следующего плана выполнения:

Начальная стоимость узла Nested Loop — сумма начальных стоимостей дочерних узлов (Index Scan).

Полная стоимость узла Nested Loop складывается из:

- стоимости получения данных от внешнего набора (полная стоимость узла Index Scan по билетам);
- стоимости получения данных от внутреннего набора (полная стоимость узла Index Scan по перелетам), умноженной на число строк внешнего набора (2);
- стоимости процессорной обработки строк.

В общем случае формула более сложная, но основной вывод: стоимость пропорциональна N*M, где N — число строк во внешнем наборе данных, а M — среднее число строк, внутреннего набора, читаемое за одну итерацию. В худшем случае стоимость получается квадратичной.



Соединение вложенным циклом может использоваться в параллельных планах.

Внешний набор строк сканируется несколькими рабочими процессами параллельно. Получив строку из внешнего набора, процесс затем перебирает соответствующие ему строки внутреннего набора последовательно.

Вложенный цикл в параллельных планах

Найдем всех пассажиров, купивших билеты на определенный рейс:

```
=> EXPLAIN (costs off)
SELECT t.passenger_name
FROM tickets t
  JOIN ticket_flights tf ON tf.ticket_no = t.ticket_no
JOIN flights f ON f.flight_id = tf.flight_id
WHERE f.flight_id = 12345;
                        QUERY PLAN
.....
Nested Loop
  -> Index Only Scan using flights_pkey on flights f
        Index Cond: (flight_id = 12345)
  -> Gather
        Workers Planned: 2
        -> Nested Loop
              -> Parallel Seq Scan on ticket_flights tf
                   Filter: (flight_id = 12345)
                 Index Scan using tickets_pkey on tickets t
                   Index Cond: (ticket_no = tf.ticket_no)
(10 rows)
```

На верхнем уровне используется соединение вложенным циклом. Внешний набор данных состоит из одной строки, полученной из таблицы рейсов (flights) по уникальному индексу.

Для получения внутреннего набора используется параллельный план. Каждый из процессов читает свою часть таблицы перелетов (ticket_flights) и соединяет ее с билетами (tickets) с помощью другого вложенного цикла.

Итоги



Вложенный цикл не требует подготовительных действий

может отдавать результат соединения без задержек

Эффективен для небольших выборок

внешний набор строк не очень велик к внутреннему есть эффективный доступ (обычно по индексу)

Зависит от порядка соединения

обычно лучше, если внешний набор меньше внутреннего

Поддерживает соединение по любому условию

как эквисоединения, так и любые другие

14

Сильной стороной способа соединения вложенными циклами является его простота: не требуется никаких подготовительных действий, мы можем начать возвращать результат практически моментально.

Обратная сторона состоит в том, что этот способ крайне неэффективен для больших объемов данных. Ситуация та же, что и с индексами: чем больше выборка, тем больше накладных расходов.

Таким образом, соединение вложенными циклами имеет смысл применять, если:

- один из наборов строк небольшой;
- к другому набору есть эффективный доступ по условию соединения;
- общее количество строк результата невелико.

Это обычная ситуация для OLTP-запросов (например, запросов от пользовательского интерфейса, где веб-страница или экранная форма должны открыться быстро и не выводят большой объем информации).

Еще одна особенность, которую стоит отметить: соединение вложенными циклами может работать для любого условия соединения. Подходит как эквисоединение (по условию равенства, как в примере), так и любое другое.

Практика



- 1. Создайте индекс на таблице рейсов (flights) по аэропортам отправления (departure_airport). Найдите все рейсы из Ульяновска и проверьте план выполнения запроса.
- 2. Соедините любые две таблицы без указания условий соединения (иными словами, выполните декартово произведение таблиц). Какой способ соединения будет выбран планировщиком?
- 3. Постройте таблицу расстояний между всеми аэропортами (так, чтобы каждая пара встречалась только один раз). Какой способ соединения используется в таком запросе?

15

3. Используйте оператор <@> из расширения earthdistance.

1. Рейсы из Ульяновска

```
Индекс на таблице рейсов:
=> CREATE INDEX ON flights(departure_airport);
CREATE INDEX
План запроса:
=> EXPLAIN SELECT *
 FROM flights f JOIN airports a ON a.airport_code = f.departure_airport
 WHERE a.city = 'Ульяновск';
                                            QUERY PLAN
Nested Loop (cost=24.31..3732.03 rows=2066 width=162)
  -> Seq Scan on airports_data ml (cost=0.00..30.56 rows=1 width=145)
        Filter: ((city ->> lang()) = 'Ульяновск'::text)
  -> Bitmap Heap Scan on flights f (cost=24.31..2637.48 rows=2066 width=63)
        Recheck Cond: (departure airport = ml.airport code)
        -> Bitmap Index Scan on flights_departure_airport_idx (cost=0.00..23.79 rows=2066 width=0)
              Index Cond: (departure airport = ml.airport code)
(7 rows)
Планировщик использовал соединение вложенным циклом.
Заметим, что в данном случае соединение необходимо, так как в Ульяновске два аэропорта:
=> SELECT airport_code, airport_name FROM airports WHERE city = 'Ульяновск';
airport code |
                airport name
UI Y
           | Ульяновск-Восточный
ULV
             | Баратаевка
(2 rows)
2. Декартово произведение
=> EXPLAIN SELECT *
 FROM airports al CROSS JOIN airports a2;
                                   QUERY PLAN
_____
Nested Loop (cost=0.00..11067.70 rows=10816 width=198)
  -> Seq Scan on airports data ml (cost=0.00..4.04 rows=104 width=145)
  -> Materialize (cost=0.00..4.56 rows=104 width=145)
        -> Seq Scan on airports_data ml_1 (cost=0.00..4.04 rows=104 width=145)
(4 rows)
Соединение вложенным циклом — единственный способ выполнения таких соединений.
Узел Materialize — «материализация» выборки строк. Если выборка не превышает размер, заданный параметром
```

work mem, то она остается в памяти; если превышает — то записывается во временный файл. В данном случае эта операция выглядит лишней, но в следующем примере она позволяет сканировать во вложенном цикле уже отфильтрованный набор строк из а2, а не всю таблицу:

```
=> EXPLAIN SELECT *
 FROM airports al CROSS JOIN airports a2
 WHERE a2.timezone = 'Europe/Moscow';
                                  OUERY PLAN
Nested Loop (cost=0.00..4687.41 rows=4576 width=198)
  -> Seq Scan on airports_data ml (cost=0.00..4.04 rows=104 width=145)
   -> Materialize (cost=0.00..4.52 rows=44 width=145)
        -> Seq Scan on airports_data ml_1 (cost=0.00..4.30 rows=44 width=145)
              Filter: (timezone = 'Europe/Moscow'::text)
(5 rows)
```

3. Таблица расстояний между аэропортами

```
=> CREATE EXTENSION earthdistance CASCADE;
```

И снова вложенный цикл — единственный способ соединения для такого условия.