

# Авторские права

© Postgres Professional, 2016–2022.

Авторы: Егор Рогов, Павел Лузанов, Илья Баштанов

# Использование материалов курса

Некоммерческое использование материалов курса (презентации, демонстрации) разрешается без ограничений. Коммерческое использование возможно только с письменного разрешения компании Postgres Professional. Запрещается внесение изменений в материалы курса.

# Обратная связь

Отзывы, замечания и предложения направляйте по адресу: edu@postgrespro.ru

### Отказ от ответственности

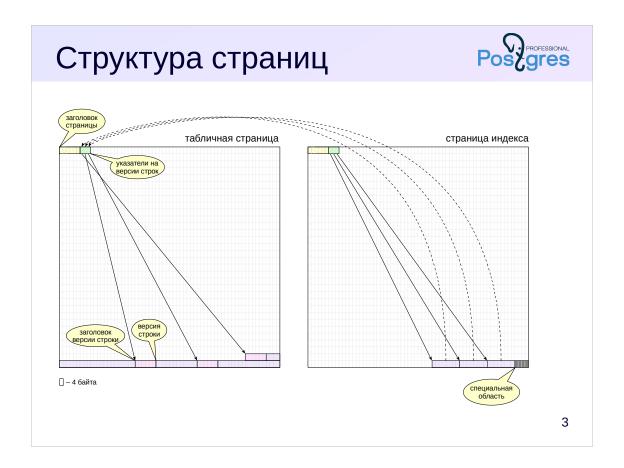
Компания Postgres Professional не несет никакой ответственности за любые повреждения и убытки, включая потерю дохода, нанесенные прямым или непрямым, специальным или случайным использованием материалов курса. Компания Postgres Professional не предоставляет каких-либо гарантий на материалы курса. Материалы курса предоставляются на основе принципа «как есть» и компания Postgres Professional не обязана предоставлять сопровождение, поддержку, обновления, расширения и изменения.

# Темы



Структура страниц и версий строк Как работают операции над данными Вложенные транзакции

2



Размер страницы составляет 8 килобайт. Это значение можно увеличить (вплоть до 32 килобайт), но только при сборке.

И таблицы, и индексы, и большинство других объектов, которые в PostgreSQL обозначаются по-английски термином relation, используют одинаковую структуру страниц, чтобы пользоваться общим буферным кешем. В начале страницы идет заголовок (24 байта), содержащий общие сведения и размер следующих областей: указателей, свободного пространства, версий строк и специальной области.

«Версия строки» называется по-английски tuple; если это не нарушает однозначности, мы будем сокращать название до «строка».

Указатели имеют фиксированный размер (4 байта) и составляют массив, позиция в котором определяет идентификатор строки (tuple id, tid). Указатели ссылаются на собственно версии строк (tuple), которые расположены в конце блока. Такая косвенная адресация удобна тем, что во-первых, позволяет найти строку, не перебирая все содержимое блока (строки имеют разную длину), а во-вторых, позволяет перемещать строку внутри блока, не ломая ссылки из индексов.

Версия строки, в свою очередь, имеет заголовок и данные.

Между указателями и версиями строк находится свободное место. В конце блока может находиться специальная область, которая используется в некоторых индексных страницах.

https://postgrespro.ru/docs/postgresql/13/storage-page-layout

# Формат данных Страницы читаются в оперативную память «как есть» данные не переносимы между разными платформами между полями данных возможны пропуски из-за выравнивания

Формат данных на диске полностью совпадает с представлением данных в оперативной памяти. Страница читается в буферный кеш «как есть», без преобразований.

Поэтому файлы данных с одной платформы (разрядность, порядок байтов и т. п.) не могут быть перенесены на другие платформы.

Кроме того, многие архитектуры предусматривают выравнивание данных по границам машинных слов. Например, на 32-битной системе х86 целые числа (тип integer, занимает 4 байта) выравниваются по границе 4-байтных слов, как и числа с плавающей точкой двойной точности (тип double precision, 8 байт). А на 64-битной системе значения double precision будут выровнены по границе 8-байтных слов.

Из-за этого размер табличной строки зависит от порядка расположения полей. Обычно этот эффект не сильно заметен, но в некоторых случаях он может привести к существенному увеличению размера. Например, если располагать поля типов char(1) и integer вперемешку, между ними, как правило, будет пропадать 3 байта.

https://pgconf.ru/media/2016/05/13/tuple-internals-ru.pdf

### Структура страниц

Для изучения структуры и содержания страниц предназначено расширение pageinspect.

```
=> CREATE DATABASE mvcc_tuples;
CREATE DATABASE
=> \c mvcc_tuples
You are now connected to database "mvcc_tuples" as user "student".
=> CREATE EXTENSION pageinspect;
CREATE EXTENSION
```

Границы областей страницы записаны в ее заголовке. Возьмем для примера нулевую страницу одной из таблиц системного каталога:

Области занимают следующие диапазоны адресов:

- 0 начало заголовка страницы и указатели на версии строк,
- lower начало свободного места,
- upper начало данных (версий строк),
- special начало спец. данных (только для индексов),
- pagesize конец страницы.



Страница содержит массив указателей на версии строк. Каждый указатель (занимающий 4 байта) содержит:

- ссылку на версию строки;
- длину этой версии строки (для удобства);
- несколько бит, определяющих статус версии строки.

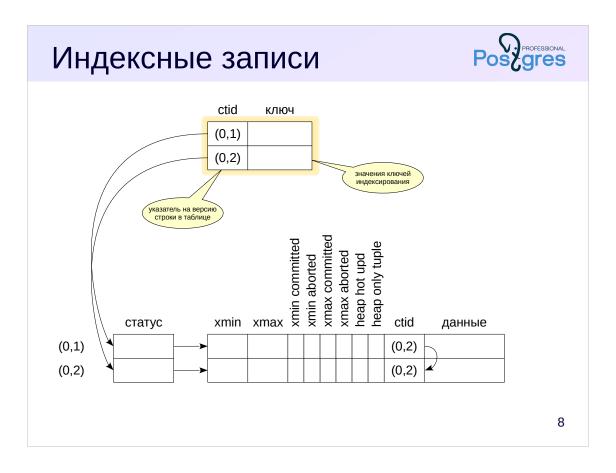


Версии строк (tuples) в табличных страницах (heap pages) кроме собственно данных имеют также заголовок. Заголовок, помимо прочего, содержит следующие важные поля:

- xmin и xmax определяют видимость данной версии строки в терминах начального и конечного номеров транзакций.
- infomask содержит ряд битов, определяющих свойства данной версии. На рисунке показаны основные из них, но далеко не все. Часть показанных битов будет рассмотрена в этой теме, часть в других темах этого модуля.
- ctid является ссылкой на следующую, более новую, версию той же строки. У самой новой, актуальной, версии строки ctid ссылается на саму эту версию. Такие ссылки используются не всегда, мы рассмотрим их в теме «НОТ-обновления».

Заголовок версии строки на табличной странице составляет 23 байта (или больше: в него включается битовая карта неопределенных значений).

Напомним, что каждая версия строки всегда целиком помещается внутрь одной страницы. Если версия строки имеет большой размер, PostgreSQL попробует сжать часть полей или вынести часть полей во внешнее TOAST-хранилище (это рассматривается в модуле «Физическая организация данных» курса DBA1).



Информация в индексной странице сильно зависит от типа индекса. И даже у одного типа индекса бывают разные виды страниц. Например, у В-дерева есть страница с метаданными и «обычные» страницы.

Тем не менее, обычно в странице имеется массив указателей и строки (так же, как и в табличной странице). Во избежание путаницы мы будем называть индексные строки *записями*. Кроме того, в конце индексной страницы отводится место под специальные данные.

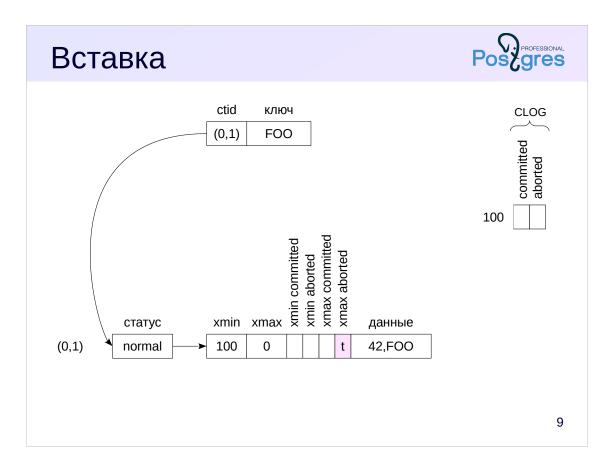
Индексные записи тоже могут иметь очень разную структуру в зависимости от типа индекса. Например, для В-дерева записи, относящиеся к листовым страницам, содержат значение ключа индексирования и ссылку (ctid) на соответствующую строку таблицы (подробно структура В-дерева разбирается в учебном курсе QPT «Оптимизация запросов»).

В общем случае индекс может быть устроен совсем другим образом, но как правило он все равно будет содержать ссылки на версии строк.

Номера ctid имеют вид (*x*,*y*): здесь *x* — номер страницы, *y* — порядковый номер указателя в массиве. Для удобства мы будем показывать номера слева от указателей на табличные версии строк.

Важный момент состоит в том, что никакой индекс не содержит информацию о версионности (нет полей хтіп и хтах). Прочитав индексную запись, невозможно определить видимость строки, на которую она ссылается, не заглянув в табличную страницу. Для оптимизации этой проверки служит карта видимости.

На рисунке показаны записи обычного индекса-В-дерева. Для простоты указатели на эти записи опущены.



Рассмотрим, как выполняются операции со строками на низком уровне, и начнем со вставки.

В нашем примере предполагается таблица с двумя столбцами (числовой и текстовый); по текстовому полю создан индекс В-дерево.

При вставке строки в табличной странице появится указатель с номером 1, ссылающийся на первую и единственную версию строки.

В версии строки поле хтіп заполнено номером текущей транзакции (100 в нашем примере). Поскольку изменения еще не фиксировались и транзакция активна, то в журнале статуса транзакций (CLOG) соответствующая запись заполнена нулями. CLOG можно представить себе как массив, в котором для каждой транзакции (начиная с некоторой) отводится ровно два бита. Эти данные хранятся в каталоге PGDATA/pg\_xact, а несколько наиболее актуальных страниц кешируются в разделяемой памяти сервера.

В индексной странице также создается указатель с номером 1, который ссылается на индексную запись, которая, в свою очередь, ссылается на первую версию строки в табличной странице. Чтобы не загромождать рисунок, указатель и индексная запись объединены.

Поле хтах заполнено фиктивным номером 0, поскольку данная версия строки не удалена и является актуальной. Транзакции не будут обращать внимание на этот номер, поскольку установлен бит хтах aborted.

### Вставка

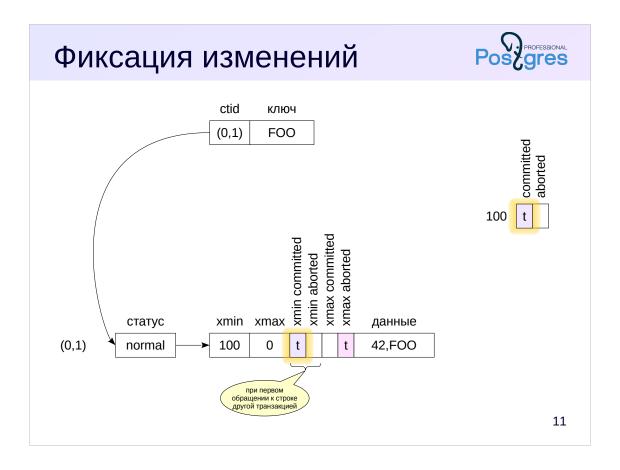
=> SELECT \* FROM t\_v;

```
Создадим таблицу и индекс:
=> CREATE TABLE t(
 id integer GENERATED ALWAYS AS IDENTITY,
 s text
);
CREATE TABLE
=> CREATE INDEX t_s on t(s);
CREATE INDEX
Для удобства создадим представление, которое с помощью расширения pageinspect покажет интересующую нас
информацию о версиях строк из нулевой страницы таблицы:
=> CREATE VIEW t v AS
SELECT '(θ,'||lp||')' AS ctid,
       CASE lp_flags
         WHEN 0 THEN 'unused'
         WHEN 1 THEN 'normal'
         WHEN 2 THEN 'redirect to '||lp_off
         WHEN 3 THEN 'dead'
       END AS state,
       t_xmin as xmin,
       t_xmax as xmax,
       CASE WHEN (t_infomask & 256) > 0 THEN 't' END AS xmin_c,
       CASE WHEN (t_infomask & 512) > 0 THEN 't' END AS xmin_a,
       CASE WHEN (t_infomask & 1024) > 0 THEN 't' END AS xmax_c,
       CASE WHEN (t_infomask & 2048) > 0 THEN 't' END AS xmax_a
FROM heap_page_items(get_raw_page('t',0))
ORDER BY lp;
CREATE VIEW
Также создадим представление, чтобы заглянуть в индекс. Нулевая страница индекса содержит метаинформацию,
поэтому смотрим в первую:
=> CREATE VIEW t_s_v AS
SELECT itemoffset,
       ctid
FROM bt page items('t s',1);
CREATE VIEW
Вставим одну строку, предварительно начав транзакцию.
=> BEGIN;
BEGIN
=> INSERT INTO t(s) VALUES ('F00');
INSERT 0 1
Вот номер нашей текущей транзакции и ее статус:
=> SELECT pg_current_xact_id(); -- txid_current() до версии 13
 pg_current_xact_id
                517
(1 row)
=> SELECT pg_xact_status('517');
 pg_xact_status
in progress
(1 row)
Вот что содержится в табличной странице:
```

Похожую, но существенно менее детальную информацию можно получить и из самой таблицы, используя псевдостолбцы ctid, xmin и xmax:

```
=> SELECT ctid, xmin, xmax, * FROM t;
ctid | xmin | xmax | id | s
.....+....+....+.....
(0,1) | 517 | 0 | 1 | F00
(1 row)
```

В индексной странице видим один указатель на единственную строку таблицы:



При фиксации изменений в CLOG для данной транзакции выставляется признак committed. Это, по сути, единственная операция (не считая журнала упреждающей записи), которая необходима.

Когда какая-либо другая транзакция обратится к этой табличной странице, ей придется ответить на вопросы:

- 1) завершилась ли транзакция 100 (надо проверить список активных процессов и их транзакций; такая структура в общей памяти имеет название ProcArray),
- 2) а если завершилась, то фиксацией или отменой (свериться с CLOG).

Поскольку выполнять проверку по CLOG каждый раз накладно, выясненный однажды статус транзакции записывается в битыподсказки xmin committed и xmin aborted. Если один из этих битов установлен, то состояние транзакции xmin считается известным и следующей транзакции уже не придется обращаться к CLOG.

Почему эти биты не устанавливаются той транзакцией, которая выполняла вставку? В момент, когда транзакция фиксируется или отменяется, уже непонятно, какие именно строки в каких именно страницах транзакция успела поменять. Кроме того, часть этих страниц может быть вытеснена из буферного кеша на диск; читать их заново, чтобы изменить биты, означало бы существенно замедлить фиксацию.

Обратная сторона состоит в том, что любая транзакция (даже выполняющая простое чтение — SELECT) может загрязнить данные в буферном кеше и породить новые журнальные записи.

### Фиксапия изменений

Выполним фиксацию:

```
=> COMMIT;
```

COMMIT

Что изменилось в странице?

Ничего, так как единственная операция, которая выполняется при фиксации — запись статуса транзакции в CLOG.

```
=> SELECT pg_xact_status('517');
pg_xact_status
.....
committed
(1 row)
```

Информация о статусах транзакций хранится в подкаталоге pg\_xact каталога PGDATA и кешируется в общей памяти. Начиная с PostgreSQL 13, статистику использования кеша показывает представление pg\_stat\_slru:

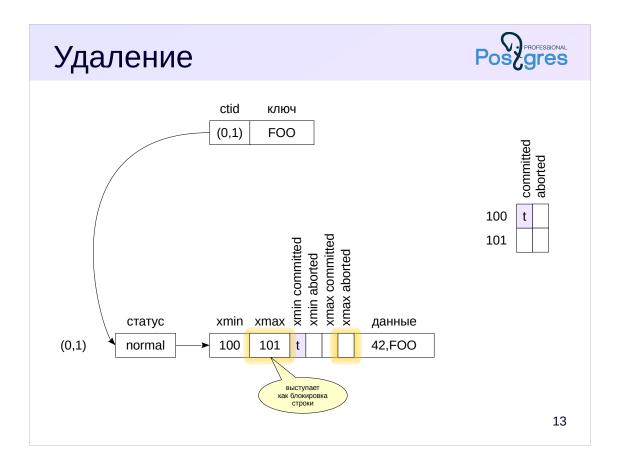
```
=> SELECT name, blks_hit, blks_read, blks_written
FROM pg_stat_slru WHERE name = 'Xact';

name | blks_hit | blks_read | blks_written

Xact | 76 | 0 | 0

(1 row)
```

Транзакция, первой обратившаяся к странице, должна будет определить статус транзакции xmin. Этот статус будет записан в информационные биты:



При удалении строки в поле хтах текущей версии записывается номер текущей удаляющей транзакции, а бит хтах aborted сбрасывается. Больше ничего не происходит.

Заметим, что установленное значение хтах, соответствующее активной транзакции (что определяется другими транзакциями по ProcArray), выступает в качестве блокировки. Если другая транзакция намерена обновить или удалить эту строку, она будет вынуждена дождаться завершения транзакции хтах.

Подробнее блокировки рассматриваются в одноименном модуле. Пока отметим только, что число блокировок строк ничем не ограничено. Они не занимают место в оперативной памяти, производительность системы не страдает от их количества (разумеется, за исключением того, что первый процесс, обратившийся к странице, должен будет проставить биты-подсказки).

# Удаление

```
Tenepь удалим строку.

=> BEGIN;

BEGIN

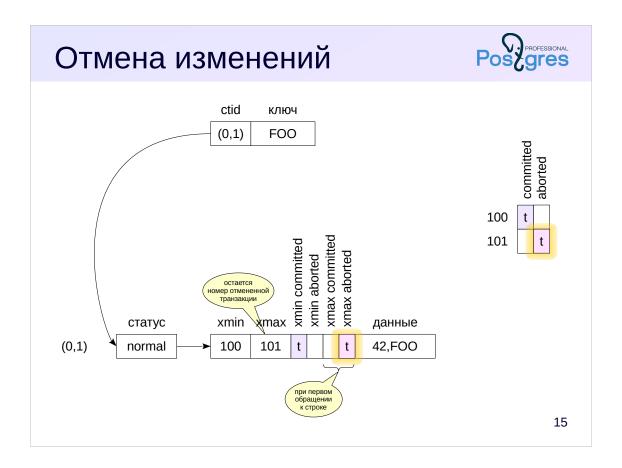
=> DELETE FROM t;

DELETE 1

Homep транзакции записался в поле xmax:

=> SELECT * FROM t_v;

ctid | state | xmin | xmax | xmin_c | xmin_a | xmax_c | xmax_a | x
```

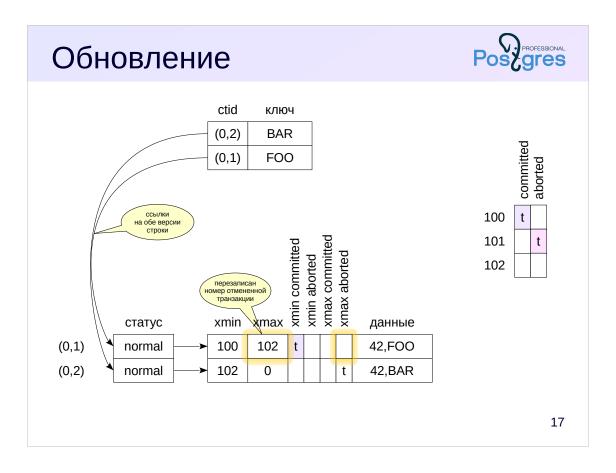


Отмена изменений работает аналогично фиксации, только в CLOG для транзакции выставляется бит aborted. Отмена выполняется так же быстро, как и фиксация — не требуется выполнять откат выполненных действий.

Номер прерванной транзакции остается в поле хтах — его можно было бы стереть, но в этом нет смысла. При обращении к странице будет проверен статус и в версию строки будет установлен бит подсказки хтах aborted. Это будет означать, что на поле хтах смотреть не нужно.

### Отмена изменений

При обрыве транзакции номер хтах остается в заголовке.



Обновление работает так, как будто сначала выполнялось удаление старой версии строки, а затем вставка новой.

Старая версия помечается номером текущей транзакции в поле хтах. Обратите внимание, что новое значение 102 записалось поверх старого 101, так как транзакция 101 была отменена. Кроме того, биты хтах соmmitted и хтах аborted старой версии строки сброшены в ноль, так как статус текущей транзакции еще не известен.

В индексной странице появляется второй указатель и вторая запись, ссылающаяся на вторую версию в табличной странице.

Так же, как и при удалении, значение хтах в первой версии строки служит признаком того, что строка заблокирована.

### Обновление

(1 row)

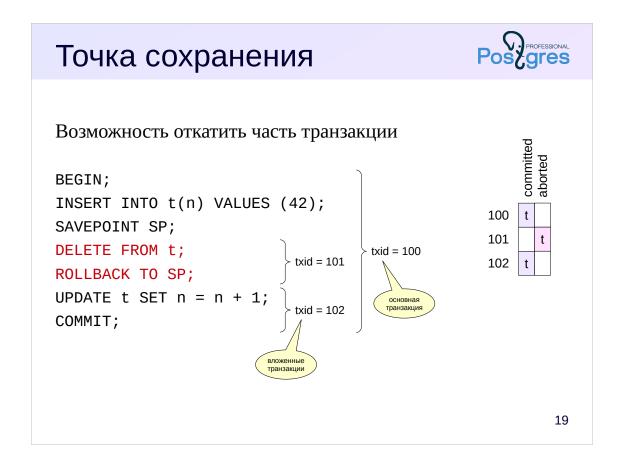
Теперь проверим обновление.

```
=> UPDATE t SET s = 'BAR';
UPDATE 1
Запрос выдает одну строку (новую версию):
=> SELECT * FROM t;
id | s
...+....
1 | BAR
```

Но в странице мы видим обе версии. Причем новый номер транзакции записался на место старого (поскольку старая транзакция была отменена).

При этом в индексной странице обнаруживаем указатели на обе версии:

Индексные записи внутри страницы упорядочены. Поэтому первой идет запись с ключом BAR (ссылается на версию (0,2)), а второй — запись с ключом FOO (ссылается на версию (0,1)).



Тонкий момент представляет функционал точек сохранения, позволяющий отменить часть операцией текущей транзакции. Это не укладывается в приведенную выше схему, поскольку физически никакие данные не откатываются, а лишь изменяется статус всей транзакции целиком.

Поэтому транзакция с точкой сохранения состоит из отдельных вложенных (не путать с автономными!) транзакций (subtransactions), статусом которых можно управлять отдельно.

# Вложенные транзакции



# Собственный номер и статус в CLOG

конечный статус зависит от статуса основной транзакции

# Информация о вложенности сохраняется на диске

каталог PGDATA/pg\_subtrans данные кешируются в буферах общей памяти (аналогично CLOG)

# Примеры использования

точка сохранения SAVEPOINT обработка исключений в PL/pgSQL (EXCEPTION) режим psql ON\_ERROR\_ROLLBACK = on/interactive

20

Вложенные транзакции имеют свой номер (бо́льший, чем номер основной транзакции). Статус вложенных транзакций записывается обычным образом в CLOG, однако финальный статус зависит от статуса основной транзакции: если она отменена, то отменяются также и все вложенные транзакции.

Информация о вложенности транзакций хранится в каталоге PGDATA/pg\_subtrans. Обращение к файлам происходит через буферы в общей памяти сервера, организованные так же, как и буферы CLOG.

Вложенные транзакции нельзя использовать явно, то есть нельзя начать новую транзакцию, не завершив текущую. Этот механизм задействуется неявно при использовании точек сохранения, при обработке исключений PL/pgSQL и т. п.

Особенный интерес представляет режим ON\_ERROR\_ROLLBACK в psql, при включении которого транзакция, выполнившая ошибочную операцию, не прерывается, а продолжает работать. Почему этот режим не включен по умолчанию? Дело в том, что ошибка может произойти где-то в середине выполнения оператора, и таким образом нарушится атомарность выполнения оператора. Единственный способ отменить изменения, уже сделанные этим оператором, не трогая остальные изменения — использовать вложенные транзакции. Поэтому режим ON\_ERROR\_ROLLBACK фактически ставит перед каждой командой неявную точку сохранения. А это чревато существенными накладными расходами.

### Точки сохранения и вложенные транзакции

RETURNING \*, ctid, xmin, xmax;

```
Опустошим таблицу (при этом опустошаются файлы таблицы и индекса):
=> TRUNCATE t;
TRUNCATE TABLE
Начинаем транзакцию и вставляем первую строку.
=> BEGIN;
BEGIN
=> INSERT INTO t(s) VALUES ('F00')
 RETURNING *, ctid, xmin, xmax;
id | s | ctid | xmin | xmax
 2 | F00 | (0,1) | 521 | 0
(1 row)
INSERT 0 1
Ставим точку сохранения и вставляем вторую строку.
=> SAVEPOINT sp;
SAVEPOINT
=> INSERT INTO t(s) VALUES ('BAR')
 RETURNING *, ctid, xmin, xmax;
id | s | ctid | xmin | xmax
 3 | BAR | (0,2) | 522 | 0
(1 row)
INSERT 0 1
Обратите внимание: функция pg current xact id() выдает номер основной, а не вложенной, транзакции:
=> SELECT pg current xact id();
 pg_current_xact_id
               521
(1 row)
Откатимся к точке сохранения. Версии строк в странице остаются на месте, зато изменится статус вложенной
транзакции:
=> ROLLBACK TO sp;
ROLLBACK
=> SELECT pg_xact_status('521') xid,
          pg_xact_status('522') subxid;
   xid | subxid
in progress | aborted
(1 row)
Поэтому запрос к таблице вторую строку не покажет:
=> SELECT *, ctid, xmin, xmax FROM t;
id | s | ctid | xmin | xmax
 2 | F00 | (0,1) | 521 | 0
(1 row)
Для дальнейших изменений создается новая вложенная транзакция:
=> INSERT INTO t(s) VALUES ('BAZ')
```

Фиксируем изменения. При этом в таблице, как и прежде, ничего не меняется:

```
=> COMMIT;
COMMIT
=> SELECT * FROM t_v;
```

```
ctid | state | xmin | xmax | xmin_c | xmin_a | xmax_c | xmax_a | (0,1) | normal | 521 | 0 | | | | | | t | (0,2) | normal | 522 | 0 | | t | | t | t (0,3) | normal | 523 | 0 | | | | | t | t (3 rows)
```

А в CLOG основная транзакция и все вложенные, которые еще не завершены, получают статус committed:

Информация о вложенности транзакций хранится в подкаталоге pg\_subtrans каталога PGDATA. Она кешируется в общей памяти, как и информация о статусах транзакций:

# Итоги



В табличных страницах может храниться несколько версий одной и той же строки, ограниченных номерами транзакций xmin и xmax

В индексных записях нет информации о версионности Фиксация и откат выполняются одинаково быстро Для точек сохранения используются вложенные транзакции

22

# Практика



- 1. Создайте таблицу и вставьте в нее одну строку. Затем дважды обновите эту строку и удалите ее. Сколько версий строк находится сейчас в таблице? Проверьте, используя расширение pageinspect.
- 2. Определите, в какой странице находится строка таблицы pg\_class, относящаяся к самой таблице pg\_class. Сколько актуальных версий строк находится в той же странице?
- 3. Включите в psql параметр ON\_ERROR\_ROLLBACK и убедитесь, что этот режим использует вложенные транзакции.

23

### 1. Версии строк

```
Создаем расширение и таблицу.
=> CREATE DATABASE mvcc_tuples;
CREATE DATABASE
=> \c mvcc_tuples
You are now connected to database "mvcc_tuples" as user "student".
=> CREATE EXTENSION pageinspect;
CREATE EXTENSION
=> CREATE TABLE t(s text):
CREATE TABLE
Вставляем строку, обновляем ее и затем удаляем:
=> INSERT INTO t VALUES ('F00');
INSERT 0 1
=> UPDATE t SET s = 'BAR';
UPDATE 1
=> UPDATE t SET s = 'BAZ':
UPDATE 1
=> DELETE FROM t;
DELETE 1
В таблице ничего нет:
=> SELECT * FROM t;
(0 rows)
Проверяем версии в странице:
=> SELECT '(0,'||lp||')' AS ctid,
       t_xmin as xmin,
       t xmax as xmax,
       CASE WHEN (t_infomask & 256) > 0 THEN 't' END AS xmin_c,
       CASE WHEN (t_infomask & 512) > 0 THEN 't' END AS xmin_a,
       CASE WHEN (t_infomask & 1024) > 0 THEN 't' END AS xmax_c,
       CASE WHEN (t_infomask & 2048) > 0 THEN 't' END AS xmax_a
FROM heap_page_items(get_raw_page('t',0))
ORDER BY lp;
 ctid | xmin | xmax | xmin_c | xmin_a | xmax_c | xmax_a
(0,1) | 28771 | 28772 | t | (0,2) | 28772 | 28773 | t |
                                          | t
                                                   | t
 (0,3) | 28773 | 28774 | t
                                          | t
(3 rows)
```

### 2. Версии строк на определенной странице

Номер страницы содержится в первой компоненте значения ctid:

```
=> SELECT ctid FROM pg_class WHERE relname = 'pg_class';
  ctid
------
(7,18)
(1 row)
```

К сожалению, тип данных tid не позволяет непосредственно получить номер страницы, но можно, например, воспользоваться приведением к типу point:

```
=> SELECT (ctid::text::point)[0]::integer FROM pg_class WHERE relname = 'pg_class';
ctid
   7
(1 row)
Количество строк на той же странице:
=> SELECT count(*)
FROM pg_class
WHERE (ctid::text::point)[0]::integer = (
 SELECT (ctid::text::point)[0]::integer FROM pg_class WHERE relname = 'pg_class'
count
_ _ _ _ _
   31
(1 row)
3. Peжим ON_ERROR_ROLLBACK
Включим режим:
=> \set ON_ERROR_ROLLBACK on
Начнем транзакцию и вставим строку.
=> BEGIN;
BEGIN
=> INSERT INTO t VALUES ('F00')
 RETURNING s, xmin, pg_current_xact_id();
 s | xmin | pg_current_xact_id
F00 | 28776 | 28775
(1 row)
INSERT 0 1
Вставим еще одну строку.
=> INSERT INTO t VALUES ('BAR')
 RETURNING s, xmin, pg_current_xact_id();
 s | xmin | pg_current_xact_id
BAR | 28777 |
                         28775
(1 row)
INSERT 0 1
Каждая команда происходит в отдельной вложенной транзакции, что и требовалось установить.
=> COMMIT;
```

COMMIT