

Авторские права

© Postgres Professional, 2016–2022.

Авторы: Егор Рогов, Павел Лузанов, Илья Баштанов

Использование материалов курса

Некоммерческое использование материалов курса (презентации, демонстрации) разрешается без ограничений. Коммерческое использование возможно только с письменного разрешения компании Postgres Professional. Запрещается внесение изменений в материалы курса.

Обратная связь

Отзывы, замечания и предложения направляйте по адресу: edu@postgrespro.ru

Отказ от ответственности

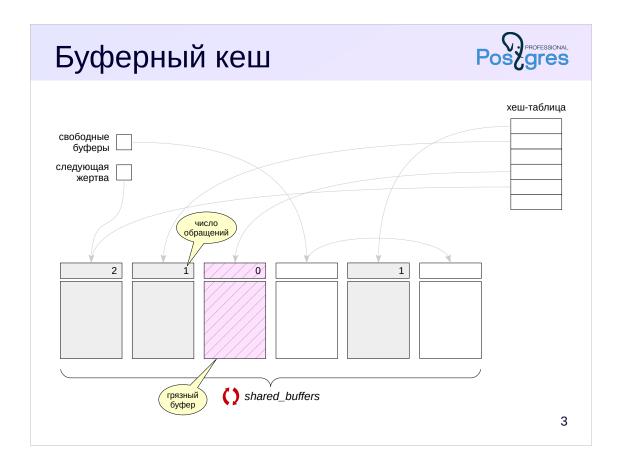
Компания Postgres Professional не несет никакой ответственности за любые повреждения и убытки, включая потерю дохода, нанесенные прямым или непрямым, специальным или случайным использованием материалов курса. Компания Postgres Professional не предоставляет каких-либо гарантий на материалы курса. Материалы курса предоставляются на основе принципа «как есть» и компания Postgres Professional не обязана предоставлять сопровождение, поддержку, обновления, расширения и изменения.

Темы



Устройство и использование буферного кеша Механизм вытеснения страниц Массовое вытеснение и буферные кольца Настройка размера кеша Локальный кеш для временных таблиц Прогрев кеша

2



Задача буферного кеша — сглаживать разницу в производительности двух типов памяти: оперативной (быстрая, но мало) и дисковой (медленная, но много). Чтобы работать с данными — читать или изменять, — процессы читают страницы в буферный кеш. Пока страница находится в кеше, мы экономим на обращениях к диску.

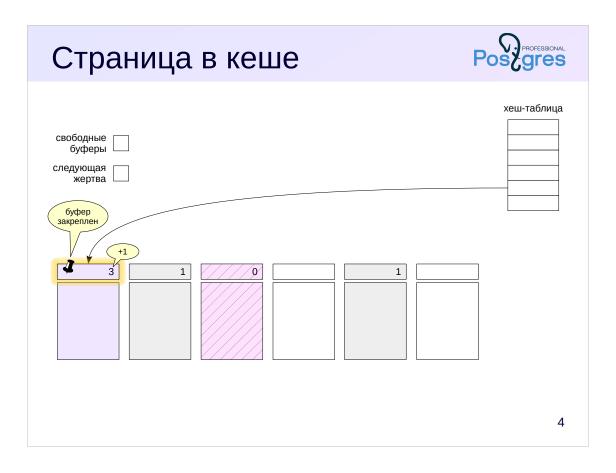
Буферный кеш располагается в общей памяти сервера и представляет собой массив буферов. Каждый буфер состоит из места под одну страницу данных и заголовка. Заголовок содержит, в числе прочего:

- расположение страницы на диске (файл и номер страницы в нем);
- число обращений к буферу (счетчик увеличивается каждый раз, когда процесс читает или изменяет буфер);
- признак того, что данные на странице изменились и рано или поздно должны быть записаны на диск (такой буфер называют грязным);

Размер буферного кеша задается параметром *shared_buffers*. Его изменение требует перезапуска сервера.

Изначально кеш содержит пустые буферы, и все они связаны в список свободных буферов. Смысл указателя на «следующую жертву» станет ясен чуть позже.

Чтобы быстро находить нужную страницу в кеше, используется хештаблица.



Когда процессу требуется прочитать страницу, он сначала пытается найти ее в буферном кеше с помощью хеш-таблицы.

Ключом хеширования служит файл и номер страницы внутри файла; получив номер буфера, процесс быстро проверяет, действительно ли он содержат нужную страницу. Как и в любой хеш-таблице, здесь возможны коллизии; в таком случае процессу придется проверить несколько страниц.

Если нужная страница найдена в кеше, процесс должен «закрепить» буфер (увеличить счетчик pin count) и увеличить число обращений (счетчик usage count). Буфер могут закреплять несколько процессов одновременно, поэтому используется именно счетчик, а не логический признак.

Пока буфер закреплен (значение pin count больше нуля), считается, что буфер используется и его содержимое не должно «радикально» измениться. Например, в странице может появиться новая версия строки — это никому не мешает благодаря многоверсионности и правилам видимости. Но в закрепленный буфер не может быть прочитана другая страница.

Страница в кеше

```
=> CREATE DATABASE wal_buffercache;
CREATE DATABASE
=> \c wal_buffercache
You are now connected to database "wal_buffercache" as user "student".
Создадим таблицу с одной строкой:
=> CREATE TABLE test(
 t text
WITH (autovacuum_enabled = off);
CREATE TABLE
=> INSERT INTO test VALUES ('a row');
Содержимое буферного кеша можно посмотреть с помощью расширения:
=> CREATE EXTENSION pg_buffercache;
CREATE EXTENSION
Создадим для удобства представление, расшифровывающее некоторые столбцы.
Условие на базу данных необходимо, так как в буферном кеше содержатся данные всего кластера. Расшифровать
мы можем только информацию из той БД, к которой подключены. Глобальные объекты считаются принадлежащими
БД с нулевым OID.
=> CREATE VIEW pg_buffercache_v AS
SELECT bufferid,
       (SELECT c.relname
       FROM pg_class c
WHERE pg_relation_filenode(c.oid) = b.relfilenode
       ) relname.
       CASE relforknumber
        WHEN 0 THEN 'main'
        WHEN 1 THEN 'fsm'
        WHEN 2 THEN 'vm'
       END relfork,
       relblocknumber,
       isdirty,
      usagecount
FROM
      pg_buffercache b
WHERE b.reldatabase IN (
         0, (SELECT oid FROM pg_database WHERE datname = current_database())
AND
       b.usagecount IS NOT NULL;
CREATE VIEW
В буферном кеше уже находятся страницы таблицы; они появились при выполнении вставки:
=> SELECT * FROM pg buffercache_v WHERE relname = 'test';
bufferid | relname | relfork | relblocknumber | isdirty | usagecount
     330 | test | main |
                                             0 | t
                                                        (1 row)
Команда EXPLAIN с указанием analyze и buffers показывает использование буферного кеша при выполнении
=> EXPLAIN (analyze, buffers, costs off, timing off, summary off)
SELECT * FROM test;
```

```
QUERY PLAN
```

```
Seq Scan on test (actual rows=1 loops=1)
  Buffers: shared hit=1
Planning:
  Buffers: shared hit=3
(4 rows)
```

Строка «Buffers: shared hit=1» говорит о том, что страница была найдена в кеше.

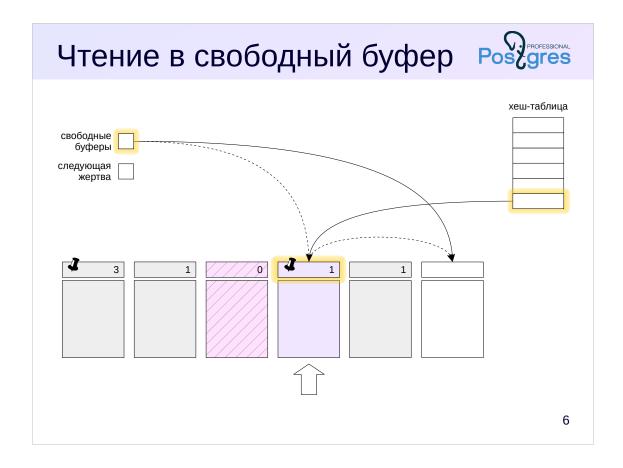
После выполнения запроса счетчик использования увеличился на единицу:

```
=> SELECT * FROM pg_buffercache_v WHERE relname = 'test';

bufferid | relname | relfork | relblocknumber | isdirty | usagecount

330 | test | main | 0 | t | 2

(1 row)
```



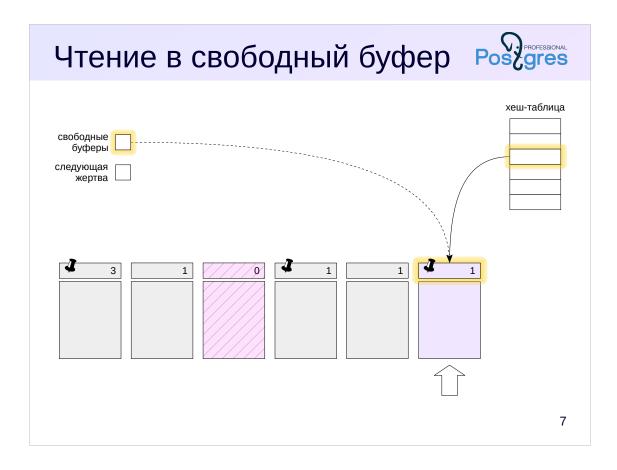
Может получиться так, что необходимая страница не будет найдена в кеше. В этом случае ее необходимо считать с диска в какой-либо буфер.

В первую очередь поиск подходящего буфера будет проходить по списку свободных буферов, если он не пуст.

Найденный по указателю буфер закрепляется, в него читается необходимая страница, число обращений устанавливается в единицу.

Указатель на свободный буфер передвигается на следующий по списку буфер, если он есть.

Кроме того, ссылку на загруженную страницу необходимо прописать в хеш-таблицу, чтобы в дальнейшем ее можно было найти.



В конце концов будет заполнен и последний свободный буфер.

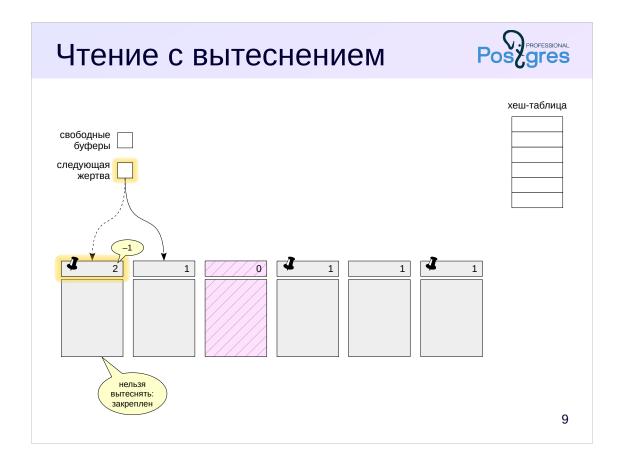
Теперь ссылка на свободный буфер пуста — в дальнейшем, чтобы прочитать новую страницу в любой буфер, придется из этого буфера вытеснить страницу, которая там находится.

Буферы возвращаются в список свободных буферов только при удалении или опустошении таблицы, или при отсечении части хвостовых страниц при очистке — то есть в случаях, когда страница в буфере не заменяется другой, а просто исчезает.

Чтение в свободный буфер

```
Перезагрузим сервер, чтобы сбросить буферный кеш.
student$ sudo pg_ctlcluster 13 main restart
student$ psql wal_buffercache
В кеше есть свободные буферы:
=> SELECT count(*) FROM pg_buffercache WHERE usagecount IS NULL;
16211
(1 row)
Выполним запрос к таблице:
=> EXPLAIN (analyze, buffers, costs off, timing off, summary off)
SELECT * FROM test;
              QUERY PLAN
Seq Scan on test (actual rows=1 loops=1)
  Buffers: shared read=1
Planning:
  Buffers: shared hit=12 read=6
(4 rows)
Строка «Buffers: shared read=1» показывает, что страницу пришлось прочитать. Вот она:
=> SELECT * FROM pg_buffercache_v WHERE relname = 'test';
bufferid | relname | relfork | relblocknumber | isdirty | usagecount
-----
                                       0 | f | 1
     181 | test | main |
(1 row)
Количество свободных буферов уменьшилось:
=> SELECT count(*) FROM pg buffercache WHERE usagecount IS NULL;
count
16160
(1 row)
```

В кеш попала не только прочитанная страница, но и страницы таблиц системного каталога, которые потребовались планировщику.

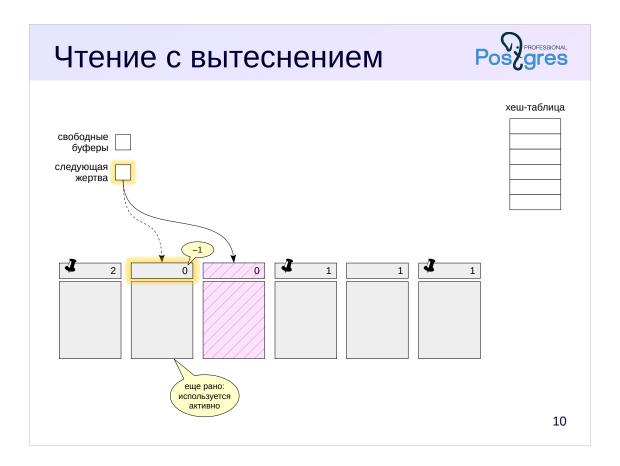


Механизм вытеснения использует указатель на следующую «жертву».

Алгоритм состоит в том, чтобы перебирать по кругу все буферы, уменьшая их счетчики обращений (usage count). Выбирается первый же буфер, у которого значение счетчика равно 0 и который в принципе может быть занят новой страницей. По-английски этот алгоритм называется clock-sweep: аналогия с часовой стрелкой, которая пробегает циферблат по кругу.

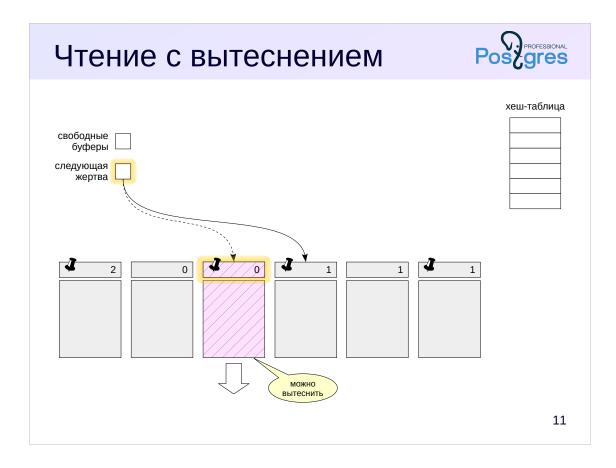
Чем больше значение счетчика у буфера (то есть чем чаще он используется), тем больше у него шансов задержаться в кеше. Максимальное значение счетчика обращений ограничено числом 5, чтобы избежать «наматывания кругов» при больших значениях.

В нашем примере процесс обращается к буферу по указателю. Буфер закреплен (то есть используется каким-то процессом), и поэтому страница не может быть вытеснена из него. Тем не менее мы уменьшаем значение счетчика обращений на единицу и переходим к следующему буферу.



Следующий буфер не закреплен, однако его счетчик обращений больше нуля.

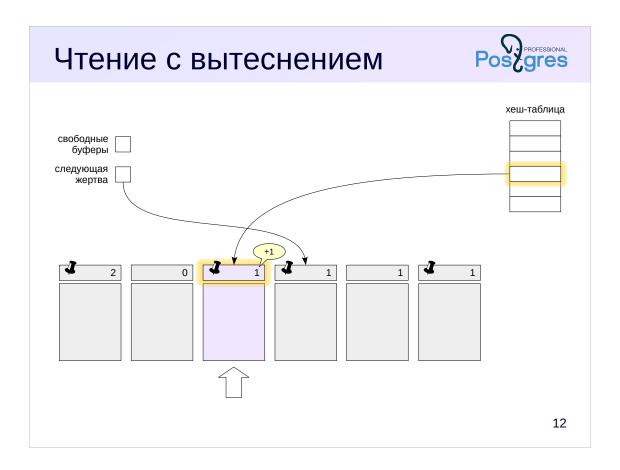
Мы уменьшаем счетчик на единицу и даем ему шанс остаться в кеше.



Наконец, мы приходим к незакрепленному буферу с нулевым счетчиком обращений. Страница из этого буфера и будет вытеснена.

Однако в нашем примере найденный буфер оказался грязным — он содержит измененные данные. Поэтому сначала страницу требуется сохранить на диск. Для этого буфер закрепляется (чтобы показать остальным процессам, что он используется), после чего страница записывается на диск.

Это не очень хорошая ситуация: процессу, который собирался прочитать страницу, придется ждать, пока «чужие» данные будут записаны. Этот эффект сглаживается процессами контрольной точки и фоновой записи, которые рассмотрены в теме «Контрольная точка».



После того как страница из грязного буфера записана на диск, в освободившийся буфер ранее рассмотренным образом читается новая страница.

Ссылка на следующую «жертву» уже указывает на следующий буфер, а у только что загруженного есть время нарастить счетчик обращений, пока указатель не обойдет по кругу весь буферный кеш и не вернется вновь.

Настройка размера кеша



Настройка



() shared_buffers = 128MB ~



Буферный кеш должен содержать «активные» данные

при меньшем размере постоянно вытесняются полезные страницы при большем размере бессмысленно растут накладные расходы начальное приближение — 0.25 ОЗУ

Нужно учитывать двойное кеширование

если страницы нет в кеше СУБД, она может оказаться в кеше ОС алгоритм вытеснения ОС не учитывает специфики базы данных

13

Размер кеша устанавливается параметром shared_buffers. Значение по умолчанию — 128 МБ — сильно занижено.

Как выбрать подходящее значение? Даже самая большая база имеет ограниченный набор данных, с которыми ведется активная работа. В идеале этот набор (плюс некоторое место для «одноразовых» данных) должен помещаться в буферный кеш.

При меньшем размере кеша активно используемые страницы будут постоянно вытеснять друг друга, создавая избыточный ввод-вывод. Признаком такой ситуации может служить то, что все страницы в кеше имеют большое число обращений (usage count).

Однако при большом размере кеша будут расти накладные расходы на его поддержание.

В качестве первого приближения можно взять 1/4 оперативной памяти, но надо понимать, что оптимальное значение зависит не от размера ОЗУ, а от конкретных данных и нагрузки.

He следует забывать и о том, что PostgreSQL работает с диском через операционную систему и, таким образом, происходит двойное кеширование: страницы попадают как в буферный кеш, так и в кеш ОС. Таким образом, «непопадание» в буферный кеш не всегда приводит к необходимости реального ввода-вывода. Но стратегия вытеснения ОС не учитывает специфики баз данных.

https://postgrespro.ru/docs/postgresgl/13/runtime-config-resource#RUNTIM E-CONFIG-RESOURCE-MEMORY

Настройка размера кеша

Используя расширение pg buffercache, можно наблюдать за состоянием кеша под разными углами.

Кроме информации о том, как представлена в кеше та или иная страница, можно, например, посмотреть распределение буферов по их «популярности»:

Можно посмотреть, какая доля каких таблиц закеширована (и насколько активно используются эти данные):

relname	blocks	% of rel	% hot
pg_attribute	29	51	49
pg_class	13	76	76
pg_proc	12	14	2
pg_operator	10	56	39
pg_proc_oid_index	9	82	27
pg_attribute_relid_attnum_index	8	80	60
pg_proc_proname_args_nsp_index	7	23	3
pg_operator_oprname_l_r_n_index	5	83	33
pg_amop	5	50	40
pg_amproc	4	50	13
(10 rows)			

Подобные запросы могут подсказать, насколько активно используется буферный кеш и дать пищу для размышлений о том, стоит ли увеличивать или уменьшать его размер.

Надо учитывать, что такие запросы надо повторять несколько раз: цифры будут меняться в определенных пределах.

Массовое вытеснение



Буферное кольцо

часть буферного кеша, выделенная для одной операции предотвращает вытеснение кеша «одноразовыми» данными

операция	кол-во страниц	грязные буферы
последовательное чтение	32	исключаются из кольца
очистка (VACUUM)	32	вытесняются на диск
массовая запись (СОРҮ, CTAS)	≤2048	вытесняются на диск

15

При операциях, выполняющих массовое чтение или запись данных, есть опасность быстрого вытеснения полезных страниц из буферного кеша «одноразовыми» данными. Чтобы этого не происходило, для таких операций используются так называемые буферные кольца — для каждой операции выделяется небольшая часть буферного кеша. При этом вытеснение действует только в пределах кольца, поэтому остальные данные в буфере не страдают.

При последовательном чтении (sequential scan) больших таблиц используется кольцо размером 32 страницы. Если в процессе появляются грязные буферы (в результате простановки битов-подсказок или при выполнении команды UPDATE), они отключаются от кольца, возвращаются в основной кеш и вытесняются уже на общих основаниях. Вместо отключенного буфера в кольцо из кеша подключается другой буфер. Такая стратегия рассчитана на то, что данные в основном читаются, а не меняются.

Если в процессе чтения таблицы другому процессу тоже потребуются эти данные, он не начинает читать таблицу сначала, а подключается к уже имеющемуся буферному кольцу. После окончания сканирования он дочитывает «пропущенное» начало таблицы.

Для процесса очистки также используется небольшое кольцо (32 страницы), так как замедление фоновой задачи не столь критично, как замедление пользовательских процессов.

Наоборот, для массовых операций записи — COPY, CREATE TABLE AS SELECT — кольцо имеет достаточно большой размер (обычно 2048 страниц, но не больше одной восьмой всего буферного кеша).

Массовое вытеснение

Для полного чтения таблиц, размер которых превышает четверть буферного кеша, используется буферное кольцо. Размер кеша (в страницах):

```
=> SELECT setting FROM pg_settings WHERE name='shared_buffers';
 setting
16384
(1 row)
Добавим строк в таблицу:
=> INSERT INTO test SELECT repeat('A',1000) FROM generate_series(1,30000);
INSERT 0 30000
=> ANALYZE test;
ANALYZE
=> SELECT relpages FROM pg_class WHERE relname = 'test';
 relpages
     4286
(1 row)
Перезагрузим сервер, чтобы сбросить буферный кеш.
student$ sudo pg_ctlcluster 13 main restart
student$ psql wal_buffercache
Прочитаем данные из таблицы:
=> EXPLAIN (analyze, buffers, costs off, timing off, summary off)
SELECT * FROM test:
                  QUERY PLAN
Seq Scan on test (actual rows=30001 loops=1)
   Buffers: shared read=4286
 Planning:
  Buffers: shared hit=12 read=7 dirtied=1
(4 rows)
Были прочитаны все страницы с данными, но сколько буферов кеша ими занято?
=> SELECT count(*) FROM pg buffercache v WHERE relname = 'test';
 count
   32
(1 row)
Но если страницы будут изменяться и отсоединяться от буферного кольца, они могут занять значительную часть
=> EXPLAIN (analyze, buffers, costs off, timing off, summary off)
UPDATE test SET t = t || '!';
                           QUERY PLAN
 Update on test (actual rows=0 loops=1)
   Buffers: shared hit=68603 read=4257 dirtied=8574 written=4286
   -> Seq Scan on test (actual rows=30001 loops=1)
         Buffers: shared hit=32 read=4254
 Planning:
  Buffers: shared hit=3
(6 rows)
```

Сейчас в кеше находятся все или почти все страницы таблицы, количество которых удвоилось из-за появления новых версий строк:

Локальный кеш



Для временных таблиц

видны только одному сеансу — нет смысла использовать общий кеш существуют в пределах сеанса — не жалко потерять при сбое

Особенности

не требуются блокировки память выделяется по необходимости в пределах *temp_buffers* обычный алгоритм вытеснения

17

Исключение из общего правила представляют собой временные таблицы. Поскольку временные данные видны только одному процессу, им нечего делать в общем буферном кеше. Более того, временные данные существуют только в рамках одного сеанса, так что их не нужно защищать от сбоя.

Для временных данных используется облегченный локальный кеш.

Поскольку локальный кеш доступен только одному процессу, для него не требуются блокировки. Память выделяется по мере необходимости (в пределах, заданных параметром temp_buffers), ведь временные таблицы используются далеко не во всех сеансах. В локальном кеше используется обычный алгоритм вытеснения.

Временные таблицы

Buffers: local hit=1

Buffers: shared hit=3

Planning:

(4 rows)

```
COЗДАДИМ ВРЕМЕННУЮ ТАБЛЕЦ C ОДНОЙ СТРОКОЙ:

=> CREATE TEMP TABLE test_tmp(
    t text
);

CREATE TABLE

=> INSERT INTO test_tmp VALUES ('a row');

INSERT 0 1

В плане выполнения запроса обращение к локальному кешу выглядит как «Buffers: local»:

=> EXPLAIN (analyze, buffers, costs off, timing off, summary off)

SELECT * FROM test_tmp;

QUERY PLAN

Seq Scan on test_tmp (actual rows=1 loops=1)
```

Прогрев кеша



Расширение pg_prewarm

ручной прогрев кеша операционной системы ручной прогрев буферного кеша автоматический прогрев буферного кеша при перезапуске сервера

19

После перезапуска сервера буферный кеш пуст и должно пройти некоторое время, чтобы он «прогрелся», то есть набрал актуальные активно использующиеся данные. Иногда может оказаться полезным сразу прочитать в кеш данные определенных таблиц.

Расширение pg_prewarm позволяет в ручном режиме прочитать некоторые таблицы либо в кеш операционной системы, либо и в буферный кеш СУБД тоже.

Начиная с версии PostgreSQL 11, расширение позволяет в автоматическом режиме восстановить содержимое буферного кеша после перезапуска сервера. Для этого необходимо подключить библиотеку расширения, добавив ее в параметр shared_preload_libraries.

https://postgrespro.ru/docs/postgresql/13/pgprewarm

Прогрев кеша

Посмотрим самый простой сценарий использования расширения для прогрева кеша.

```
=> CREATE EXTENSION pg_prewarm;

CREATE EXTENSION

В очередной раз перезапустим сервер, чтобы в кеше не было таблицы test:

student$ sudo pg_ctlcluster 13 main restart

student$ psql wal_buffercache

=> SELECT count(*) FROM pg_buffercache_v WHERE relname = 'test';

count

0
(1 row)
```

Вызов функции pg_prewarm без дополнительных параметров полностью считывает основной слой указанной таблицы в буферный кеш:

Итоги



Вся работа с данными происходит через буферный кеш Редко используемые страницы вытесняются, часто используемые — остаются

Буферный кеш сокращает объем ввода-вывода, но приводит к необходимости журналирования

21

Практика



- 1. Создайте таблицу и вставьте в нее некоторое количество строк. Определите, сколько занимает таблица
 - а) страниц на диске,
 - б) буферов в кеше.
- 2. Узнайте количество грязных буферов в кеше на текущий момент. Выполните контрольную точку командой СНЕСКРОІNТ. Сколько грязных буферов осталось теперь?
- 3. Подключите библиотеку расширения pg_prewarm и проверьте, что после перезапуска сервера содержимое буферного кеша восстанавливается.

22

Чтобы проверить содержимое буферного кеша, используйте расширение pg_buffercache: https://postgrespro.ru/docs/postgresql/13/pgbuffercache.html

1. Таблина в кеше

```
Создадим таблицу:
=> CREATE DATABASE wal_buffercache;
CREATE DATABASE
=> \c wal_buffercache
You are now connected to database "wal_buffercache" as user "student".
=> CREATE TABLE t(n integer);
CREATE TABLE
=> INSERT INTO t SELECT 1 FROM generate_series(1,10000);
INSERT 0 10000
Сколько страниц на диске занимает таблица?
=> SELECT setting FROM pg_settings WHERE name = 'block_size';
 setting
8192
(1 row)
=> SELECT pg table size('t') / 8192;
 ?column?
      48
(1 row)
Из них основной слой:
=> SELECT pg relation size('t', 'main') / 8192;
 ?column?
      45
(1 row)
И карта свободного пространства:
=> SELECT pg_relation_size('t','fsm') / 8192;
 ?column?
        3
(1 row)
Сколько буферов в кеше занимает таблица?
=> CREATE EXTENSION pg_buffercache;
CREATE EXTENSION
=> SELECT CASE relforknumber
         WHEN 0 THEN 'main'
         WHEN 1 THEN 'fsm'
         WHEN 2 THEN 'vm'
       END relfork,
      count(*)
FROM pg_buffercache b,
       pg class c
WHERE b.reldatabase = (
        SELECT oid FROM pg_database WHERE datname = current_database()
AND
      c.oid = 't'::regclass
AND
      b.relfilenode = c.relfilenode
GROUP BY 1;
```

2. Грязные буферы в кеше

Грязных буферов не осталось. Подробнее о контрольной точке рассказывается в отдельной теме.

3. Автоматический прогрев кеша

```
Подключим библиотеку pg prewarm и перезапустим сервер.
=> ALTER SYSTEM SET shared_preload_libraries = 'pg_prewarm';
ALTER SYSTEM
student$ sudo pg_ctlcluster 13 main restart
student$ psql wal_buffercache
Теперь отдельный фоновый процесс будет сбрасывать на диск список страниц, находящихся в буферном кеше, раз в
pg prewarm.autoprewarm interval единиц времени.
postgres$ ps -o pid,command --ppid `head -n 1 /var/lib/postgresql/13/main/postmaster.pid` | grep prewarm
  41607 postgres: 13/main: autoprewarm master
Прочитаем таблицу t в буферный кеш:
=> CREATE EXTENSION pg_prewarm;
CREATE EXTENSION
=> SELECT pg_prewarm('t');
 pg_prewarm
         45
(1 row)
=> SELECT count(*)
FROM pg buffercache
WHERE relfilenode = pg_relation_filenode('t'::regclass);
```

Можно либо подождать, либо сбросить список страниц вручную:

=> SELECT autoprewarm dump now();

45 (1 row)

```
autoprewarm_dump_now
                 299
(1 row)
В файл записываются идентификаторы базы данных, табличного пространства и файла, номер слоя и номер блока:
postgres$ head -n 10 /var/lib/postgresql/13/main/autoprewarm.blocks
<<299>>
0,1664,1262,0,0
0,1664,1260,0,0
1,1663,1259,0,0
1,1663,1259,0,1
1,1663,1259,0,2
1,1663,1259,0,3
1,1663,1249,0,0
1,1663,1249,0,1
1,1663,1249,0,2
Снова перезапустим сервер.
student$ sudo pg_ctlcluster 13 main restart
student$ psql wal_buffercache
После запуска фоновый процесс прочитает в буферный кеш все страницы, указанные в файле.
=> SELECT count(*)
FROM pg_buffercache
WHERE relfilenode = pg_relation_filenode('t'::regclass);
count
   45
(1 row)
```