

Авторские права

© Postgres Professional, 2016–2022.

Авторы: Егор Рогов, Павел Лузанов, Илья Баштанов

Использование материалов курса

Некоммерческое использование материалов курса (презентации, демонстрации) разрешается без ограничений. Коммерческое использование возможно только с письменного разрешения компании Postgres Professional. Запрещается внесение изменений в материалы курса.

Обратная связь

Отзывы, замечания и предложения направляйте по адресу: edu@postgrespro.ru

Отказ от ответственности

Компания Postgres Professional не несет никакой ответственности за любые повреждения и убытки, включая потерю дохода, нанесенные прямым или непрямым, специальным или случайным использованием материалов курса. Компания Postgres Professional не предоставляет каких-либо гарантий на материалы курса. Материалы курса предоставляются на основе принципа «как есть» и компания Postgres Professional не обязана предоставлять сопровождение, поддержку, обновления, расширения и изменения.

Темы



Уровни журнала и решаемые задачи Надежность записи Производительность

Уровни журнала



minimal, replica, logical

Уровни журнала





Minimal

восстановление после сбоя

Replica

восстановление из резервной копии, репликация

+ операции массовой обработки данных, блокировки, номера выполняющихся транзакций

Logical

логическая репликация

+ информация для логического декодирования

4

Кроме основной задачи — восстановления согласованности после сбоя — журнал можно и удобно использовать и для других целей, если добавить в него дополнительную информацию. Для этого существуют несколько уровней журнала, устанавливаемые параметром wal level.

Уровень **minimal** содержит только информацию, необходимую для восстановления после сбоя. В журнал не записываются операции массовой обработки данных (такие, как CREATE TABLE AS SELECT, CREATE INDEX и т. п.), их долговечность гарантируется немедленной записью данных на диск.

Уровень **replica** (используется по умолчанию) позволяет восстанавливать систему из горячих резервных копий, сделанных утилитой pg_basebackup. Для этого в журнал записываются все изменения данных, включая операции массовой обработки. Уровень также позволяет организовать репликацию — передавать поток журнальных записей на другой сервер (эти темы рассматриваются в курсе DBA3), для чего в журнал включается информация о ряде блокировок.

Уровень **logical** используется для логической репликации — он должен быть включен на сервере, публикующем изменения. Для правильной работы логического декодирования в журнал записывается дополнительная информация, позволяющая корректно расшифровать смысл операций по журнальным записям.

Чем выше уровень, тем больше информации попадает в журнал и, следовательно, тем больше его объем.

```
Уровни журнала
```

```
Используем новую базу данных
=> CREATE DATABASE wal_tuning;
CREATE DATABASE
=> \c wal_tuning
You are now connected to database "wal_tuning" as user "student".
Уровень журнала по умолчанию — replica.
=> SHOW wal_level;
 wal_level
 replica
(1 row)
Посмотрим, как записывается в журнал команда CREATE TABLE AS SELECT.
=> SELECT pg_current_wal_insert_lsn();
 pg current wal insert lsn
 0/100A9790
=> SELECT pg_walfile_name('0/100A9790');
      pg_walfile_name
  (1 row)
=> CREATE TABLE t wal(n) AS SELECT 1 from generate series(1,1000);
=> SELECT pg_current_wal_insert_lsn();
 pg_current_wal_insert_lsn
 0/100CE390
(1 row)
Объем журнала:
=> SELECT '0/100CE390'::pg_lsn - '0/100A9790'::pg_lsn;
 ?column?
    150528
(1 row)
Помимо изменений системного каталога, в журнал попадают записи:
    • CREATE — создание файла отношения

    INSERT+INIT — вставка строк в таблицу;
    COMMIT — фиксация транзакции.

postgres$ /usr/lib/postgresql/13/bin/pg_waldump -p /var/lib/postgresql/13/main/pg_wal -s 0/100A9790 -e 0/100CE390 000000100000000000000 | grep 'CREATE\|INSERT+INIT\|COMMIT'
                                                42/ 42, tx:
59/ 59, tx:
421/ 421, tx:
                                                                                  0, lsn: 0/100A3790, prev 0/100A8F88, desc: CREATE base/24896/24897
659, lsn: 0/100B6728, prev 0/100B66F8, desc: INSERT+INIT off 1 flags 0x00, blkref #0: rel 1663/24896/24897 blk 0
659, lsn: 0/100CF00, prev 0/100CF80, desc: INSERT+INIT off 1 flags 0x00, blkref #0: rel 1663/24896/24897 blk 1
659, lsn: 0/100CS90, prev 0/100CS300, desc: INSERT+INIT off 1 flags 0x00, blkref #0: rel 1663/24896/24897 blk 2
659, lsn: 0/100C9120, prev 0/100C90E0, desc: INSERT+INIT off 1 flags 0x00, blkref #0: rel 1663/24896/24897 blk 3
659, lsn: 0/100CS100, prev 0/100CS000, desc: INSERT+INIT off 1 flags 0x00, blkref #0: rel 1663/24896/24897 blk 3
659, lsn: 0/100CS100, prev 0/100CS100, desc: INSERT+INIT off 1 flags 0x00, blkref #0: rel 1663/24896/24897 blk 4
659, lsn: 0/100CE1E8, prev 0/100CE1A8, desc: COMMIT 2024-01-16 10:54:08.506598 MSK; inval msgs: catcache 75 catcache 74 catca
rmgr: Storage
                         len (rec/tot):
rmgr: Heap
rmgr: Heap
rmgr: Heap
rmgr: Heap
                         len (rec/tot):
len (rec/tot):
                         len (rec/tot):
len (rec/tot):
len (rec/tot):
 rmgr: Heap
rmor: Transaction len (rec/tot):
На уровне replica журнал содержит все изменения данных, что позволяет применить их к физической резервной копии или к реплике.
Установим для журнала уровень minimal (при этом придется также задать нулевое значение параметра max_wal_senders и перезапустить сервер).
=> ALTER SYSTEM SET wal_level = minimal;
ALTER SYSTEM
=> ALTER SYSTEM SET max wal senders = 0;
ALTER SYSTEM
student$ sudo pg_ctlcluster 13 main restart
student$ psql wal_tuning
Посмотрим, как теперь записывается в журнал команда CREATE TABLE AS SELECT.
=> DROP TABLE t_wal;
DROP TABLE
=> SELECT pg current wal insert lsn();
 pg current wal insert lsn
 0/100D4708
(1 row)
=> SELECT pg_walfile_name('0/100D4708');
 pg_walfile_name
  (1 row)
=> CREATE TABLE t_wal(n) AS SELECT 1 from generate_series(1,1000);
 => SELECT pg_current_wal_insert_lsn();
 pg_current_wal_insert_lsn
  0/100ECAB8
(1 row)
Объем журнала уменьшился:
=> SELECT '0/100ECAB8'::pg_lsn - '0/100D4708'::pg_lsn;
```

```
?column?
-----99248
(1 row)
```

В журнале нет записей INSERT+INIT:

postgres\$ /usr/lib/postgresql/13/bin/pg_waldump -p /var/lib/postgresql/13/main/pg_wal -s 0/100D4708 -e 0/100ECAB8 00000010000000000010 | grep 'CREATE\|INSERT+INIT\|COMMIT'

```
rmgr: Storage len (rec/tot): 42/ 42, tx: 0, lsn: 0/100D5E28, prev 0/100D5E08, desc: CREATE base/24896/24900 rmgr: Transaction len (rec/tot): 34/ 34, tx: 661, lsn: 0/100ECA90, prev 0/100E29B0, desc: COMMIT 2024-01-16 10:54:12.101324 MSK
```

Ha ypoвhe minimal операторы CREATE TABLE AS SELECT, TRUNCATE и некоторые другие выполняют синхронизацию, обеспечивая тем самым долговечность. А журнал содержит только записи, необходимые для восстановления после сбоя.

Вернем уровень по умолчанию (replica).

```
=> ALTER SYSTEM RESET wal_level;
```

ALTER SYSTEM

=> ALTER SYSTEM RESET max_wal_senders;

ALTER SYSTEM

student\$ sudo pg_ctlcluster 13 main restart

student\$ psql wal_tuning

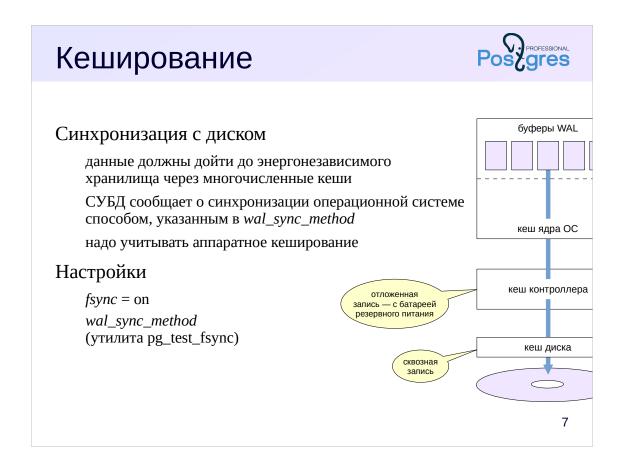
Надежность записи



Кеширование

Повреждение данных

Неатомарность записи страниц



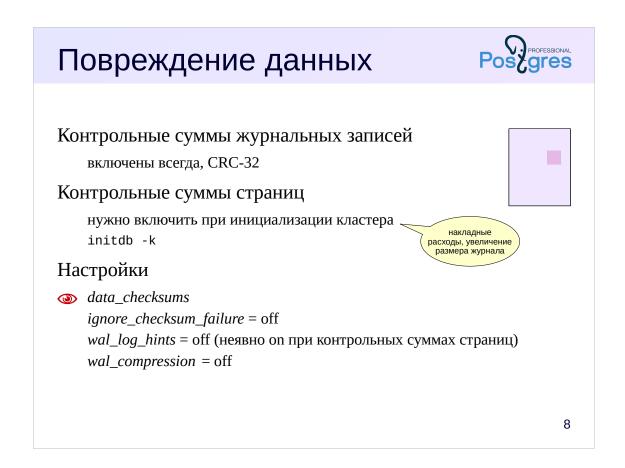
Есть несколько моментов, которые влияют на надежность. Во-первых, всевозможные кеши, находящиеся на пути к энергонезависимому хранилищу (такому как пластина жесткого диска).

Когда PostgreSQL требуется надежно записать данные, он пользуется способом, указанным в параметре wal_sync_method. Вариантов несколько, но основных — два: либо после записи операционной системе дается команда синхронизации (fsync, fdatasync), либо файл открывается или записывается со специальным флагом, который говорит о необходимости синхронизации, а по возможности — прямой записи, минуя кеш ОС. Утилита pg_test_fsync позволяет выбрать способ, наиболее подходящий для конкретной ОС и конкретной файловой системы. Но в любом случае это дорогостоящая операция.

Кроме этого, администратор должен убедиться в том, что данные действительно доходят до диска, а не задерживаются в кеше контроллера или самого диска. Если кеш контроллера откладывает запись, то контроллер в обязательном порядке должен иметь батарею резервного питания. Для дисков лучше устанавливать сквозную запись.

Вообще говоря, синхронизацию можно отменить (параметр fsync), но в этом случае про надежность хранения следует забыть. Единственный разумный вариант отключения этого параметра — временное увеличение производительности в случае, если данные можно легко восстановить (например, при начальной миграции).

https://postgrespro.ru/docs/postgresql/13/wal-reliability



Во-вторых, данные могут быть повреждены на носителе, при передаче данных по интерфейсным кабелям и т. п. Часть таких ошибок обрабатывается на аппаратном уровне, но часть — нет.

Чтобы вовремя обнаружить возникшую проблему, журнальные записи всегда снабжаются контрольными суммами.

Страницы данных также можно защитить контрольными суммами. Это лучше сделать сразу при инициализации кластера, но можно включить и потом, остановив сервер. В производственной среде контрольные суммы должны быть включены обязательно, несмотря на накладные расходы на их вычисление и контроль. Иначе можно получить ситуацию, когда возникший сбой не будет вовремя обнаружен.

Проверить, включены ли контрольные суммы, можно с помощью параметра data_checksums (только для чтения). Параметр ignore_checksum_failure позволяет не прерывать транзакцию, прочитавшую сбойную страницу, но обычно его не следует включать.

При включенных контрольных суммах в журнал всегда попадает такая «несущественная» информация, как биты подсказок (рассмотрены в модуле «Многоверсионность»), поскольку изменение любого бита приводит и к изменению контрольной суммы. При выключенных контрольных суммах за запись битов подсказок в журнал отвечает параметр wal_log_hints.

Изменения битов подсказок всегда журналируется в виде полного образа страницы (FPI, full page image), что сильно увеличивает размер журнала. Для экономии можно включить сжатие полных образов с помощью параметра wal_compression.

Неатомарность записи Образ страницы при сбое страница может быть записана не полностью в журнал записывается образ страницы при первом ее изменении после контрольной точки при восстановлении журнальные записи применяются к записанному образу Настройки full_page_writes = on wal_compression = off

В-третьих, есть проблема атомарности записи.

Страница данных занимает 8 КБ (или больше: 16 КБ, 32 КБ), а на низком уровне запись происходит блоками, которые обычно имеют меньший размер (512 байт, 4 КБ, хотя бывают и другие размеры). Поэтому при сбое питания страница данных может записаться частично.

Понятно, что при восстановлении бессмысленно применять к такой странице обычные журнальные записи.

Для защиты PostgreSQL позволяет записывать в журнал образ всей страницы при первом ее изменении после контрольной точки (такой же образ записывается и при изменении битов подсказок) — этим управляет параметр full_page_writes. Отключать его имеет смысл, только если используемая файловая система и аппаратура сами по себе гарантируют атомарность записи.

Если при восстановлении мы встречаем в журнале образ страницы, мы безусловно записываем его на диск (к нему больше доверия, так как он, как и всякая журнальная запись, защищен контрольной суммой). И уже к нему применяем обычные журнальные записи.

Хотя PostgreSQL исключает из полного образа страницы незанятое место, все же объем журнальных записей увеличивается. Как уже говорилось, размер можно уменьшить за счет сжатия полных образов (параметр wal_compression).

Контрольные суммы

```
Создадим еще одну таблицу:
=> CREATE TABLE t(id integer);
CREATE TABLE
=> INSERT INTO t VALUES (1),(2),(3);
INSERT 0 3
Вот файл, в котором находятся данные:
=> SELECT pg_relation_filepath('t');
pg_relation_filepath
base/24896/24903
(1 row)
Остановим сервер и поменяем несколько байтов в странице (сотрем из заголовка LSN последней журнальной
student$ sudo pg_ctlcluster 13 main stop
postgres$ dd if=/dev/zero of=/var/lib/postgresql/13/main/base/24896/24903 oflag=dsync conv=notrunc bs=1 count=8
8+0 records in
8+0 records out
8 bytes copied, 0,0999988 s, 0,1 kB/s
Можно было бы и не останавливать сервер. Достаточно, чтобы:
   • страница записалась на диск и была вытеснена из кеша;
   • произошло повреждение;
   • страница была прочитана с диска.
Теперь запускаем сервер.
student$ sudo pg_ctlcluster 13 main start
student$ psql wal_tuning
Попробуем прочитать таблицу:
=> SELECT * FROM t;
WARNING: page verification failed, calculated checksum 59790 but expected 36709
ERROR: invalid page in block 0 of relation base/24896/24903
Параметр ignore_checksum_failure позволяет попробовать прочитать таблицу с риском получить искаженные
данные (например, если нет резервной копии):
=> SET ignore_checksum_failure = on;
SET
=> SELECT * FROM t;
WARNING: page verification failed, calculated checksum 59790 but expected 36709
- - - -
 1
 2
 3
(3 rows)
```

Производительность



Характер нагрузки

Синхронная запись

Асинхронная запись

Характер нагрузки



Постоянный поток записи

последовательная запись, отсутствие случайного доступа характер нагрузки отличается от остальной системы при высокой нагрузке — размещение на отдельных физических дисках (символьная ссылка из PGDATA/pg_wal)

Редкое чтение

при восстановлении при работе процессов walsender, если реплика не успевает быстро получать записи

12

При обычной работе происходит постоянная и последовательная запись журнальных файлов. Поскольку отсутствует случайный доступ, с такой нагрузкой отлично справляются и обычные диски HDD.

Но такой характер нагрузки существенно отличается от того, как происходит доступ к файлам данных. Поэтому обычно выгодно размещать журнал на отдельном физическом диске (дисках), примонтированных к ФС сервера; вместо каталога PGDATA/pg_wal нужно создать символьную ссылку на соответствующий каталог.

Однако есть ситуация, при которой журнальные файлы необходимо читать (кроме понятного случая восстановления после сбоя). Она возникает, если используется потоковая репликация и реплика не успевает получать журнальные записи, пока они еще находятся в буферах оперативной памяти основного сервера. Тогда процессу walsender приходится читать нужные данные с диска. Взаимодействие с репликой подробно рассматривается в курсе DBA3 в модуле «Репликация».

Синхронная запись



Алгоритм

при фиксации изменений сбрасывает накопившиеся записи, включая запись о фиксации

ждет commit_delay, если активно не менее commit_siblings транзакций

Свойства

гарантируется долговечность увеличивается время отклика

Настройки

13

Запись журнала происходит в одном из двух режимов: синхронном (когда при фиксации транзакции продолжение работы невозможно до тех пор, пока все журнальные записи о транзакции не окажутся на диске) и асинхронном (когда журнал записывается частями в фоне).

Синхронный режим включается параметром synchronous_commit.

Поскольку синхронизация работает долго, выгодно выполнять ее как можно реже. Для этого процесс, записывающий журнал, делает паузу, определяемую параметром commit_delay, но только в том случае, если имеется не менее commit_siblings активных транзакций — расчет на то, что за время ожидания часть транзакций успеют завершиться и можно будет синхронизировать их записи за один раз.

Затем процесс выполняет сброс журнала на диск до необходимого LSN (или несколько больше, если за время ожидания добавились новые записи).

При синхронной записи гарантируется долговечность — если транзакция зафиксирована, то все ее журнальные записи уже есть на диске и не будут потеряны. Обратная сторона состоит в том, что синхронная запись увеличивает время отклика (команда COMMIT не возвращает управление до окончания синхронизации) и снижает производительность системы.

Асинхронная запись



Алгоритм

циклы записи через wal_writer_delay записывает только целиком заполненные страницы; но если новых полных страниц нет, то записывает последнюю до конца

Свойства

гарантируется согласованность, но не долговечность зафиксированные изменения могут пропасть (3 × wal_writer_delay)

Настройки

synchronous_commit wal_writer_delay = 200ms
wal_writer_flush_after = 1MB

14

При асинхронной записи работает процесс wal writer, сбрасывая накопившиеся журнальные записи либо через wal_writer_delay единиц времени, либо по достижению объема wal_writer_flush_after:

- Если с прошлого раза в буферах была целиком заполнена одна или несколько страниц, сбрасываются только такие, полностью заполненные, страницы (или часть таких страниц; вспомним, что журнальный кеш представляет собой кольцевой буфер записывается только непрерывная последовательность страниц). При большом потоке изменений это позволяет не синхронизировать одну и ту же страницу несколько раз.
- Если же заполненные страницы не появились, записывается текущая (не до конца заполненная) страница журнала.

Асинхронная запись эффективнее синхронной — фиксация изменений не ждет записи. Однако надежность уменьшается: зафиксированные данные могут пропасть в случае сбоя, если между фиксацией и сбоем прошло менее 3 × wal_writer_delay единиц времени.

Параметр *synchronous_commit* можно устанавливать в рамках транзакций. Это позволяет увеличивать производительность, жертвуя надежностью только части транзакций.

https://postgrespro.ru/docs/postgrespro/13/wal-async-commit

В реальности оба режима работают совместно. Журнальные записи долгой транзакции будут записываться асинхронно (чтобы освободить буферы WAL). А если при сбросе грязного буфера окажется, что соответствующая журнальная запись еще не на диске, она тут же будет сброшена в синхронном режиме.

Влияние синхронной фиксации на производительность

```
Режим, включенный по умолчанию, — синхронная фиксация.
=> SHOW synchronous commit;
 synchronous_commit
(1 row)
Запустим простой тест производительности с помощью утилиты pgbench. Для этого сначала инициализируем необходимые
student$ pgbench -i wal_tuning
dropping old tables...
NOTICE: table "pgbench_accounts" does not exist, skipping
NOTICE: table "pgbench_branches" does not exist, skipping
NOTICE: table "pgbench history" does not exist, skipping
NOTICE: table "pgbench tellers" does not exist, skipping
creating tables..
generating data (client-side)...
100000 of 100000 tuples (100%) done (elapsed 0.10 s, remaining 0.00 s)
creating primary keys...
done in 0.74 s (drop tables 0.00 s, create tables 0.06 s, client-side generate 0.24 s, vacuum 0.16 s, primary keys 0.27 s).
Запускаем тест на 10 секунд.
student$ pgbench -P 1 -T 10 wal_tuning
starting vacuum...end.
progress: 1.0 \text{ s}, 70.0 \text{ tps}, lat 14.097 \text{ ms} stddev 7.100
progress: 2.0 s, 107.0 tps, lat 9.283 ms stddev 5.062
progress: 3.0 s, 128.0 tps, lat 7.830 ms stddev 1.491
progress: 4.0 s, 129.0 tps, lat 7.759 ms stddev 1.227
progress: 5.0 s, 120.0 tps, lat 8.335 ms stddev 2.635
progress: 6.0 s, 119.0 tps, lat 8.410 ms stddev 1.827
progress: 7.0 s, 132.0 tps, lat 7.551 ms stddev 1.387
progress: 8.0 s, 112.0 tps, lat 8.950 ms stddev 1.376
progress: 9.0 s, 110.0 tps, lat 9.032 ms stddev 1.356
progress: 10.0 s, 110.0 tps, lat 9.081 ms stddev 0.985
transaction type: <builtin: TPC-B (sort of)>
scaling factor: 1
query mode: simple
number of clients: 1
number of threads: 1
duration: 10 s
number of transactions actually processed: 1138
latency average = 8.774 ms
latency stddev = 3.147 ms
tps = 113.787182 (including connections establishing)
tps = 113.938698 (excluding connections establishing)
В результатах нас интересует число транзакций или скорость (tps).
Теперь установим асинхронный режим.
=> ALTER SYSTEM SET synchronous_commit = off;
ALTER SYSTEM
=> SELECT pg reload conf();
pg_reload_conf
t
(1 row)
Снова запускаем тест.
student$ pgbench -P 1 -T 10 wal_tuning
starting vacuum...end.
progress: 1.0 s, 2348.9 tps, lat 0.424 ms stddev 0.191
progress: 2.0 s, 2477.1 tps, lat 0.403 ms stddev 0.311
progress: 3.0 s, 2506.9 tps, lat 0.399 ms stddev 0.144 progress: 4.0 s, 2511.0 tps, lat 0.398 ms stddev 0.134
progress: 5.0 s, 2358.1 tps, lat 0.424 ms stddev 0.177
progress: 6.0 s, 2482.0 tps, lat 0.403 ms stddev 0.118
progress: 7.0 s, 1902.0 tps, lat 0.525 ms stddev 0.256
progress: 8.0 s, 2313.9 tps, lat 0.432 ms stddev 0.215 progress: 9.0 s, 2046.0 tps, lat 0.488 ms stddev 0.218
```

```
progress: 10.0 s, 1675.0 tps, lat 0.596 ms stddev 0.340
transaction type: <builtin: TPC-B (sort of)>
scaling factor: 1
query mode: simple
number of clients: 1
number of threads: 1
duration: 10 s
number of transactions actually processed: 22636
latency average = 0.442 ms
latency stddev = 0.224 ms
tps = 2260.424384 (including connections establishing)
tps = 2261.425336 (excluding connections establishing)
```

Разумеется, на реальной системе соотношение может быть другим, но видно, что в асинхронном режиме производительность существенно выше.

Итоги



Журнал позволяет восстановить согласованность после сбоев, но может использоваться и для других задач

Надежность записи требует настройки не только СУБД, но и на уровне ОС, ФС и аппаратуры

Настройка позволяет достичь баланса между долговечностью и производительностью

Практика



- 1. Изучите, как влияет на размер журнальных записей значение параметра *full_page_writes*.
 - Для этого повторите простой тест pgbench, показанный в демонстрации, с разными настройками журнала. Перед запуском каждого теста выполняйте контрольную точку. Объясните полученный результат.
- 2. Во сколько раз уменьшается размер журнальных записей при включении параметра *wal_compression*?

17

1. Обратите внимание на значение параметра data_checksums.

Для детального анализа может пригодиться утилита pg_waldump с ключом --stats, показывающим статистическую информацию о составе журнальных записей.

```
1a. Full page writes = on
=> CREATE DATABASE wal_tuning;
CREATE DATABASE
student$ pgbench -i wal_tuning
dropping old tables...
NOTICE: table "pgbench_accounts" does not exist, skipping
NOTICE: table "pgbench branches" does not exist, skipping
NOTICE: table "pgbench history" does not exist, skipping
NOTICE: table "pgbench_tables" does not exist, skipping
NOTICE: table "pgbench_tellers" does not exist, skipping
creating tables...
generating data (client-side)...
100000 of 100000 tuples (100%) done (elapsed 0.10 s, remaining 0.00 s)
vacuuming...
creating primary keys...
done in 0.35 s (drop tables 0.00 s, create tables 0.02 s, client-side generate 0.14 s, vacuum 0.08 s, primary keys 0.11 s).
=> SHOW full_page_writes;
 full_page_writes
on
(1 row)
=> CHECKPOINT:
CHECKPOINT
Запускаем тест на 30 секунд.
=> SELECT pg_current_wal_insert_lsn();
 pg_current_wal_insert_lsn
 0/429092C0
student$ pgbench -T 30 wal_tuning
starting vacuum...end.
transaction type: <br/>
scaling factor: 1<br/>
query mode: simple<br/>
number of clients: 1<br/>
number of threads: 1<br/>
duration: 30 s<br/>
number of transactions actually processed: 4162<br/>
latency average = 7.209 ms<br/>
tps = 138.711351 (including connections establishing)<br/>
tps = 138.728464 (excluding connections establishing)
starting vacuum...end.
=> SELECT pg current wal insert lsn():
 pg current wal insert lsn
 0/438D0EF8
Размер журнальных записей:
=> SELECT pg_size_pretty('0/438D0EF8'::pg_lsn - '0/429092C0'::pg_lsn);
 pg_size_pretty
  16 MB
(1 row)
Основной объем журнала составляют полные образы страниц (FPI):
=> SELECT pg walfile name('0/429092C0'), pg walfile name('0/438D0EF8');
       pg walfile name
                         name | pg_walfile_name
  0000001000000000000042 | 00000010000000000000043
Туре
                                                                  N (%)
                                                                                                 Record size (%)
                                                                                                                                                 FPI size
                                                                                                                                                                  (%)
                                                                                                                                                                                      Combined size
                                                                    24 ( 0,08)
                                                                                                                       0,06)
XLOG/FPI FOR HINT
                                                                                                            1176 (
                                                                                                                                                     184912 ( 1,29)
                                                                                                                                                                                                 186088 (
                                                                                                                                                                                                               1,13)
                                                                                                        1176 ( 0,06)
142238 ( 6,72)
42 ( 0,00)
42 ( 0,00)
104 ( 0,00)
408 ( 0,02)
251968 ( 11,91)
                                                                                                                                                         0 ( 0,00)
0 ( 0,00)
0 ( 0,00)
0 ( 0,00)
 Transaction/COMMIT
                                                                4167 ( 13.86)
                                                                                                                                                                                                 142238 (
                                                                                                                                                                                                                0.87)
Storage/CREATE
Standby/LOCK
Standby/RUNNING_XACTS
                                                                     1 ( 0,00)
1 ( 0,00)
2 ( 0,01)
                                                                                                                                                                                                     42 (
42 (
104 (
                                                                                                                                                                                                               0,00)
0,00)
0,00)
 Standby/INVALIDATIONS
Heap2/CLEAN
                                                                4 ( 0,01)
4136 ( 13,75)
                                                                                                                                                           Θ (
Θ (
                                                                                                                                                                   0.00)
                                                                                                                                                                                                      408 (
                                                                                                                                                                                                                0.00)
                                                                                                                                                                                                 251968 (
                                                                                                                                                                    0.00)
                                                                                                                                                                                                                1.53)
 Heap2/CLEANUP_INFO
Heap2/VISIBLE
                                                                                                         42 ( 0,00)
67270 ( 3,18)
330537 ( 15,62)
                                                                1 ( 0,00)
1140 ( 3,79)
4141 ( 13,77)
                                                                           0,00)
                                                                                                                                                      0 (
16384 (
                                                                                                                                                                    0,00)
0,11)
                                                                                                                                                                                                  42 (
83654 (
                                                                                                                                                       0 ( 0,00)
2928 ( 0,02)
604 ( 0,00)
 Heap/INSERT
                                                                                                                                                                                                 330537 (
                                                                                                                                                                                                                2,01)
 Heap/UPDATE
                                                               1800 ( 5,99)
10677 ( 35,50)
                                                                                                         308040 ( 14.56)
                                                                                                                                                                                                 310968 (
                                                                                                                                                                                                               1.89)
                                                                                                         770978 ( 36.43)
 Heap/HOT UPDATE
                                                                                                                                                                                                 771582 (
                                                                                                                                                                                                               4.70)
Heap/INPLACE
Heap/INSERT+INIT
                                                                1819 ( 6,05)

8 ( 0,03)

27 ( 0,09)

21 ( 0,07)
                                                                                                         105706 ( 4,99)
1668 ( 0,08)
2133 ( 0,10)
4034 ( 0,19)
                                                                                                                                                  12081696 ( 84,38)
0 ( 0,00)
0 ( 0,00)
0 ( 0,00)
                                                                                                                                                                                              12187402 ( 74,16)
1668 ( 0,01)
2133 ( 0,01)
4034 ( 0,02)
 Heap/UPDATE+INIT
 Btree/INSERT_LEAF
Btree/VACUUM
                                                                1829 (
                                                                            6.08)
                                                                                                         113998 ( 5,39)
15950 ( 0,75)
                                                                                                                                                   2030828 ( 14,18) 0 ( 0,00)
                                                                                                                                                                                               2144826 ( 13,05)
15950 ( 0,10)
                                                                  274 (
                                                                           0,91)
                                                                                                       2116334 [12,88%]
                                                                                                                                                  14317352 [87,12%]
                                                                                                                                                                                              16433686 [100%]
Обратите внимание на общий размер (строка Total) полных образов (столбец FPI size).
1b. Full page writes = off
=> ALTER SYSTEM SET full_page_writes = off;
ALTER SYSTEM
 => SELECT pg_reload_conf();
 pg_reload_conf
```

(1 row)
=> CHECKPOINT;
CHECKPOINT

```
Запускаем тест на 30 секунд.
=> SELECT pg_current_wal_insert_lsn();
 pg_current_wal_insert_lsn
0/438D0FC8
(1 row)
student$ papench -T 30 wal tuning
starting vacuum...end.
transaction type: <builtin: TPC-B (sort of)>
scaling factor: 1
query mode: simple
number of clients: 1
number of threads: 1
duration: 30 s
number of transactions actually processed: 3976
hamber of transactions actuatry processed: 3976 latency average = 7.547 ms
tps = 132.504925 (including connections establishing)
tps = 132.516166 (excluding connections establishing)
=> SELECT pg_current_wal_insert_lsn();
 pg_current_wal_insert_lsn
 0/44334498
Размер журнальных записей:
=> SELECT pg_size_pretty('0/44334498'::pg_lsn - '0/438D0FC8'::pg_lsn);
 pq size pretty
 10 MB
(1 row)
Размер уменьшился, но не так существенно, как можно было бы ожидать
Причина в том, что кластер инициализирован с контрольными суммами в страницах данных:
=> SHOW data_checksums;
 data_checksums
on
(1 row)
При этом, несмотря на то что full_page_writes выключен, в журнал все равно записываются полные образы страниц при изменении битов подсказок. Эти данные и составляют большую часть всего объема:
=> SELECT pg_walfile_name('0/438D0FC8'), pg_walfile_name('0/44334498');
                            | pg_walfile_name
     pg walfile name
 0000001000000000000043 | 0000001000000000000044
(1 row)
Туре
                                                            N (%)
                                                                                        Record size
                                                                                                             (%)
                                                                                                                                   FPI size
                                                                                                                                                    (%)
                                                                                                                                                                     Combined size
                                                                                                                                                                                               (%)
XLOG/FPI_FOR_HINT
Transaction/COMMIT
Storage/CREATE
Standby/LOCK
Standby/RUNNING_XACTS
                                                                                               55321 ( 3,28)
135298 ( 8,03)
42 ( 0,00)
42 ( 0,00)
108 ( 0,01)
180 ( 0,01)
                                                          1129 ( 4,43)
3977 ( 15,61)
1 ( 0,00)
1 ( 0,00)
                                                                                                                                     9111736 (100,00)
                                                                                                                                                                             9167057 ( 84,91)
                                                                                                                                         0 ( 0,00)
0 ( 0,00)
0 ( 0,00)
                                                                                                                                                                                            1,25)
0,00)
0,00)
                                                             2 ( 0,01)
                                                                                                                                              0 ( 0,00)
                                                                                                                                                                                   108 (
180 (
                                                                                                                                                                                            0,00)
Standby/INVALIDATIONS
Heap2/CLEAN
Heap2/VISIBLE
                                                                                                                                                    0.00)
                                                                                                                                                                                            0.00
                                                                                              225200 ( 13,37)
118 ( 0,01)
312050 ( 18,52)
71089 ( 4,22)
                                                                                                                                                                              225200 (
118 (
312050 (
71089 (
                                                         3611 ( 14,17)
2 ( 0,01)
                                                                                                                                                    0,00)
                                                                                                                                                                                            2,09
                                                          2 ( 0,01)
3950 ( 15,50)
Heap/INSERT
                                                                                                                                                   0,00)
                                                                                                                                                                                            2,89)
Heap/UPDATE
                                                           416 (
                                                                    1,63)
                                                                                                                                              0 ( 0,00)
                                                                                                                                                                                            0,66)
                                                        416 ( 1,63)
11506 ( 45,16)
422 ( 1,66)
2 ( 0,01)
26 ( 0,10)
7 ( 0,03)
                                                                                              71089 ( 4,22)
831498 ( 49,36)
22788 ( 1,35)
458 ( 0,03)
2054 ( 0,12)
1197 ( 0,07)
                                                                                                                                                                              71089 ( 0,66)
831498 ( 7,70)
22788 ( 0,21)
458 ( 0,00)
2054 ( 0,02)
1197 ( 0,01)
Heap/HOT_UPDATE
Heap/LOCK
Heap/INPLACE
Heap/INSERT+INIT
                                                                                                                                             0 ( 0,00)
0 ( 0,00)
0 ( 0,00)
0 ( 0,00)
Heap/UPDATE+INIT
                                                                                                                                                    0,00)
Btree/INSERT LEAF
                                                           425 ( 1,67)
                                                                                               27216 ( 1,62)
                                                                                                                                             0 ( 0.00)
                                                                                                                                                                               27216 ( 0 25)
                                                                                              1684659 [15,60%]
                                                                                                                                     9111736 [84,40%]
                                                                                                                                                                            10796395 [100%]
2. Сжатие
=> ALTER SYSTEM SET full_page_writes = on;
ALTER SYSTEM
=> ALTER SYSTEM SET wal_compression = on;
ALTER SYSTEM
=> SELECT pg_reload_conf();
 pg_reload_conf
(1 row)
=> CHECKPOINT:
CHECKPOINT
Запускаем тест на 30 секунд.
=> SELECT pg_current_wal_insert_lsn();
 pg_current_wal_insert_lsn
 0/44334568
student$ pgbench -T 30 wal_tuning
starting vacuum...end.
transaction type: <builtin: TPC-B (sort of)>
scaling factor: 1
scaling lactor: I
query mode: simple
number of clients: 1
number of threads: 1
duration: 30 s
number of transactions actually processed: 4299
```

latency average = 6.979 ms tps = 143.293431 (including connections establishing) tps = 143.307643 (excluding connections establishing)

В данном случае — при наличии большого числа полных образов страниц — размер журнальных записей уменьшился примерно в три раза. Хотя включение сжатия и нагружает процессор, практически наверняка им стоит воспользоваться при включенных контрольных суммах.