

## Авторские права

© Postgres Professional, 2016–2022.

Авторы: Егор Рогов, Павел Лузанов, Илья Баштанов

## Использование материалов курса

Некоммерческое использование материалов курса (презентации, демонстрации) разрешается без ограничений. Коммерческое использование возможно только с письменного разрешения компании Postgres Professional. Запрещается внесение изменений в материалы курса.

## Обратная связь

Отзывы, замечания и предложения направляйте по адресу: edu@postgrespro.ru

### Отказ от ответственности

Компания Postgres Professional не несет никакой ответственности за любые повреждения и убытки, включая потерю дохода, нанесенные прямым или непрямым, специальным или случайным использованием материалов курса. Компания Postgres Professional не предоставляет каких-либо гарантий на материалы курса. Материалы курса предоставляются на основе принципа «как есть» и компания Postgres Professional не обязана предоставлять сопровождение, поддержку, обновления, расширения и изменения.

# Темы



Назначение локализации
Локали и категории
Работа с датами, числами, денежными единицами
Настройка сервера и клиента
Настройка сообщений сервера и клиентских утилит
Правила сортировки

2

# Назначение



## Поддержка кодировок

выбор кодировки символов для различных языков перекодировка символов между клиентом и сервером

## Функционал, зависящий от локализации

сортировка и сравнение символов функции upper, lower, initcap поиск по шаблону функции to\_char с датами, числами, денежными единицами язык сообщений сервера и утилит

3

Возможности локализации в PostgreSQL позволяют хранить текст в различных кодировках. Для русского языка поддерживаются все основные кодировки символов, включая UTF8, WIN1251, KOI8R, ISO 8859 5.

Клиентское приложение может работать в кодировке, отличной от кодировки сервера. В таком случае настраивается преобразование символов между клиентом и сервером.

Кроме поддержки различных кодировок локализация влияет на работу следующего функционала сервера:

- сортировка символов, например в предложениях ORDER BY или в операциях сравнения (>, <);
- преобразование букв в верхний и нижний регистр в функциях upper, lower, initcap;
- поиск по шаблону в регулярных выражениях, операторах LIKE, SIMILAR TO, включая поиск без учета регистра символов;
- форматирование дат, чисел и денежных единиц в функциях to\_char;
- выбор языка сообщений сервера и утилит.

https://postgrespro.ru/docs/postgresgl/13/locale

# Локали и категории



### Локали

определяют язык, территорию и кодировку символов, например ru\_RU.UTF8

установлены в операционной системе

## Категории локали

lc\_ctype классификация символов lc\_collate правила сортировки символов

lc\_messages язык сообщений

lc\_monetary формат денежных единиц

lc\_numeric формат чисел

lc\_time формат даты и времени

4

PostgreSQL использует возможности локализации, предоставляемые операционной системой. Поэтому в ОС следует предварительно настроить локали, которые потребуются для работы СУБД.

Обычно локали в ОС задаются в формате «язык\_территория кодировка». Например, ru\_RU.UTF8 определяет локаль с русским языком (ru), на котором говорят в России (RU), и кодировкой UTF8. В Windows используются развернутые имена: Russian\_Russia.1251.

Язык и территория определяют такие национальные особенности, как порядок символов, формат даты, разделитель десятичных разрядов и т. п.

Иногда бывает необходимо комбинировать поведение некоторых функций из разных локалей. Например, вместе с правилами сортировки русского языка использовать английские сообщения сервера. PostgreSQL поддерживает раздельную установку категорий локали через одноименные параметры конфигурации.

#### Локали и категории

В операционной системе сервера должны быть установлены локали с поддержкой русского языка:

```
student$ locale -a | grep ru
ru_RU.koi8r
ru_RU.utf8
russian
```

Параметры локализации сеанса ОС определяются переменными окружения:

```
student$ locale
```

```
LANG=en_US.UTF-8
LANGUAGE=en_US
LC_CTYPE="en_US.UTF-8"
LC_NUMERIC=ru_RU.UTF-8
LC_TIME=ru_RU.UTF-8
LC_COLLATE="en_US.UTF-8"
LC_MONETARY=ru_RU.UTF-8
LC_PAPER=ru_RU.UTF-8
LC_NAME=ru_RU.UTF-8
LC_ADDRESS=ru_RU.UTF-8
LC_TELEPHONE=ru_RU.UTF-8
LC_TELEPHONE=ru_RU.UTF-8
LC_MEASUREMENT=ru_RU.UTF-8
LC_MEASUREMENT=ru_RU.UTF-8
LC_IDENTIFICATION=ru_RU.UTF-8
LC_JLL=
```

Помимо переменных, соответствующих категориям локали, здесь также присутствуют переменные, имеющие особое значение:

- LC ALL если установлена, то используется для всех категорий локали, даже если они заданы;
- LANG используется для тех категорий локали, для которых значение не задано;
- LANGUAGE если установлена, то используется вместо LC MESSAGES (об этом далее).

При установке PostgreSQL из пакета в виртуальной машине курса для инициализации кластера main были использованы параметры сеанса ОС. Если нужно задать другие значения, можно использовать ключ --locale (эквивалентен LANG), а также ключи для каждой категории, например так:

```
student$ sudo pg createcluster 13 new cluster --locale=ru RU.UTF-8 --lc-messages=en US.UTF-8
```

Шесть параметров PostgreSQL соответствуют одноименным категориям локали. Видно, что их меньше чем в ОС:

```
=> SELECT name, setting, context, sourcefile
FROM pg_settings
WHERE name LIKE 'lc%';
```

name	setting	context	sourcefile
lc_collate lc_ctype lc_messages lc_monetary lc_numeric lc_time (6 rows)	en_US.UTF-8   en_US.UTF-8   en_US.UTF-8   ru_RU.UTF-8   ru_RU.UTF-8   ru_RU.UTF-8	internal   superuser   user   user	     /etc/postgresql/13/main/postgresql.conf   /etc/postgresql/13/main/postgresql.conf   /etc/postgresql/13/main/postgresql.conf   /etc/postgresql/13/main/postgresql.conf

Параметры lc\_ctype и lc\_collate задаются при инициализации кластера и изменить их невозможно. Значения остальных четырех параметров записываются в конфигурационный файл. При этом параметры lc\_monetary, lc numeric и lc time может изменить любой пользователь (context=user), a lc messages — только суперпользователь.

Каждый обслуживающий процесс при запуске сбрасывает значение LC\_ALL и устанавливает переменные окружения ОС для категорий локали в соответствии с конфигурационными параметрами "lc%".

При изменении параметра по ходу сеанса обслуживающий процесс устанавливает это же значение для соответствующей переменной окружения.

Стандартные базы postgres, template0 и template1 используют параметры  $lc_collate$  и  $lc_ctype$  кластера, кодировка баз также определяется этими параметрами.

Новые базы данных по умолчанию копируют параметры используемого шаблона:

```
=> CREATE DATABASE admin_localization_utf8;
```

Name			Collate	Ctype	Access privileges
<pre>admin_localization_utf8 template1</pre>	•		en_US.UTF-8   en_US.UTF-8	en_US.UTF-8	!
(2 rows)	ı	l	ı	ı	, , , , , , , , , , , , , , , , , , , ,

### Даты и LC\_TIME

Параметр конфигурации, отвечающий за соответствующую категорию локали:

```
=> SET lc_time = 'ru_RU.UTF8';
SFT
```

Tuesday, 16 January 2024

(1 row)

Для использования названий месяцев и дней недели на русском языке в форматной маске функции to\_char используется префикс TM:

```
=> SELECT to_char(current_date, 'TMDay, DD TMmonth YYYY');

to_char

Вторник, 16 января 2024
(1 row)

То же самое для американского английского:

=> SET lc_time = 'en_US.UTF8';

SET

=> SELECT to_char(current_date, 'TMDay, DD TMMonth YYYY');

to_char
```

Функции to\_date/to\_char позволяют в явном виде указать формат даты и времени при вводе/выводе значений. На неявное преобразование даты в текст и наоборот влияет параметр datestyle. Вот несколько примеров:

```
=> SET datestyle = 'Postgres'; SELECT current setting('datestyle') AS datestyle, now();
SET
 datestyle |
                             now
Postgres, DMY | Tue 16 Jan 10:57:50.211158 2024 MSK
(1 row)
=> SET datestyle = 'SQL, DMY'; SELECT current_setting('datestyle') AS datestyle, now();
datestyle |
                      now
          +-----
SQL, DMY | 16/01/2024 10:57:50.293018 MSK
=> SET datestyle = 'SQL, MDY'; SELECT current_setting('datestyle') AS datestyle, now();
SET
datestyle |
                      now
SQL, MDY | 01/16/2024 10:57:50.354744 MSK
(1 row)
=> RESET datestyle; SELECT current_setting('datestyle') AS datestyle, now();
RESET
datestyle |
                      now
ISO, DMY | 2024-01-16 10:57:50.418187+03
(1 row)
```

### Числа и LC\_NUMERIC

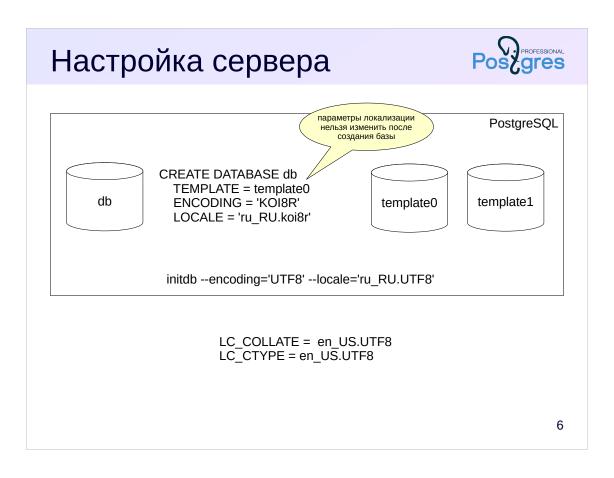
=> SET lc\_monetary = 'en\_US.UTF8';

=> SELECT '12345'::money;

SET

money -----\$12,345.00 (1 row)

```
Параметр конфигурации, отвечающий за соответствующую категорию локали:
=> SET lc_numeric = 'ru_RU.UTF8';
SET
Разделители групп разрядов (G), а также целой и дробной части (D), принятые в России:
=> SELECT to_char('12345'::numeric, '999G999D00');
  to_char
  12 345,00
(1 row)
То же для США:
=> SET lc_numeric = 'en_US.UTF8';
=> SELECT to_char('12345'::numeric, '999G999D00');
  to_char
  12,345.00
(1 row)
Денежные единицы и LC_MONETARY
Параметр конфигурации, отвечающий за соответствующую категорию локали:
=> SET lc_monetary = 'ru_RU.UTF8';
SET
Денежный тип данных MONEY добавляет к сумме код валюты:
=> SELECT '12345'::money;
   money
 12 345,00 ₽
(1 row)
Но нужно учитывать, что в таблице с таким типом можно хранить только одну валюту, и та будет меняться вместе с
LC_MONETARY:
```



Установка локали выполняется при инициализации кластера баз данных. Утилита initdb использует локаль из окружения ОС, либо локаль можно указать явно через соответствующие параметры.

При создании новой базы данных из шаблона template0 можно указать параметры локализации, отличные от тех, что использовались при инициализации кластера баз данных.

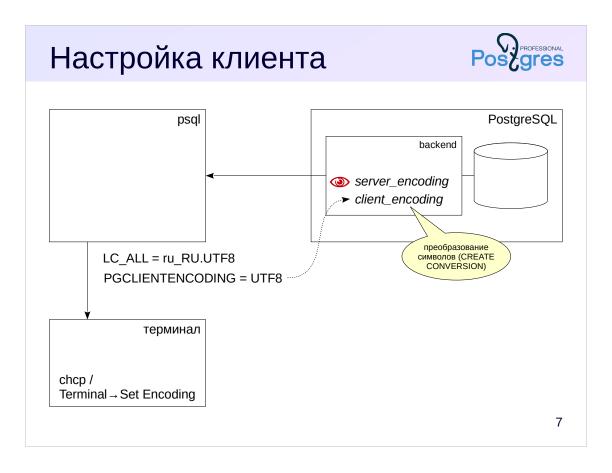
К основным параметрам локализации базы данных относятся: кодировка символов (encoding), а также категории локали lc\_ctype и lc\_collate, которые удобно задавать одним параметром (ключом) locale, потому что их значения обычно совпадают.

На эти категории локали накладываются ограничения:

- кодировки символов у locale (lc\_ctype и lc\_collate) должны совпадать с кодировкой базы данных.
- после создания базы данных locale (lc\_ctype и lc\_collate) изменить нельзя.

Второе ограничение объясняется тем, что изменение правил сортировки и классификации символов может нарушить работу существующих индексов. Кроме того, может измениться поведение операций сравнения текстовых строк в ограничениях СНЕСК и табличных триггерах, что сделает уже сохраненные данные некорректными.

Именно поэтому, если нужно создать базу с отличающимися параметрами локализации, необходимо использовать шаблон template0, в котором гарантированно нет никаких данных.



Для настройки локализации клиентского приложения нужно сделать следующее.

- Проверить, что настройки сервера корректны. Как минимум, что используется правильная кодировка БД (неизменяемый параметр server\_encoding покажет кодировку, заданную при создании БД).
- Проверить, что в клиентской ОС установлены нужные локали, и настроить категории локали (переменные среды LC\_\*) в сеансе ОС.
- Настроить кодировку, с которой работает приложение, и проверить настройки устройства вывода. Например, psql в Windows обычно использует кодировку Win-1251, поэтому в терминале (cmd.exe) необходимо выполнить команду chcp 1251 и установить шрифт true type (например, Lucida Console).
- После подключения к БД проверить параметр *client\_encoding*. Этот параметр отвечает за перекодировку символов между клиентом и сервером. При необходимости установить в значение кодировки приложения. Значение *client\_encoding* можно задать и в переменной среды PGCLIENTENCODING.

Обслуживающий процесс автоматически перекодирует символы из кодировки БД (server\_encoding) в кодировку клиента (client\_encoding). Для большинства кодировок в PostgreSQL преднастроены необходимые процедуры преобразования символов: они находятся в таблице системного каталога pg\_conversion. Возможно создание дополнительных пользовательских процедур (CREATE CONVERSION).

#### Работа клиента и сервера в разных кодировках

Создадим базу данных с кодировкой KOI8R, а клиент по-прежнему будет использовать UTF8. Чтобы база данных успешно создалась, нужно учесть следующее:

- в ОС должна быть установлена локаль с нужной кодировкой символов;
- нужно использовать шаблон template0: это пустая БД, индексы в которой гарантированно не пострадают в результате изменения кодировки.

Значения LC\_COLLATE и LC\_CTYPE, как правило, должны быть согласованы, поэтому обычно их устанавливают вместе одним параметром LOCALE:

Кодировки клиента и сервера:

```
=> SELECT name, setting, context
FROM pg_settings
WHERE name LIKE '%encoding';

name | setting | context

client_encoding | KOI8R | user
server_encoding | KOI8R | internal
(2 rows)
```

Значение параметра client\_encoding устанавливает клиент, в данном случае psql. В интерактивном режиме значение устанавливается по кодировке клиента (переменной LC\_CTYPE в OC). Но при запуске из скрипта, как сейчас в демонстрации, параметр устанавливается в значение кодировки базы данных.

Явно зададим такое же значение, как и у клиентской локали:

```
=> \! locale | grep LC_CTYPE

LC_CTYPE="en_US.UTF-8"

=> SET client_encoding = 'UTF-8';

SET

Теперь символы будут правильно конвертироваться из UTF8 в KOI8R и обратно:

=> CREATE TABLE tab AS SELECT 'Привет, мир!'::text AS col;

SELECT 1

=> SELECT * FROM tab;

col

Привет, мир!
(1 row)
```

Список доступных перекодировок для коі8:

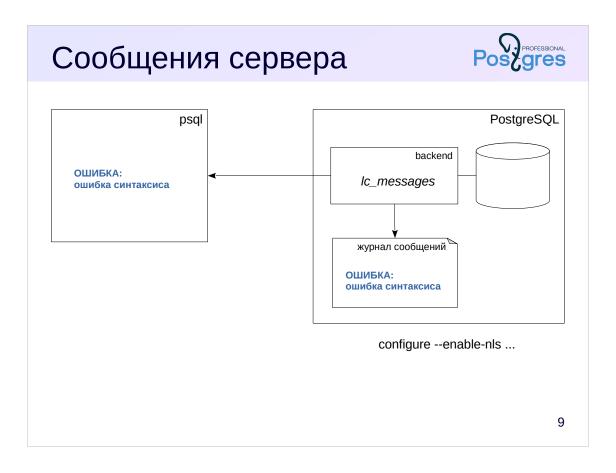
```
=> \dcS *koi8*
```

### List of conversions

Schema	Name	Source	Destination	Default?
pg_catalog   pg_catalog	koi8_r_to_utf8 koi8_r_to_windows_1251   koi8_r_to_windows_866   koi8_u_to_utf8 mic_to_koi8_r utf8_to_koi8_r utf8_to_koi8_u	ISO_8859_5 KOI8R KOI8R KOI8R KOI8R KOI8R KOI8R KOI8U MULE_INTERNAL UTF8 UTF8 WIN1251 WIN866	K018R ISO_8859_5 MULE_INTERNAL UTF8 WIN1251 WIN866 UTF8 K018R K018R K018R K018R K018R K018R K018R	yes

### => \c admin\_localization\_utf8

You are now connected to database "admin\_localization\_utf8" as user "student".



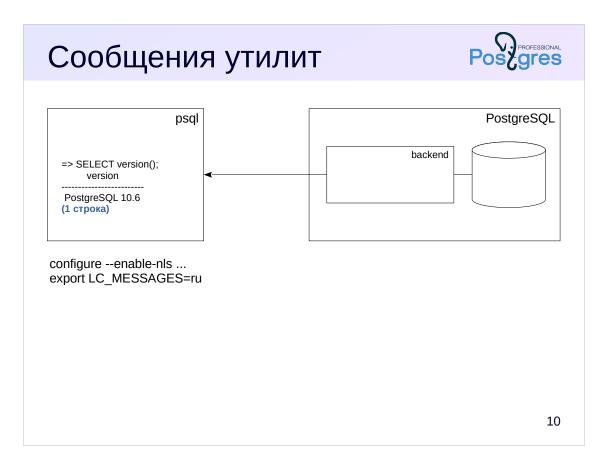
Сообщения сервера (и утилит) PostgreSQL переведены на несколько языков. В том числе и на русский.

Для того чтобы сообщения сервера выводились на русском языке, нужно, чтобы сервер PostgreSQL был собран с поддержкой национальных языков (configure --enable-nls).

Параметр конфигурации *lc\_messages* управляет языком сообщений сервера.

Сообщения сервера не только отправляются клиенту, но и записываются в журнал сервера. При выборе языка, отличного от английского, следует убедиться, что инструменты работы с журналом сервера понимают этот язык. Например pgBadger может работать только с английскими сообщениями.

Подробнее о переводе сообщений сервера для переводчиков и разработчиков: <a href="https://postgrespro.ru/docs/postgresql/13/nls">https://postgrespro.ru/docs/postgresql/13/nls</a>



Утилиты PostgreSQL (psql, pg\_dump и пр.) также поддерживают национальные языки.

Для того, чтобы сообщения утилит выводились на языке, отличном от английского, нужно, чтобы клиент PostgreSQL был собран с поддержкой NLS. Язык вывода устанавливается на клиенте переменной среды LC\_MESSAGES (параметр сервера *lc\_messages* влияет только на сообщения самого сервера, но не клиента).

Большинство ОС (включая Windows) используют следующий порядок просмотра переменных среды для языка сообщений: LANGUAGE, LC\_ALL, LC\_MESSAGES, LANG.

#### Сообщения сервера и клиента

```
Сообщения сервера можно выводить на разных языках. Предварительно нужно убедиться, что PostgreSQL собран с поддержкой национальных
=> SELECT unnest(regexp_match(setting,'--enable-nls')) config
FROM pg_config()
WHERE name = 'CONFIGURE';
    config
 --enable-nls
(1 row)
Список доступных языков и файлы сообщений здесь:
=> SELECT setting
FROM pg_config()
WHERE name = 'LOCALEDIR';
      setting
 /usr/share/locale
(1 row)
postgres$ ls -C /usr/share/locale
aa
           ca@valencia fa_IR is
                                               mhr
                                                       pl
                                                                 ti
ab
           ce
                         ff
                                it
                                               шi
                                                       pms
                                                                 tiq
                         fi
                                it CARES
           ch
ace
                                                       ps
                                                                 tk
                                               miw
                         fil
                                                                 tl
ach
           chr
                                               mk
                                                       pt
                                iu
                                                       pt_BR
af
           ckb
                         fo
                                jа
                                               ml
                                                                 tr
ak
           СО
                                jam
                                                       ro
                                                                 trv
am
           crh
                         fr_CA
                                įν
                                               mnw
                                                       ru
                                                                 tt
an
           cs
                         frp
                                ka
                                               mo
                                                       rw
                                                                 tt@iqtelif
ar
           csb
                         fur
                                kab
                                               mr
                                                       sa
                                                                 tzm
arn
           CV
                         fy
                                ki
                                               ms
                                                       SC
                                                                 ua
                                                       sd
                                kk
                                               mt
                                                                 uk
ary
           су
                         ga
           da
                         gd
                                kl
                                                       sdh
                                               my
                                                                 ur
as
                                                                 ur PK
ast
           de
                         gez
                                               na
                                                       se
ay
           de_CH
                         gl
                                kmr
                                               nah
                                                       shn
                                                                 117
az
           dν
                         gn
                                kn
                                               nb
                                                       si
                                                                 uz@Latn
                                               nb NO
ba
           dz
                         gu
                                kο
                                                      sk
                                                                 ve
bar
           ee
                         gv
                                kok
                                               nds
                                                       sl
                                                                 vec
           el
                         ha
                                                                 ٧i
be
                                ku
                                               ne
                                                       S0
be@latin
                                               nl
                         haw
                                                       son
           en
                                kν
                                                                 wa
           en_AU
bem
                         he
                                kw
                                               nn
                                                       sq
                                                                 wae
be@tarask
           en@boldquot
                                ky
                                               nso
                                                                 wal
           en_CA
                         hr
                                la
                                               nν
                                                       sr@latin
                                                                 wo
bi
           en_GB
                         ht
                                lb
                                               ny
                                                       sr@Latn
                                                                 xh
bn
           en@quot
                         hu
                                lg
                                               οс
                                                       sv
bn_BD
                                                                 zh CN
           en@shaw
                                                       SW
                         hv
                                ln
                                               om
bn IN
                         hy AM
                                                       szl
                                                                 zh Hans
           eo
                                lo
                                               or
bo
                         hye
                                locale.alias
                                                                 zh_Hant
           es
                                               05
                                                       ta
br
           et
                         ia
                                lt
                                                       ta_LK
                                                                 zh\_HK
                                               pa
bs
           eu
                         id
                                1 v
                                               pam
                                                       te
                                                                 zh_LATN@pinyin
byn
           fa
                         ie
                                mai
                                               pap
                                                       tg
                                                                 zh_TW
           fa_AF
ca
                         io
                                mg
                                               рi
                                                                 zu
Для записи в журнал будем использовать ошибочную команду:
=> select1;
ERROR: syntax error at or near "select1"
LINE 1: select1;
postgres$ tail -n 2 /var/log/postgresql/postgresql-13-main.log
2024-01-16 10:57:54.199 MSK [27659] student@admin_localization_utf8 ERROR: syntax error at or near "select1" at character 1
2024-01-16 10:57:54.199 MSK [27659] student@admin_localization_utf8 STATEMENT: select1;
В журнал сервера записывается такое же сообщение об ошибке и сама ошибочная команда.
Для вывода сообщений на русском языке надо изменить параметр lc\_messages.
=> SET lc_messages T0 'ru_RU.UTF8';
=> select1;
ОШИБКА: ошибка синтаксиса (примерное положение: "select1")
LINE 1: select1;
postgres$ tail -n 2 /var/log/postgresql/postgresql-13-main.log
2024-01-16 10:57:54.319 MSK [27659] student@admin_localization_utf8 ОШИБКА: ошибка синтаксиса (примерное положение: "select1") (символ 1)
2024-01-16\ 10:57:54.319\ MSK\ [27659]\ student@admin\_localization\_utf8\ O\PiEPATOP:\ select1;
Теперь сообщение выводится клиенту и в журнал на русском языке.
```

Посмотрим на сообщения, которые выводит клиент psql. Они остались на английском языке:

```
=> \dt
```

Did not find any relations.

Язык сообщений клиента, собранного с поддержкой национальных языков, определяется переменными ОС LC\_MESSAGES и LANGUAGE, причем LANGUAGE имеет приоритет:

```
=> \! echo $LC_MESSAGES
en_US.UTF8

=> \! echo $LANGUAGE
en_US

Для полной русификации установим русский язык и для сообщений psql.

=> \q
student$ export LANGUAGE=ru_RU
student$ psql -d admin_localization_utf8

=> \dt
Отношения не найдены.

=> SET lc_messages TO 'ru_RU.UTF8';
```

Теперь все сообщения выводятся на русском языке.

# Правила сортировки



## Объекты базы данных

разные правила сортировки в одной БД начальное наполнение при создании БД указываются для столбцов таблиц и в выражениях

## Провайдеры

libc

**ICU** 

Специальные правила сортировки

«С» и «POSIX»

12

Чтобы в одной базе данных можно было по-разному сортировать и сравнивать текстовые данные, в PostgreSQL существуют специальные объекты — правила сортировки (collation). Они позволяют использовать порядок сортировки, отличный от установленного по умолчанию для базы данных.

При создании правила сортировки указываются внешняя библиотека, реализующая сортировку (провайдер), и классификация символов. Начиная с PostgreSQL 10 можно выбирать между библиотеками ICU и libc; до этого всегда использовалась libc.

Начальный список объектов — правил сортировки — формируется при инициализации кластера. Для всех имеющихся в ОС локалей в базу данных загружаются правила сортировки. В дальнейшем при добавлении локалей в ОС можно дозагрузить правила.

Правила сортировки можно использовать при создании текстовых столбцов таблиц, при определении доменов и просто в выражениях, где сортируются или сравниваются текстовые строки.

Специальные правила сортировки «С» и «POSIX» работают одинаково и создаются для всех кодировок сервера. Для этих правил буквами будут считаться только латинские символы от A до Z, все остальные знаки будут сортироваться в соответствии со своими кодами в данной кодировке.

Посмотреть имеющиеся правила сортировки можно в таблице системного каталога pg\_collation.

https://postgrespro.ru/docs/postgresgl/13/collation

# Провайдер libc



## Порядок символов

зависит от реализации в операционной системе

### Изменения в библиотеке

отслеживается номер версии

### Использование

по умолчанию для базы данных или кластера явное указание при определении столбцов и в выражениях

13

Правила сортировки провайдера libc в базе данных работают точно так же, как и в операционной системе. Однако библиотека libc может быть реализована по-разному в разных операционных системах. Как следствие, сортировка для одних и тех же локалей может отличаться в зависимости от ОС сервера базы данных. Если приложение должно поддерживать работу (включая логическую репликацию) СУБД на разных ОС, следует убедиться, что сортировка везде работает корректно.

Более серьезной потенциальной проблемой является установка новой версии библиотеки libc в ОС. Такое может произойти, например, при переходе на новый сервер с новой версией ОС. Изменение в новой версии libc используемых в базе данных правил сортировки может привести к некорректной работе индексов и другим проблемам.

# Провайдер ICU



## Порядок символов

зависит от версии библиотеки, но не от операционной системы

### Использование

явное указание при определении столбцов и в выражениях нельзя использовать по умолчанию для базы данных или кластера

## Дополнительные возможности

управление порядком сортировки групп символов

14

Для использования провайдера ICU в определении правил сортировки необходимо, чтобы PostgreSQL был собран с поддержкой этой библиотеки. Библиотека ICU и реализованные в ней правила сортировки работают одинаково на всех операционных системах.

Библиотека ICU допускает видоизменение правил сортировки без смены языка и территории. Можно указать разный порядок сортировки для отдельных групп символов. Например, символы какой группы должны идти раньше: кириллица, латиница или цифры; буквы в верхнем регистре или в нижнем.

## https://icu.unicode.org/

При инициализации кластера баз данных или при создании новой БД можно указать только локали библиотеки libc. Использовать в таком качестве библиотеку ICU можно, начиная с версии PostgreSQL 15.

### Правила сортировки

При инициализации кластера в системном каталоге каждой базы данных создаются специальные объекты — правила сортировки. Они создаются на основе информации об установленных в ОС локалях.

Начальное наполнение базы правилами сортировки:

```
=> SELECT CASE collprovider
   WHEN 'd' THEN 'default'
    WHEN 'c' THEN 'libc'
   WHEN 'i' then 'icu'
  END,
 count(*)
FROM pg_collation
GROUP BY collprovider;
 case | count
       | 787
icu
libc
             45
default |
              1
(3 строки)
```

Правила сортировки для русского языка, полученные из ОС:

```
=> \d0S+ ru*
```

Список правил сортировки						
Схема	Имя	LC_COLLATE	LC_CTYPE	Провайдер	Детерминированное?	Описание
	+	+		+	+	+
pg_catalog	ru-BY-x-icu	ru-BY	ru-BY	icu	да	Russian (Belarus)
pg_catalog	ru-KG-x-icu	ru-KG	ru-KG	icu	да	Russian (Kyrgyzstan)
pg_catalog	ru-KZ-x-icu	ru-KZ	ru-KZ	icu	да	Russian (Kazakhstan)
pg_catalog	ru-MD-x-icu	ru-MD	ru-MD	icu	да	Russian (Moldova)
pg_catalog	ru-RU-x-icu	ru-RU	ru-RU	icu	да	Russian (Russia)
pg_catalog	ru-UA-x-icu	ru-UA	ru-UA	icu	да	Russian (Ukraine)
pg_catalog	ru-x-icu	ru	ru	icu	да	Russian
pg_catalog	ru_RU	ru_RU.utf8	ru_RU.utf8	libc	да	1
pg catalog	ru RU.utf8	ru_RU.utf8	ru RU.utf8	libc	да	1
(9 строк)						

Правила сортировки для провайдера ICU создаются только в том случае, если сервер собран с параметром --with-

------

#### Правила сортировки ICU

Сортировка для правила ru-x-icu отличается от используемой по умолчанию сортировки для правила ru\_RU. Кириллица идет раньше латиницы:

Ключевое слово COLLATE после выражения (в ORDER BY) явно задает правило сортировки. По умолчанию используется правило с именем default, соответствующее параметрам локали базы данных.

.....

Возможности библиотеки ICU позволяют по-разному настраивать сортировку отдельных групп символов.

Создадим новое правило сортировки, где латинские символы идут раньше символов кириллицы:

```
=> CREATE COLLATION latn_cyrl
   (provider = icu, locale = 'ru-RU-u-kr-latn-cyrl');
CREATE COLLATION
Еще одно, где в дополнение к предыдущему буквы идут раньше цифр:
=> CREATE COLLATION latn cyrl digit
   (provider = icu, locale = 'ru-RU-u-kr-latn-cyrl-digit');
CREATE COLLATION
Проверяем сортировку:
=> WITH t(c) AS (
 VALUES('a'),('6'),('B'),('a'),('b'),('c'),('1'),('2'),('3')
FROM t \gx
-[ RECORD 1 ]---+----
default
             | 1,2,3,a,b,c,a,б,в
             .
| 1,2,3,a,б,в,а,b,с
ru-x-icu
          | 1,2,3,a,b,c,a,б,в
latn cyrl
latn_cyrl_digit | a,b,c,a,6,B,1,2,3
```

# Детерминизм



## Детерминированные правила сортировки

равенство строк при побайтовом совпадении

## Недетерминированные правила сортировки

строки, состоящие из разных байтов, могут быть равными дополнительная гибкость производительность ниже не поддерживают LIKE и другие операции

16

Правило сортировки в зависимости от типа используемого сравнения может быть детерминированным или недетерминированным.

Детерминированные сравнения считают равными строки, состоящие из одних и тех же байтов. При недетерминированном сравнении даже не совпадающие побайтово строки могут считаться равными. Например, в Unicode буква «ё» может быть представлена одним символом Cyrillic Small Letter Io (U+0451), а может быть составлена из буквы «е» (U+0435) и диакритического знака «диерезис» (U+0308).

Все стандартные правила — детерминированные. Пользовательские правила по умолчанию тоже будут детерминированными.

Недетерминированные правила дают дополнительную гибкость: можно, например, задать ограничение уникальности без учета регистра или диакритических символов. Но производительность детерминированных правил обычно выше. К тому же недетерминированные правила не поддерживают некоторые операции, такие как поиск по шаблону.

### Недетерминированные правила сортировки

Определим недетерминированное правило для регистронезависимой сортировки:

Но поиск по шаблону для недетерминированного правила невозможен:

```
=> SELECT 'PostgreSQL' LIKE 'post%' COLLATE "ignore_case";
```

ОШИБКА: недетерминированные правила сортировки не поддерживаются для LIKE

# Отслеживание изменений



## Изменение библиотеки-провайдера приводит к проблемам

неправильная сортировка значений в индексах сравнения строк в ограничениях целостности сравнения строк в запросах и т. д.

Номер версии библиотеки хранится в системном каталоге При изменении установленной версии — предупреждение libc не гарантирует стабильность и платформонезависимость версии

18

Если при изменении библиотеки-провайдера сравнение начинает работать иначе, это может повлиять на используемые в базе данных правила сортировки и вызвать проблемы:

- неправильную работу запросов из-за нарушения сортировки значений в индексах;
- некорректные данные из-за изменившегося поведения при сравнении строк в ограничениях целостности CHECK и триггерах;
- некорректные результаты из-за изменившегося поведения сравнения строк в запросах, процедурном коде и политиках защиты строк.

Поэтому при использовании правил сортировки PostgreSQL будет предупреждать о возможных проблемах, связанных с изменением библиотек.

При создании правила текущий номер версии библиотеки сохраняется в системном каталоге. При каждом использовании правила сохраненный номер версии сверяется с текущим номером, и при обнаружении расхождения запросы будут выдавать предупреждения о несоответствии версий.

Если такая ситуация случилась, следует пересоздать индексы, использующие измененные правила сортировки, а также проверить все места, где используются правила сортировки.

Нужно помнить, что, в отличие от ICU, провайдер libc не гарантирует одинаковую работу сортировки даже при совпадении версий библиотеки.

#### Изменения в библиотеках-провайдерах

При создании правила сортировки в системном каталоге сохраняется версия библиотеки, переданная операционной системой. Если в ОС изменится версия библиотеки, каждый раз при использовании правила будет выдаваться предупреждение о том, что версии не совпадают.

Проверить соответствие версий можно запросом:

```
=> SELECT c.collname,
 c.collversion AS version,
 pg_collation_actual_version(c.oid) AS actual_version
FROM pg_collation c
WHERE c.collname LIKE 'ru%';
 collname | version | actual_version
ru-BY-x-icu | 153.112.40 | 153.112.40
 ru-KG-x-icu | 153.112.40 | 153.112.40
ru-KZ-x-icu | 153.112.40 | 153.112.40
ru-MD-x-icu | 153.112.40 | 153.112.40
ru-RU-x-icu | 153.112.40 | 153.112.40
ru-UA-x-icu | 153.112.40 | 153.112.40
ru-x-icu
           | 153.112.40 | 153.112.40
ru_RU
           | 2.35
                        | 2.35
           | 2.35
                        | 2.35
ru RU
ru RU.koi8r | 2.35
                        | 2.35
ru RU.utf8 | 2.35
                         | 2.35
russian
           | 2.35
                        | 2.35
(12 строк)
```

Изменение правила сортировки может привести к некорректной работе индексов. Если подобное произошло, рекомендуется пересоздать индексы с новой версией правила сортировки. После этого можно обновить версию в системном каталоге командой ALTER COLLATION ... REFRESH VERSION и предупреждения перестанут выдаваться.

Запрос для получения списка объектов, которые зависят от требующих обновления правил сортировки:

# Итоги



Перед инициализацией кластера нужные для СУБД локали должны быть установлены в ОС

Клиент и сервер могут работать в различных кодировках с автоматическим преобразованием символов

Сообщения сервера и утилит переведены на множество языков, включая русский

Правила сортировки используют внешние библиотеки, изменения в которых могут привести к повреждению данных и некорректным результатам

20

# Практика



1. Перенос данных между базами в разных кодировках.

Создайте базу данных с кодировкой KOI8R.

Создайте таблицу и добавьте в нее строки, содержащие символы кириллицы.

Сделайте копию базы данных утилитой pg\_dump.

Восстановите таблицу из копии в базу с кодировкой UTF8.

2. Получите номер сегодняшнего дня недели.

Меняется ли номер дня недели в зависимости от настроек локализации?

21

- 1. Для создания БД в кодировке KOI8R:
- убедитесь, что в ОС установлена нужная локаль;
- в команде CREATE DATABASE используйте шаблон template0 параметры ENCODING и LOCALE.
- 2. Для получения номера дня недели используйте функцию to\_char.

Допустимые форматные маски даты:

https://postgrespro.ru/docs/postgresql/13/functions-formatting#FUNCTIONS -FORMATTING-DATETIME-TABLE

### 1. Кодировки базы данных

```
Проверим, что в ОС есть локали с кодировкой коі8:
=> \! locale -a | grep koi8
ru RU.koi8r
Создаем базы данных с кодировками KOI8R и UTF8:
=> CREATE DATABASE admin_localization_koi8r
 TEMPLATE template0
 ENCODING 'koi8r'
 LOCALE 'ru RU.koi8r';
CREATE DATABASE
=> CREATE DATABASE admin_localization_utf8;
CREATE DATABASE
=> \l admin_localization_*
                                    List of databases
                      | Owner | Encoding | Collate |
                                                            Ctype | Access privileges
         Name
admin_localization_utf8 | student | UTF8 | en_US.UTF-8 | en_US.UTF-8 |
(2 rows)
Подключаемся к базе с кодировкой KOI8R:
=> \c admin_localization_koi8r
You are now connected to database "admin localization koi8r" as user "student".
=> SET client_encoding = 'UTF8';
SET
Убедимся, что клиент и сервер используют разные кодировки:
=> SELECT name, setting
FROM pg_settings
WHERE name LIKE '%encoding';
              | setting
     name
client encoding | UTF8
server encoding | K0I8R
(2 rows)
Создаем таблицу, содержащую строки с кириллицей:
=> CREATE TABLE tab AS
 SELECT 'Привет, мир!' AS col;
SELECT 1
=> SELECT * FROM tab;
    col
Привет, мир!
(1 row)
=> \q
Получаем логическую копию:
student$ pg_dump -d admin_localization_koi8r -Fc -f koi8r.dump
Содержимое копии выгружается в кодировке базы данных (KOI8R), а в начале файла есть команда установки
параметра client encoding в то же значение KOI8R.
```

Восстанавливаем таблицу в базе данных admin localization utf8:

student\$ pg restore koi8r.dump -d admin localization utf8 -t tab

Благодаря установке client\_encoding при восстановлении символы автоматически перекодируются. Проверим, что кириллица корректно перенесена:

```
student$ psql -d admin_localization_utf8
=> SELECT * FROM tab;

col
......
Привет, мир!
(1 row)
```

### 2. Номер сегодняшнего дня недели

Текущие настройки локализации даты и времени:

Для получения номера дня недели есть две форматные маски:

- ID неделя начинается с понедельника;
- D неделя начинается с воскресенья.

Номер дня недели не зависит от настроек локализации, в частности, от параметра lc time: