

Авторские права

© Postgres Professional, 2018–2022 Авторы: Егор Рогов, Павел Лузанов, Илья Баштанов

Использование материалов курса

Некоммерческое использование материалов курса (презентации, демонстрации) разрешается без ограничений. Коммерческое использование возможно только с письменного разрешения компании Postgres Professional. Запрещается внесение изменений в материалы курса.

Обратная связь

Отзывы, замечания и предложения направляйте по адресу: edu@postgrespro.ru

Отказ от ответственности

Компания Postgres Professional не несет никакой ответственности за любые повреждения и убытки, включая потерю дохода, нанесенные прямым или непрямым, специальным или случайным использованием материалов курса. Компания Postgres Professional не предоставляет каких-либо гарантий на материалы курса. Материалы курса предоставляются на основе принципа «как есть» и компания Postgres Professional не обязана предоставлять сопровождение, поддержку, обновления, расширения и изменения.

Темы



Задачи репликации

Схема работы физической репликации

Способы доставки журнальных записей

Особенности и ограничения использования реплики

Синхронная и асинхронная репликация

Мониторинг репликации

Возможные проблемы и способы их решения

2

Задачи репликации



Репликация

процесс синхронизации нескольких копий кластера баз данных на разных серверах

Базовый механизм для решения ряда задач

отказоустойчивость при возникновении сбоя система

должна сохранить работоспособность

масштабируемость распределение нагрузки между серверами

3

Одиночный сервер, управляющий базами данных, может не удовлетворять требованиям, предъявляемым к системе. Есть две основных задачи, для решения которых требуется наличие нескольких серверов.

Во-первых, отказоустойчивость: один физический сервер — это возможная точка отказа. Если сервер выходит из строя, система становится недоступной.

Во-вторых, производительность. Один сервер может не справляться с нагрузкой. Зачастую желательна возможность не вертикального, а горизонтального масштабирования — распределения нагрузки на несколько серверов. Дело может быть как в стоимости аппаратуры, так и в необходимости различных настроек для разных типов нагрузки (например, для OLTP и отчетности).

В случае PostgreSQL распределенные системы строятся по принципу «shared nothing»: несколько серверов работают независимо друг от друга и не имеют ни общей оперативной памяти, ни общих дисков. Следовательно, если серверы должны работать с одними и теми же данными, то эти данные требуется синхронизировать между ними. Механизм синхронизации и называется репликацией.

Мастер → реплика



Записи WAL передаются на реплику и применяются

поток данных только в одну сторону реплицируется кластер целиком, выборочная репликация невозможна

Реплика — точная копия мастера

одна и та же основная версия сервера полностью совместимые архитектуры и платформы

Реплика доступна только для чтения


4

При физической репликации, рассматриваемой в этой теме, серверы имеют назначенные роли: один является ведущим («мастер») и один или несколько серверов являются ведомыми («реплики»).

Мастер передает на реплику журнальные записи, а реплика применяет эти записи к своим файлам данных. Применение происходит чисто механически, без «понимания смысла» изменений, и выполняется быстрее, чем работало бы повторное выполнение операторов SQL. Но при этом критична двоичная совместимость между серверами — они должны работать на одной и той же программно-аппаратной платформе и на них должны быть запущены одинаковые основные версии PostgreSQL.

Поскольку журнал является общим для всего кластера, то и реплицировать можно только кластер целиком, а не отдельные базы данных или таблицы. Возможность «отфильтровать» журнальные записи отсутствует.

Реплика не может генерировать собственных журнальных записей, она лишь применяет записи мастера. Поэтому при таком подходе реплика может быть доступна только для чтения — никакие операции, изменяющие данные, на реплике не допустимы.



Есть два способа доставки журналов от мастера к реплике. Основной, который используется на практике — потоковая репликация.

В этом случае реплика подключается к мастеру по протоколу репликации и читает поток записей WAL. За счет этого при потоковой репликации отставание реплики от мастера минимально (и при необходимости может быть сведено к нулю).

На реплике за прием журнальных записей отвечает процесс wal receiver. Запустившись, он подключается к мастеру по протоколу репликации, а мастер запускает процесс wal sender, который обслуживает это соединение. Полученные записи пишутся на диск в виде сегментов WAL так же, как это происходит на мастере. Далее они (сразу или с задержкой) применяются к файлам данных. За применение отвечает процесс startup — тот же самый, который обеспечивает восстановление после сбоев, только теперь работает постоянно.

Потоковая репликация может, если нужно, использовать слот репликации.

Настройка потоковой репликации

Поскольку в нашей конфигурации не будет архива журнала предзаписи, важно на всех этапах использовать слот репликации — иначе при определенной задержке мастер может успеть удалить необходимые сегменты и весь процесс придется повторять с самого начала.

```
α=> SELECT pg_create_physical_replication_slot('replica');
 pg_create_physical_replication_slot
(replica,)
(1 row)
Посмотрим на созданный слот:
α=> SELECT * FROM pg_replication_slots \gx
-[ RECORD 1 ]-----
                         | replica
slot_name
plugin
slot_type
datoid
database
                        | physical
temporary
active
active_pid
xmin
xmin
catalog_xmin |
restart_lsn |
confirmed_flush_lsn |
```

Вначале слот не инициализирован (restart Isn и wal status пустые).

Как мы помним из модуля «Резервное копирование», все необходимые настройки есть по умолчанию:

- wal level = replica:

wal_status safe wal size

max_wal_senders;
paзрешение на подключение в pg_hba.conf.

Создадим автономную резервную копию, используя созданный слот. Копию расположим в подготовленном каталоге. С ключом -R утилита создает файлы, необходимые для будущей реплики.

student\$ pg_basebackup --pgdata=/home/student/backup -R --slot=replica

Снова проверим слот:

```
α=> SELECT * FROM pg_replication_slots \gx
```

```
-[ RECORD 1 ]-----+---
                             | replica
plugin
slot_type
datoid
                             physical
database
temporary
active
active_pid
xmin
catalog_xmin
                             0/4000000
restart_lsn
confirmed flush lsn
wal_status
safe_wal_size
                              reserved
```

После выполнения резервной копии слот инициализировался, и мастер теперь хранит все файлы журнала с начала копирования (restart lsn, wal status)

Сравните со строкой в backup label:

```
student$ head -n 1 /home/student/backup/backup label
```

START WAL LOCATION: 0/4000028 (file 00000001000000000000000000)

Файл postgresql.auto.conf был подготовлен утилитой pg_basebackup, поскольку мы указали ключ -R. Он содержит информацию для подключения к мастеру (primary_conninfo) и имя слота репликации (primary slot name):

```
student$ cat /home/student/backup/postgresql.auto.conf
```

Do not edit this file manually!
It will be overwritten by the ALTER SYSTEM command.
primary_conninfo = 'user=student passfile=''/home/student/.pgpass'' channel_binding=prefer host=''/var/run/postgresql'' port=5432 sslmode=prefer sslcompression=0 sslsni=1 ssl_min_proto primary_slot_name = 'replica'

По умолчанию реплика будет «горячей», то есть сможет выполнять запросы во время восстановления. Если такая возможность не нужна, реплику можно сделать «теплой» (hot standby = off).

Утилита также создала сигнальный файл standby.signal, наличие которого указывает серверу войти в режим постоянного восстановления

```
student$ ls -l /home/student/backup/standby.signal
```

```
-rw----- 1 student student 0 янв 16 12:17 /home/student/backup/standby.signal
```

Выкладываем резервную копию в каталог данных сервера beta.

```
student$ sudo pg ctlcluster 13 beta status
```

Error: /var/lib/postgresgl/13/beta is not accessible or does not exist


```
student$ sudo rm -rf /var/lib/postgresql/13/beta
```

student\$ sudo mv /home/student/backup /var/lib/postgresql/13/beta

student\$ sudo chown -R postgres:postgres /var/lib/postgresql/13/beta

Журнальные записи, необходимые для восстановления согласованности, реплика получит от мастера по протоколу репликации. Далее она войдет в режим непрерывного восстановления и продолжит получать и проигрывать поток записей.

student\$ sudo pg_ctlcluster 13 beta start




Другой способ доставки журнальных записей состоит в том, чтобы предоставить реплике доступ к архиву журналов — точно так же, как при обычном восстановлении из архива (этот механизм рассмотрен в модуле «Резервное копирование»).

Если реплика по каким-то причинам не сможет получить очередную журнальную запись по протоколу репликации (например, из-за обрыва связи), она попробует прочитать ее из архива с помощью команды, заданной в параметре restore_command. При восстановлении связи реплика снова автоматически переключится на использование потоковой репликации.

В принципе, репликация может работать и с одним только архивом, без потоковой репликации. Но в этом случае:

- реплика вынужденно отстает от мастера на время заполнения сегмента;
- мастер ничего не знает о существовании реплики, что в некоторых случаях может привести к проблемам.



Если архив используется только для синхронизации одной реплики, можно настроить его автоматическую очистку, для этого в параметре archive_cleanup_command задается команда, которая будет выполняться по окончании каждой точки рестарта подобно тому, как после каждой контрольной точки удаляются файлы журнала. В команде удобно вызывать утилиту рд archivecleanup:

archive_cleanup_command = 'pg_archivecleanup
/path/to/archive %r'

https://postgrespro.ru/docs/postgresql/13/runtime-config-wal#RUNTIME-CONFIG-WAL-ARCHIVE-RECOVERY

https://postgrespro.ru/docs/postgresgl/13/pgarchivecleanup



іроцессы	Postgres
Г астер	Реплика
wal sender	wal receiver startup
archiver	archiver (archive_mode = always)
checkpointer (контрольные точки)	checkpointer (точки рестарта)
writer	writer
stats collector	stats collector
wal writer	
autovacuum	
	9

На мастере и на реплике выполняется разный набор процессов. Кроме уже рассмотренных wal sender (на мастере) и wal receiver и startup (на реплике), работают также другие процессы.

Общие процессы:

- background writer записывает грязные страницы из буферного кеша на диск (на реплике, для того, чтобы применить журнальную запись, страницы точно так же читаются в буферный кеш и затем записываются в фоновом режиме или при вытеснении).
- stats collector статистика не передается в журнале, а собирается на реплике отдельно.
- **checkpointer** на реплике при получении журнальной записи о контрольной точке выполняется похожая процедура — точка рестарта. Если в процессе восстановления случится сбой, реплика сможет продолжить с последней точки рестарта, а не с самого начала.

Процессы только на мастере:

- wal writer реплика не создает журналы упреждающей записи, а только получает их с мастера.
- autovacuum launcher/worker реплика не выполняет очистку, ее выполнение на мастере передается реплике через журнал.

Есть также процесс, наличие которого зависит от настройки:

- archiver — при значении archive mode = on выполняется только на мастере, а при archive_mode = always также и на реплике (подробнее рассматривается в теме «Переключение на реплику»).

Процессы реплики

Посмотрим на процессы реплики.

```
student$ ps -o pid,command --ppid `sudo head -n 1 /var/lib/postgresql/13/beta/postmaster.pid`

PID COMMAND

10435 postgres: 13/beta: startup recovering 000000010000000000000000005

10436 postgres: 13/beta: checkpointer

10437 postgres: 13/beta: background writer

10438 postgres: 13/beta: stats collector

10439 postgres: 13/beta: walreceiver streaming 0/5000060
```

Процесс wal receiver принимает поток журнальных записей, процесс startup применяет изменения.

Процессы wal writer и autovacuum launcher отсутствуют.

И сравним с процессами мастера.

```
student \verb| ps -o pid, command --ppid `sudo head -n 1 /var/lib/postgresql/13/alpha/postmaster.pid `sudo head -n 1 /var/lib/postgresql/13/alpha/postgresql/13/alpha/postgresql/13/alpha/postgresql/13/alpha/postgresql/13/alpha/postgresql/13/alpha/postgresql/13/alpha/postgresql/13/alpha/postgresql/13/alpha/postgresql/13/alpha/postgresql/13/alpha/postgresql/13/alpha/postgresql/13/alpha/postgresql/13/alpha/postgresql/13/alpha/postgresql/13/alpha/postgresql/13/alpha/postgresql/13/alpha/po
```

```
PID COMMAND

9985 postgres: 13/alpha: checkpointer

9986 postgres: 13/alpha: background writer

9987 postgres: 13/alpha: walwriter

9988 postgres: 13/alpha: autovacuum launcher

9989 postgres: 13/alpha: stats collector

9990 postgres: 13/alpha: logical replication launcher

10028 postgres: 13/alpha: student [local] idle

10440 postgres: 13/alpha: walsender student [local] streaming 0/5000060
```

Здесь добавился процесс wal sender, обслуживающий подключение по протоколу репликации.

Использование реплики



Допускаются

запросы на чтение данных (select, сору to, курсоры) установка параметров сервера (set, reset) управление транзакциями (begin, commit, rollback...) создание резервной копии (pg_basebackup)

Не допускаются

любые изменения (insert, update, delete, truncate, nextval...) блокировки, предполагающие изменение (select for update...) команды DDL (create, drop...), в том числе создание временных таблиц команды сопровождения (vacuum, analyze, reindex...) управление доступом (grant, revoke...)

11

Как мы уже говорили, на реплике не допускается любое изменение данных. Более точно, не допускаются:

- изменения таблиц, материализованных представлений, последовательностей;
- блокировки (так как для этого требуется изменение страниц данных);
- команды DDL, включая создание временных таблиц;
- такие команды, как vacuum и analyze;
- команды управления доступом.

При этом реплика может выполнять запросы на чтение данных, если установлен параметр *hot_standby* = on. Также будет работать установка параметров сервера и команды управления транзакциями — например, можно начать (читающую) транзакцию с нужным уровнем изоляции.

Кроме того, реплику можно использовать и для изготовления резервных копий.

Использование реплики

```
Выполним несколько команд на мастере:
α=> CREATE DATABASE replica_physical;
CREATE DATABASE
You are now connected to database "replica_physical" as user "student".
α=> CREATE TABLE test(s text);
CREATE TABLE
α=> INSERT INTO test VALUES ('Πρивет, мир!');
INSERT 0 1
Проверим реплику:
student$ psql -p 5433
β=> \c replica_physical
You are now connected to database "replica physical" as user "student".
β=> SELECT * FROM test;
  Привет, мир!
  (1 row)
При этом изменения на реплике не допускаются:
β=> INSERT INTO test VALUES ('Replica');
| ERROR: cannot execute INSERT in a read-only transaction
Вообще реплику от мастера можно отличить с помощью функции:
β=> SELECT pg_is_in_recovery();
  pg_is_in_recovery
   t
  (1 row)
```

Ограничения



Изоляция и многоверсионность

большое число точек сохранения задерживает выполнение запросов не поддерживается уровень изоляции serializable

Триггеры и блокировки

триггеры и пользовательские блокировки (advisory locks) не работают

Резервное копирование с реплики

параметр *full_page_writes* должен быть заранее включен на мастере задержки из-за ожидания контрольной точки и переключения сегментов

Изменение табличных пространств

каталоги на реплике нужно создавать заранее, так как прав пользователя OC postgres может не хватить

13

У репликации есть ряд ограничений и особенностей.


Если на мастере выполняется транзакция с числом вложенных транзакций > 64 (то есть активно используются точки сохранения), создание снимка на реплике будет приостановлено — это означает невозможность некоторое время выполнять запросы.

Не поддерживается уровень изоляции serializable на реплике.

Триггеры не будут срабатывать на реплике (они выполнились на мастере и реплицируется уже результат их работы). Не будут работать и рекомендательные (advisory) блокировки.

При выполнении резервного копирования с реплики нет технической возможности полноценно управлять мастером, в частности, вызывать контрольные точки и включать параметр *full_page_writes*. Поэтому параметр нужно включить на мастере заранее, а контрольную точку приходится ждать (что может существенно задержать процесс).

Создание табличных пространств реплицируется, но, если у пользователя ОС, под которым работает СУБД, недостаточно прав для создания каталога, произойдет ошибка. Лучше всего сначала создать каталоги на мастере и на всех репликах, а уже затем выполнять команду CREATE TABLESPACE.



В ходе репликации возможны проблемы, о которых должен предупредить заранее настроенный мониторинг. Основной информацией являются позиции в журнале предзаписи. Можно выделить четыре важные точки:

- 1. появление журнальной записи на мастере;
- 2. трансляция записи процессом wal sender;
- 3. получение записи процессом wal receiver;
- 4. применение полученной записи процессом startup.

Все эти точки обычно отслеживаются на мастере. Первую точку дает функция pg_current_wal_lsn(), остальные — представление pg_stat_replication. Реплика передает мастеру статус репликации при каждой записи на диск, но как минимум раз в wal_receiver_status_interval секунд (по умолчанию — 10 секунд).

Если используется слот репликации, то информацию о нем можно получить из представления pg_replication_slots.

Данные о ходе репликации можно получить и на реплике в представлении pg_stat_wal_receiver и с помощью функций pg_last_wal_replay_lsn().

Параметр *log_replication_commands* включает вывод в журнал сообщений информации о выполняющихся командах протокола репликации.

Мониторинг репликации

Состояние репликации можно смотреть в специальном представлении на мастере. Чтобы пользователь получил доступ к этой информации, ему должна быть выдана роль pg read all stats (или он должен быть суперпользователем).

```
\alpha => \backslash du student
```

```
List of roles
                                                    Member of
Role name |
                      Attributes
student | Create role, Create DB, Replication | {pg read all stats}
α=> SELECT * FROM pg_stat_replication \gx
-[ RECORD 1 ]----+-----
pid
               | 10440
usesysid
               | 16384
usename
                | student
application_name | 13/beta
client addr
client hostname |
client port
               | -1
                | 2024-01-16 12:17:17.774325+03
backend_start
backend xmin
state
               | streaming
sent lsn
               | 0/501BFC0
               | 0/501BFC0
write lsn
               | 0/501BFC0
flush lsn
              | 0/501BFC0
replay_lsn
               00:00:00.000123
write lag
flush lag
               | 00:00:00.004935
replay lag
               00:00:00.004976
sync priority
               | 0
sync state
                | async
                | 2024-01-16 12:17:24.807756+03
reply_time
```

Обратите внимание на поля * lsn (и * laq) — они показывают отставание реплики на разных этапах. Сейчас все позиции совпадают, отставание нулевое.

Теперь вставим в таблицу большое количество строк, чтобы увидеть репликацию в процессе работы.

```
α=> INSERT INTO test SELECT 'Just a line' FROM generate series(1,1000000);
INSERT 0 1000000
α=> SELECT *, pg_current_wal_lsn() from pg_stat_replication \gx
-[ RECORD 1 ]-----+
pid
                 | 10440
usesysid
                 | 16384
                 | student
usename
                | 13/beta
application name
client addr
client hostname
                 | -1
client port
                 | 2024-01-16 12:17:17.774325+03
backend start
backend xmin
                 | streaming
state
                 | 0/697A000
sent lsn
write_lsn
                 | 0/691A000
flush lsn
                 | 0/68FA000
replay lsn
                 0/68B9FF8
                 | 00:00:02.241692
write_lag
flush lag
                 | 00:00:02.247271
                 | 00:00:02.258431
replay_lag
sync priority
                 | 0
                 | async
sync_state
```

| 2024-01-16 12:17:27.97807+03

reply time

pg_current_wal_lsn | 0/94F9C90

Видно, что возникла небольшая задержка. Однако не следует рассчитывать на точность выше чем полсекунды, так как статистика обновляется примерно с такой частотой.

Проверим реплику:

```
β=> SELECT count(*) FROM test;

count
......
1000001
(1 row)
```

Все строки успешно доехали.

И еще раз проверим состояние репликации:

Все позиции выровнялись.

Режимы репликации



Асинхронный

synchronous_commit = off local

Синхронный

фиксация с ожиданием подтверждения от синхронной реплики обеспечивает надежность, но не согласованность

synchronous_commit = remote_write

on

remote_apply

synchronous_standby_names = FIRST N (список реплик) ANY N (список реплик)

16

Как известно, фиксация транзакций может выполняться в двух режимах. В более быстром асинхронном режиме есть шанс потерять уже зафиксированные изменения в случае сбоя. В синхронном режиме команда COMMIT не завершается, пока запись не дойдет до диска. При наличии нескольких серверов надежность можно еще более увеличить, дожидаясь подтверждения от реплики о получении записи, тогда данные не пропадут даже при выходе из строя носителя.

Синхронная репликация включается тем же параметром synchronous_commit, что и синхронная фиксация. Разные значения этого параметра позволяют управлять уровнем надежности. При значении remote_write мастер ожидает подтверждения о получении записи (остается шанс потерять изменения, если на реплике случится сбой и она не успеет записать данные на диск).

При значении **on** мастер ожидает подтверждения о попадании журнальной записи на диск реплики (это надежный режим; однако приложение, обратившись к реплике, может не увидеть изменений).

Наконец, значение **remote_apply** заставляет мастер дождаться применения записи на реплике. Каждый следующий режим вызывает все большие задержки.

Мастер может синхронизироваться как с одной, так и с несколькими репликами. Можно указать список реплик в порядке приоритета или организовать синхронизацию на основе *кворума*, при которой мастер дожидается подтверждения от любых *N* реплик из числа доступных.



Мастер может удалить файл журнала, нужный реплике

если реплика не успеет его получить (например, будет остановлена на некоторое время)

Решение 1. Слот репликации

вводит зависимость мастера от реплики, требует мониторинга

Решение 2. Архив журнала предзаписи

позволяет обойтись без слота

17

При репликации возможен ряд сложностей, которые можно решать разными способами.

Cepsep PostgreSQL периодически удаляет файлы журнала, которые не требуются для восстановления. При этом мастер может удалить файл, который содержит данные, еще не переданные реплике.

Это не проблема, если используется архив журналов предзаписи, поскольку реплика, получив отказ по протоколу репликации, прочитает необходимые ей данные из архива, а затем, «догнав» мастер, снова переключится на получение данных из потока.

Но если архива нет, реплика не сможет продолжать восстановление и ее придется пересоздавать из новой резервной копии. Чтобы этого избежать, можно использовать слот репликации. Однако надо понимать, что создание слота ставит мастер в зависимость от реплики: если реплика не будет получать журнальные записи, они будут накапливаться на мастере и свободное пространство рано или поздно закончится. Поэтому слот — еще одна точка, которую необходимо включать в мониторинг.

Влияние слота репликации

```
Остановим реплику
student$ sudo pg_ctlcluster 13 beta stop
Ограничим размер WAL двумя сегментами.
α=> \c - postgres
You are now connected to database "replica_physical" as user "postgres".
α=> ALTER SYSTEM SET min wal size='32MB':
ALTER SYSTEM
α=> ALTER SYSTEM SET max_wal_size='32MB';
ALTER SYSTEM
α=> SELECT pg_reload_conf();
pg_reload_conf
(1 row)
Слот неактивен, но помнит номер последней записи, полученной репликой:
α=> SELECT active, restart lsn, wal status FROM pg replication slots \gx
- [ RECORD 1 1-----
active | f
restart_lsn | 0/94F9C90
wal_status | reserved
Вставим еще строки в таблицу.
α=> INSERT INTO test SELECT 'Just a line' FROM generate_series(1,1000000);
INSERT 0 1000000
Homep LSN в слоте не изменился:
α=> SELECT active, restart_lsn, wal_status FROM pg_replication_slots \gx
-[ RECORD 1 ]-----
active | f
restart_lsn | 0/94F9C90
wal_status | extended
Выполним контрольную точку, которая должна очистить журнал, поскольку его размер превышает допустимый.
α=> CHECKPOINT;
CHECKPOINT
Каков теперь размер журнала?
α=> SELECT pg_size_pretty(sum(size)) FROM pg_ls_waldir();
pg size pretty
 80 MB
(1 row)
Контрольная точка не упалила сегменты — их уперживает слот, несмотря на превышение лимита. Если оставить слот без присмотра, писковое пространство может быть
Скорее всего, бесперебойная работа основного сервера важнее, чем синхронизация реплики. Чтобы предотвратить разрастание журнала, можно ограничить объем,
α=> ALTER SYSTEM SET max_slot_wal_keep_size='16MB';
ALTER SYSTEM
α=> SELECT pg_reload_conf();
pg_reload_conf
(1 row)
α=> CHECKPOINT;
CHECKPOINT
Теперь журнал очищается контрольной точкой:
α=> SELECT pg_size_pretty(sum(size)) FROM pg_ls_waldir();
pg size pretty
 32 MB
(1 row)
Но слот уже не обеспечивает наличие записей WAL (wal status=lost):
\alpha \!\! = \!\! > \!\! SELECT active, restart_lsn, wal_status FROM pg_replication_slots \gx
-[ RECORD 1 ]----
active |
restart_lsn |
wal_status | lost
А реплика не может синхронизироваться:
student$ sudo pg ctlcluster 13 beta start
student$ sudo tail -n 2 /var/log/postgresql/postgresql-13-beta.log
```

Для синхронизации реплики в таких случаях можно воспользоваться архивом, задав параметр restore_command. Если это невозможно, придется заново настроить репликацию, повторив формирование базовой копии.	



Конфликты: записи WAL, несовместимые с запросами на реплике

очистка удаляет версии строк, нужные запросам на реплике исключительные блокировки объектов исключительные блокировки буферов реже: взаимоблокировки, DROP TABLESPACE, DROP DATABASE – запрос сразу отменяется

Мониторинг

pg_stat_database_conflicts

19

Вторая проблема возникает, если реплика используется для выполнения запросов. Мастер может выполнить действие, несовместимое с запросом на реплике:

- очистка может удалить версию строки, которая используется запросом, или потребовать блокировку, несовместимую с запросом;
- может прийти запись об эксклюзивной блокировке объекта (например, при удалении таблицы);

Возникновение таких конфликтов можно отслеживать с помощью представления pg stat database conflicts.

Конфликты с запросами на реплике, вызванные редкими причинами, такими как взаимоблокировки, удаление базы данных или табличного пространства, разрешаются путем немедленной отмены запроса.



Решение 0: избегать конфликтов

не выполнять команды, вызывающие блокировки отменить усечение файла в конце очистки: параметр хранения vacuum_truncate = off

Решение 1: откладывать применение конфликтующих записей

max_standby_streaming_delay
max_standby_archive_delay

20

Один из путей борьбы с конфликтами — избегать действий на мастере, приводящих к исключительным блокировкам. Например, можно не выполнять команды DROP TABLE, TRUNCATE, LOCK, DROP INDEX, DROP TRIGGER и т. п. или выполнять их в то время, когда на реплике заведомо нет выполняющихся запросов.

Некоторых неявных блокировок можно избежать, отключая соответствующую функциональность на мастере. Например, если в результате очистки освободились страницы в конце файла, при уменьшении его размера устанавливается исключительная блокировка таблицы. Но можно отменить усечение файла, задав параметр хранения таблицы vacuum_truncate = off. Однако отменять или надолго откладывать очистку нельзя, поэтому избежать конфликта в случае очистки нужных запросу версий строк таким образом не получится.

Другой способ — откладывать применение полученных несовместимых журнальных записей на реплике. Этот способ работает и при потоковой репликации, и при использовании архива; он откладывает записи, относящие и к очистке, и к эксклюзивным блокировкам. В параметрах устанавливается максимальная задержка применения (от времени получения записи). Если к этому моменту конфликтующий запрос не успеет завершиться, он будет прерван.



Решение 2: обратная связь по протоколу репликации

снимок на реплике предотвращает удаление версий строк так же, как и локальный hot_standby_feedback = on только для конфликта очистки с запросом на реплике

Мониторинг

pg_stat_replication.backend_xmin
pg_replication_slots,xmin

21

Еще один путь решения — откладывать несовместимые действия на мастере. Для этого включается *обратная связь*.

Этот способ работает только для очистки (эксклюзивную блокировку отложить не получится) и только в случае потоковой репликации (если реплика переключается на получение записей из архива, она фактически перестает существовать для мастера).

Каждый снимок данных содержит так называемый горизонт событий — это значение счетчика транзакций, по которому проходит граница между ненужными и нужными версиями строк. Минимальный горизонт по всем снимкам реплики определяет возможность очистки. Подробности обсуждаются в теме «Снимки данных» курса DBA2.

Благодаря обратной связи, мастер понимает, какие версии строк нужны реплике. В таком случае (с точки зрения очистки) запрос на реплике ничем не отличается от запроса на самом мастере.

Обратная связь позволяет мониторить горизонт событий на стороне мастера. Если слот репликации не используется, горизонт виден в поле pg_stat_replication.backend_xmin, а при использовании слота — в pg_replication_slots.xmin. Нужно учитывать, что при включенной обратной связи слот, даже неактивный, будет задерживать очистку, что может привести к увеличению размеров файлов данных. Этот эффект будет исследован в практике.

Итоги



Механизм репликации основан на передаче журнальных записей на реплику и их применении

основной режим: потоковая репликация может быть поддержана архивом журнальных записей

Реплика — точная копия мастера

не генерирует собственные записи WAL, доступна только для чтения

Сложный механизм, требующий настройки и мониторинга настройка существенно зависит от решаемых задач

22

Практика



- 1. Настройте физическую потоковую репликацию между двумя серверами в синхронном режиме, без обратной связи.
- 2. Проверьте работу репликации. Убедитесь, что при остановленной реплике фиксация не завершается.
- 3. Воспроизведите ситуацию, при которой запрос на реплике прерывается из-за очистки версий строк на мастере.
- 4. Запретите откладывать применение конфликтующих изменений; проверьте, что запрос отменяется сразу.
- 5. Включите обратную связь и убедитесь, что очистка на мастере не прерывает выполнение запроса.
- 6. Остановите реплику и убедитесь, что слот препятствует очистке. Удалите слот, чтобы очистка возобновилась.

23

- 1. Для этого на мастере установите параметры:
- synchronous_commit = on,
- synchronous_standby_names = 'beta',
- а на реплике
- cluster_name = beta.
- 3. Для этого на реплике можно начать транзакцию с уровнем изоляции repeatable read и периодически выполнять запросы к таблице, а на мастере изменить эту таблицу и выполнить очистку.

Учтите, что параметр *max_standby_streaming_delay* по умолчанию имеет значение 30 секунд.

- 4. Установите параметр max_standby_streaming_delay в ноль.
- 5. Установите на реплике параметр hot_standby_feedback = on. Максимальный интервал оповещений устанавливается в параметре wal_receiver_status_interval (по умолчанию 10 секунд).
- 6. Не забудьте отменить *synchronous_commit*, иначе при остановленной реплике не удастся зафиксировать транзакцию.

```
Физическая потоковая репликация в синхронном режиме
α=> CREATE DATABASE replica_physical;
Создаем и запускаем реплику точно так же, как в демонстрации
You are now connected to database "student" as user "postgres".
Резервная копия:
student$ pg_basebackup --pgdata=/home/student/backup -R --slot=replica --create-slot
B postgresql.auto.conf добавляем параметр cluster_name, чтобы основной сервер мог идентифицировать реплику:
student$ echo 'cluster_name=beta' | sudo tee -a /home/student/backup/postgresql.auto.conf
cluster name=beta
student$ sudo cat /home/student/backup/postgresgl.auto.conf
# Do not edit this file manually!
# It will be overwritten by the ALTER SYSTEM command.
primary_conninfo = 'user=student passfile=''/home/student/.pgpass'' channel_binding=prefer host=''/var/run/postgresql'' port=5432 sslmode=prefer sslcompression=0 sslsni=1 ssl_min_proto
primary_slot_name = 'replica'
cluster_name=beta
Другой вариант - добавить атрибут application_name в строку соединения:
primary\_conninfo='user=student\ port=5432\ application\_name=beta'
Выклалываем в PGDATA и запускаем:
student$ sudo pg ctlcluster 13 beta status
Error: /var/lib/postgresql/13/beta is not accessible or does not exist
student$ sudo rm -rf /var/lib/postgresql/13/beta
student$ sudo mv /home/student/backup /var/lib/postgresql/13/beta
student$ sudo chown -R postgres:postgres /var/lib/postgresql/13/beta
student$ sudo pg ctlcluster 13 beta start
Теперь включаем на мастере режим синхронной репликации. Сразу переключимся на суперпользовательскую роль.
student$ psql -d replica physical -U postgres
 α=> ALTER SYSTEM SET synchronous_commit = on;
ALTER SYSTEM
α=> ALTER SYSTEM SET synchronous_standby_names = beta;
ALTER SYSTEM
Если все реплики синхронные, можно задавать synchronous standby names = *
student$ sudo pg ctlcluster 13 alpha reload
Проверка физической репликации
\alpha => SELECT * FROM pg_stat_replication \gx
-[ RECORD 1 ]----+------
                   1 25536
                    16384
student
beta
usesysid
usename
application_name
client_addr
client hostname
client_port
backend_start
backend_xmin
                     2024-01-16 12:23:49.483963+03
                     streaming
state
state
sent_lsn
write_lsn
flush_lsn
replay_lsn
write_lag
flush_lag
                     0/5000646
                     0/5000646
                     0/5000646
                     0/5000640
                     00:00:00.00019
                     00:00:00.00497
replay_lag
sync_priority
sync_state
                     00:00:00.005037
                   | sync
| 2024-01-16 12:23:51.807704+03
reply_time
sync state: sync говорит о том, что репликация работает в синхронном режиме.
application_name: beta - имя, под которым мастер знает реплику.
Остановим реплику.
student$ sudo pg_ctlcluster 13 beta stop
\alpha => \c - student
You are now connected to database "replica physical" as user "student".
α=> BEGIN;
REGIN
α=> CREATE TABLE test(id integer);
CREATE TABLE
α=> COMMIT:
Фиксация ждет появления синхронной реплики...
student$ sudo pg_ctlcluster 13 beta start
После старта реплики фиксация завершается
```

Отмена запроса из-за очистки на мастере

 $\alpha =>$ INSERT INTO test VALUES (1);

student\$ psql -p 5433 -d replica_physical β=> SHOW max_standby_streaming_delay;

INSERT 0 1

```
max_standby_streaming_delay
   30s
(1 row)
Начинаем транзакцию с уровнем изоляции repeatable read: первый оператор создаст снимок данных, который будет использоваться всеми последующими операторами этой транзакции
   \beta => BEGIN TRANSACTION ISOLATION LEVEL REPEATABLE READ;
   β=> SELECT * FROM test;
    id
   (1 row)
На мастере изменяем единственную строку и выполняем очистку. При этом первая версия строки будет удалена
\alpha => UPDATE test SET id = 2;
UPDATE 1
α=> VACUUM test;
VACUUM
Через 20 секунд запрос на реплике еще сработает — реплика задерживает применение конфликтующей журнальной записи:
   B=> SELECT * FROM test:
    id
   (1 row)
Через 30 секунд такой же запрос уже будет аварийно прерван, поскольку версия строки, входящая в снимок, больше не существует.
   β=> SELECT * FROM test;
   FATAL: terminating connection due to conflict with recovery DETAIL: User query might have needed to see row versions that must be removed. HIMT: In a moment you should be able to reconnect to the database and repeat your command. server closed the connection unexpectedly
   This probably means the server terminated abnormally before or while processing the request. connection to server was lost
Запрет откладывания применения конфликтующей записи
Выставим задержку применения конфликтующих изменений в ноль
student$ psql -p 5433 -d replica_physical -U postgres
   β=> ALTER SYSTEM SET max_standby_streaming_delay = 0;
ALTER SYSTEM
   β=> \c - student
You are now connected to database "replica_physical" as user "student".
student$ sudo pg_ctlcluster 13 beta reload
Снова начинаем транзакцию...
   \beta => BEGIN TRANSACTION ISOLATION LEVEL REPEATABLE READ;
   β=> SELECT * FROM test;
   id
   (1 row)
На мастере изменяем строку и выполняем очистку...
\alpha =>  UPDATE test SET id = 3;
UPDATE 1
α=> VACUUM test;
VACUUM
Запрос на реплике прерывается тут же:
   B=> SELECT * FROM test:
   FATAL: terminating connection due to conflict with recovery
   DETAIL: User query might have needed to see row versions that must be removed.

HINT: In a moment you should be able to reconnect to the database and repeat your command. server closed the connection unexpectedly

This probably means the server terminated abnormally before or while processing the request.

connection to server was lost
Обратная связь
Установим обратную связь и, чтобы не ждать долго, небольшой интервал оповещений
student$ psql -p 5433 -d replica_physical -U postgres
   \beta=> ALTER SYSTEM SET hot_standby_feedback = on;
ALTER SYSTEM
   \beta \Rightarrow ALTER SYSTEM SET wal_receiver_status_interval = '1s';
ALTER SYSTEM
   β=> \c - student
```

You are now connected to database "replica_physical" as user "student".

β=> BEGIN TRANSACTION ISOLATION LEVEL REPEATABLE READ;

student\$ sudo pg_ctlcluster 13 beta reload

Снова начинаем транзакцию...

β=> SELECT * FROM test;

BEGIN

```
3
(1 row)
На мастере изменяем строку и выполняем очистку...
\alpha => UPDATE test SET id = 4;
α=> VACUUM VERBOSE test;
INFO: vacuuming "public.test"
INFO: "test": found 0 removable, 2 nonremovable row versions in 1 out of 1 pages
DETAIL: 1 dead row versions cannot be removed yet, oldest xmin: 492
UEIALL: 1 dead row versions cannot be removed yet, There were 0 unused item identifiers. Skipped 0 pages due to buffer pins, 0 frozen pages. 0 pages are entirely empty. CPU: user: 0.00 s, system: 0.00 s, elapsed: 0.00 s. VACUUM
Благодаря обратной связи, очистка не может удалить старую версию строки (found 0 removable, 2 nonremovable row versions).
    B=> SELECT * FROM test:
    id
   3
(1 row)
    β=> COMMIT;
COMMIT
α=> VACUUM VERBOSE test;
INFO: vacuuming "public.test"
INFO: "test": found 1 removable, 1 nonremovable row versions in 1 out of 1 pages
DETAIL: 0 dead row versions cannot be removed yet, oldest xmin: 493
There were 1 unused item identifiers.
Skipped 0 pages due to buffer pins, 0 frozen pages.
Onapped or pages due to buffer pins, 0 frozen pages. 0 pages are entirely empty. CPU: user: 0.00 s, system: 0.00 s, elapsed: 0.00 s. VACUUM
После завершения транзакции на реплике мастер может выполнить очистку (found 1 removable...). Журнальные записи реплицируются, но ничего не поломают.
Теперь отменим синхронизацию и остановим реплику:
α=> \c - postares
You are now connected to database "replica_physical" as user "postgres".
α=> ALTER SYSTEM RESET synchronous_standby_names;
You are now connected to database "replica_physical" as user "student".
student$ sudo pg_ctlcluster 13 alpha reload
student$ sudo pg ctlcluster 13 beta stop
Еще раз изменим строку таблицы:
\alpha => UPDATE test SET id = 5;
UPDATE 1
Слот неактивен, но помнит минимальный хmin снимков реплики
α=> SELECT active, xmin FROM pg_replication_slots;
 active | xmin
f | 493
(1 row)
Это значение хтіп меньше, чем минимальный хтіп локальных снимков
α=> SELECT min(backend_xmin::text::numeric) FROM pg_stat_activity;
 min
494
(1 row)
Поэтому слот будет задерживать очистку (1 dead row versions cannot be removed yet, oldest xmin: ...).
α=> VACUUM VERBOSE test;
INFO: vacuuming "public.test"
            "test": found 0 removable, 2 nonremovable row versions in 1 out of 1 pages
DETAIL: 1 dead row versions cannot be removed yet, oldest xmin: 493
DEIALL: 1 dead row versions cannot be removed yet,
There were 0 unused item identifiers.
Skipped 0 pages due to buffer pins, 0 frozen pages.
0 pages are entirely empty.
CPU: user: 0.00 s, system: 0.00 s, elapsed: 0.00 s.
VACUUM
Удалим слот, теперь очистка сработает.
α=> SELECT pg_drop_replication_slot('replica');
 pg_drop_replication_slot
(1 row)
α=> VACUUM VERBOSE test:
INFU: vacuuming "public.test"
INFO: "test": found 1 removable, 1 nonremovable row versions in 1 out of 1 pages
DETAIL: 0 dead row versions cannot be removed yet, oldest xmin: 494
There were 1 unused item identifiers.
Skipped 0 pages due to buffer pins, 0 frozen pages.
0 pages are entirely empty.
CPU: user: 0.00 s, system: 0.00 s, elapsed: 0.00 s.
VACUUM
```