

Авторские права

© Postgres Professional, 2017–2024

Авторы: Егор Рогов, Павел Лузанов, Илья Баштанов, Игорь Гнатюк Фото: Олег Бартунов (монастырь Пху и пик Бхрикути, Непал)

Использование материалов курса

Некоммерческое использование материалов курса (презентации, демонстрации) разрешается без ограничений. Коммерческое использование возможно только с письменного разрешения компании Postgres Professional. Запрещается внесение изменений в материалы курса.

Обратная связь

Отзывы, замечания и предложения направляйте по адресу: edu@postgrespro.ru

Отказ от ответственности

Компания Postgres Professional не несет никакой ответственности за любые повреждения и убытки, включая потерю дохода, нанесенные прямым или непрямым, специальным или случайным использованием материалов курса. Компания Postgres Professional не предоставляет каких-либо гарантий на материалы курса. Материалы курса предоставляются на основе принципа «как есть» и компания Postgres Professional не обязана предоставлять сопровождение, поддержку, обновления, расширения и изменения.

Темы



Что такое слабоструктурированные данные

Применение в реляционных базах данных

Необходимые операции

Тип данных для XML: xml

Типы данных для JSON: json и jsonb

Индексирование документов JSON

2

Что это такое



Наиболее известные примеры: XML и JSON

Схема данных определяется самим документом

документ содержит разметку для выделения элементов и определения иерархии

Данные не соответствуют реляционной модели

конкретный документ можно представить в виде таблиц документы общего вида тоже можно, но практически — неудобно

3

Слабоструктурированные (semi-structured) данные — это данные, представленные не в реляционном (табличном) виде. Обычно это текстовый документ, но в отличие от текста на естественном языке, документ содержит разметку, определяющую структурные единицы.

Широко известными примерами форматов (языков разметки) являются XML и JSON, в последнее время также популярен YAML.

Структура, или схема, документа определяется его собственной разметкой. (Это не исключает возможности определить структуру отдельно — например, для XML есть языки DTD, XMLSchema.)

Разметка, как правило, позволяет определить вложенные элементы, образующие иерархию.

Конечно, любую конкретную иерархию можно представить и в табличном виде. Можно уложить в таблицы и произвольную иерархию без жесткой схемы, но результат будет лишен типизации данных, возможности создания ограничений целостности, с ним будет крайне неудобно работать в терминах запросов SQL. Поэтому с некоторыми видами данных действительно удобнее и логичнее работать именно в таком, слабоструктурированном, виде.

Применение



Интерфейсный формат

между приложением и внешней системой между клиентской и серверной частями приложения

Внутри базы данных как атомарное значение

только хранение и извлечение не нарушает 1NF, достаточно обычных средств SQL

Внутри базы данных как неатомарное значение

операции с отдельными частями документа SQL не достаточно; требуется специальный язык запросов и набор дополнительных операций гибкость, когда данные плохо укладываются в реляционную модель

4

Документы XML или JSON могут применяться как удобный интерфейсный формат между разными компонентами, независимый от конкретной платформы или языка программирования. Например, для взаимодействия с внешними системами, или для обмена данными между клиентской и серверной частями системы. В последнем случае интерфейсный формат позволяет клиенту послать сложный запрос, а серверу выполнить его эффективным образом (в отличие от традиционного подхода, принятого в ORM, когда сервер базы данных нагружается большим количеством мелких запросов, не оставляя возможностей для оптимизации).

Если слабоструктурированные данные хранятся внутри самой базы данных, то все зависит от того, как эти данные используются. Если внутри SQL запросов не делается попыток работать с отдельными частями документов, то такие значения можно считать атомарными с точки зрения СУБД. Тут достаточно обычных средств SQL.

Конечно, более интересен случай, когда серверу необходимо выделять часть документа, фильтровать вывод на основе содержания документов и т. п. Для этого SQL уже не хватает и нужен специализированный язык доступа к слабоструктурированным данным. Если СУБД предоставляет такую возможность, это позволяет комбинировать строгий реляционный подход для данных, имеющих четкую структуру, и подход в духе NoSQL для данных, которые сложно представить в табличном виде.

Операции



Преобразование документа к реляционному виду

сохранение транспортного документа в базу данных использование средств SQL для обработки

Преобразование реляционных данных к виду документа

выгрузка данных в транспортный формат

Выделение части документа

специализированный язык запросов

Индексирование документов

поддержка операций специализированного языка запросов

5

Чтобы работать со слабоструктурированными документами в реляционной базе данных, понадобятся возможности для преобразования данных из одного вида в другой, поскольку в одних ситуациях удобнее использовать реляционные средства, в других — документоориентированные. Особенно это важно, если такой язык, как XML или JSON, используется в качестве транспортного формата.

Кроме этого, нужны средства для выделения части документа — каких-то отдельных значений, или какого-то подмножества элементов. Такие средства обычно представлены в виде специализированного языка запросов, который учитывает иерархическую структуру документов. Такие языки запросов можно использовать не только для выделения части документа, но и, например, для выбора тех документов, в которых присутствует заданный фрагмент.

Если слабоструктурированные документы используются в реляционной СУБД, встает задача индексирования таких данных. Для этого, как правило, не годятся обычные В-деревья, поскольку требуется поддерживать не операции сравнения документов, а операции, связанные со специализированным языком запросов.

Формат XML



eXtensible Markup Language

универсальный язык разметки, первый стандарт 1998 года форматы на основе XML: XHTML, FB2, RSS и Atom, SVG, SOAP...

Структура

вложенные элементы отделяются тегами, могут иметь атрибуты, содержат текст

Инструментарий

описание схемы (DTD, XML Schema), языки запросов XPath и XQuery, язык преобразования XSLT

PostgreSQL: XPath 1.0

6

XML (eXtensible Markup Language) появился в контексте веба и разрабатывается консорциумом W3C. XML является текстовым документом, содержащим специальную разметку. XML определяет синтаксическую структуру разметки, которая с помощью *тегов* выделяет элементы (возможно, вложенные друг в друга), которые могут также иметь атрибуты. (Язык XML довольно сложен, в нем имеются также инструкции обработки, комментарии и другие сущности, но мы не будем на этом останавливаться.)

XML позволяет определить расширения XML, определяя конкретный набор элементов и их атрибутов, и наделяя их определенной семантикой. К известным расширениям относятся XHTML (более строгий HTML, совместимый с XML), FB2 (формат электронных книг), RSS и Atom (форматы для новостных лент), SVG (векторная графика), SOAP (формат сообщений веб-сервисов) и другие.

За время существования формата XML сформировался богатый инструментарий для работы с ним, включающий языки описания схемы документов (такие, как DTD, XMLSchema), языки запросов (базовый XPath и более богатый XQuery на его основе), языки преобразования документов XML (XSLT и XSL-FO на его основе).

В реляционных базах работу с XML регламентирует стандарт SQL/XML. PostgreSQL поддерживает только XPath 1.0. Преобразования XSLT доступны в расширениях (xml2 или в сторонних). Индексирование не реализовано (хотя все возможности для этого есть).

https://postgrespro.ru/docs/postgresql/16/datatype-xml https://postgrespro.ru/docs/postgresql/16/functions-xml

Тип данных для XML



xml

хранение в виде обычного текста + синтаксическая проверка сохраняется исходное форматирование может хранить XML-документ или фрагмент документа

7

Тип xml хранит документ в виде текстовой строки. Но по сравнению с типом text он проверяет введенные значения на допустимость по правилам XML.

Допускается хранение корректно оформленных документов, а также их фрагментов, в которых может быть несколько элементов верхнего уровня или текстовых узлов.

Для типа xml не определены никакие операторы сравнения, поэтому столбец этого типа нельзя проиндексировать с помощью B-tree. Однако можно, например, использовать индекс по выражению, в котором вызывается XPath и результат приводится к строке символов.

Существуют и другие ограничения реализации этого типа в PostgreSQL. https://postgrespro.ru/docs/postgresql/16/xml-limits-conformance

XML: тип xml

```
=> CREATE DATABASE ext_semistruct;

CREATE DATABASE
=> \c ext_semistruct

You are now connected to database "ext_semistruct" as user "student".
```

Будем работать с документом, описывающим компоненты компьютера.

- Теги выделяются угловыми скобками. Для каждого открывающего тега (<computer>) есть соответствующий ему закрывающий, имя которого начинается на косую черту (</computer>). Такая пара тегов определяет элемент (computer).
- Атрибуты могут быть перечислены вместе со значениями в открывающем теге.
- Текст внутри тегов составляет текстовый элемент.

```
=> SELECT $xml$
                                          <!-- открывающий тег -->
<computer>
  <motherboard>
    <!-- текстовый элемент -->
    <cpu>Intel® Core™ i7-7567U</cpu>
     <!-- тег с атрибутом -->
     <dimm size_gb="32">Crucial DDR4-2400 SODIMM</dimm>
    </ram>
  </motherboard>
  <disks>
    <ssd size_gb="512">Intel 760p Series</ssd>
    <hdd size_gb="3000">Toshiba Canvio</hdd>
  </disks>
</computer>
                                          <!-- закрывающий тег -->
$xml$ AS xml \gset
```

B PostgreSQL имеется тип xml, значение которого хранится в виде символьной строки, а при приведении к типу происходит проверка структуры. В зависимости от значения параметра xmloption проверка ожидает:

- document документ (с одним корнем).
- ullet content фрагмент документа (любой набор элементов).

```
=> SHOW xmloption;
xmloption
.....
content
(1 row)
```

При приведении к типу xml форматирование сохраняется:

```
=> SELECT :'xml'::xml;
```

```
xml
______
<computer>
                                   <!-- открывающий тег -->+
  <motherboard>
    <!-- текстовый элемент -->
    <cpu>Intel® Core™ i7-7567U</cpu>
     <!-- тег с атрибутом -->
      <dimm size gb="32">Crucial DDR4-2400 SODIMM</dimm>
    </ram>
  </motherboard>
  <disks>
    <ssd size gb="512">Intel 760p Series</ssd>
    <hdd size_gb="3000">Toshiba Canvio</hdd>
  </disks>
</computer>
                                     <!-- закрывающий тег -->+
(1 row)
```

А попытка привести некорректный фрагмент даст ошибку:

```
=> SELECT '<tag>wrong xml<tag>'::xml;
```

```
ERROR: invalid XML content
LINE 1: SELECT '<tag>wrong xml<tag>'::xml;

DETAIL: line 1: Premature end of data in tag tag line 1
<tag>wrong xml<tag>
```

XML: выражения XPath

Посмотрим, какие средства есть для получения части XML-документа. Для этого используются выражения языка запросов XPath 1.0. Мы не будем детально рассматривать все возможности XPath, но посмотрим некоторые примеры.

XML состоит из иерархии элементов, поэтому язык описывает перемещения по дереву. Часть документа, соответствующая пути от корня:

```
=> SELECT xpath('/computer/motherboard/ram', :'xml');
                     xpath
·
{"<ram>
     <!-- тег с атрибутом -->
     <dimm size_gb=\"32\">Crucial DDR4-2400 SODIMM</dimm>+
    </ram>"}
(1 row)
В пути можно указывать не только непосредственные потомки:
=> SELECT xpath('/computer//ram', :'xml');
                      xpath
.....
     <!-- тег с атрибутом -->
     <dimm size_gb=\"32\">Crucial DDR4-2400 SODIMM</dimm>+
    </ram>"}
(1 row)
По дереву элементов можно «двигаться» не только вниз к листьям, но и вверх к корню:
=> SELECT xpath('//ram/dimm/..', :'xml');
                      xpath
{"<ram>
     <!-- тег с атрибутом -->
     <dimm size_gb=\"32\">Crucial DDR4-2400 SODIMM</dimm>+
    </ram>"}
(1 row)
Вместо конкретного имени элемента можно указать, что подходит любой:
=> SELECT xpath('//disks/*', :'xml') \gx
-[ RECORD 1 ]-----
xpath \ | \ \{"<ssd\ size\_gb=\"512\">Intel\ 760p\ Series</ssd>","<hdd\ size\ gb=\"3000\">Toshiba
Canvio</hdd>"}
Здесь мы получили в массиве две части ХМL-документа. Можно посчитать количество:
=> SELECT xpath('count(//disks/*)', :'xml');
xpath
{2}
(1 row)
Можно извлечь не весь элемент, а только его текст:
=> SELECT xpath('//cpu/text()', :'xml');
        xpath
-----
{"Intel® Core™ i7-7567U"}
(1 row)
```

Атрибуты записываются с помощью «собаки». Найдем значения атрибутов size_gb:

Условия фильтрации записываются в квадратных скобках. Найдем все элементы, объем памяти которых начинается от 1000 гигабайт:

Сравнение работает, потому что XPath поддерживает числовые типы. Кроме этого, поддерживаются строки и погический тип

Выражения XPath применяются не только в функции xpath, но и в других. Например, можно проверить, содержит ли XML-документ указанный фрагмент:

XML: преобразование в реляционный вид и обратно

Для того чтобы преобразовать XML-документ к реляционному (табличному) виду, используется функция xmltable.

Пусть у нас имеется таблица для дисковых накопителей:

```
=> CREATE TABLE disks (
    drive_type text,
    name text,
    capacity integer
);

CREATE TABLE

CHaчала выделим нужную часть документа:

=> SELECT xpath('//disks/*', :'xml');

    xpath

----

{"<ssd size_gb=\"512\">Intel 760p Series</ssd>","<hdd size_gb=\"3000\">Toshiba
Canvio</hdd>"}
(1 row)
```

Теперь можно написать вызов функции xmltable. В нем мы указываем выражение XPath, сам документ, а также описываем, как получать значения для столбцов таблицы с помощью дополнительных XPath-выражений:

```
=> SELECT * FROM xmltable(
   '//disks/*'
   PASSING : 'xml'
   COLUMNS
       drive_type text PATH 'name()',
             text PATH 'text()',
       capacity integer PATH '@size_gb * 1024'
);
drive_type |
                 name
                            | capacity
         | Intel 760p Series | 524288
ssd
hdd
           | Toshiba Canvio | 3072000
(2 rows)
```

Обратите внимание:

- выражения XPath для столбцов отсчитываются не от корня документа, а от текущего контекста (элемента, найденного основным выражением XPath);
- в выражениях можно использовать некоторые арифметические операции.

Результат такого запроса можно непосредственно вставить в таблицу:

Для создания документов XML имеется довольно много функций, с помощью которых можно собрать документ «по кусочкам». Но есть также функции, позволяющие выгрузить в XML целую таблицу, или результат запроса, или даже всю базу данных в фиксированном формате.

```
=> SELECT table to xml(
   tbl => 'disks',
   nulls => true,
                      -- выводить столбцы с NULL
   tableforest => false, -- в корне один элемент <disks>
   targetns => ''
                 -- пространство имен XML не нужно
);
                      table_to_xml
-----
<disks xmlns:xsi="http://www.w3.org/2001/XMLSchema-instance">+
<row>
  <drive type>ssd</drive type>
  <name>Intel 760p Series</name>
  <capacity>524288</capacity>
</row>
<row>
  <drive type>hdd</drive type>
  <name>Toshiba Canvio</name>
  <capacity>3072000</capacity>
</row>
</disks>
(1 row)
```

Формат JSON



JavaScript Object Notation

простой язык разметки, стандарт 1999 года появился в JavaScript, но распространен повсеместно

Структура

объекты (пары «ключ: значение»), массивы значений значения текстовые, числовые, даты, логические

Инструментарий

PostgreSQL: язык запросов JSONPath, неполная пока поддержка стандарта SQL/JSON, индексирование

9

Формат JSON — подмножество языка JavaScript, описывающее:

- простые значения (текстовые, числовые, даты и логические);
- объекты, состоящие из пар «ключ значение»;
- массивы значений.

В двух последних случаях значения могут быть как простыми, так и объектами или массивами, то есть документ имеет иерархическую структуру.

Несмотря на то, что JSON — «родной» формат для JavaScript, он получил огромное распространение благодаря своей простоте и удобству, и повсеместно используется в современном интернете.

Изначально PostgreSQL предоставлял собственные операции для работы с JSON; при необходимости более серьезного инструментария можно было воспользоваться расширением jsQuery. В настоящее время в PostgreSQL реализована часть стандарта SQL/JSON:2016, включая язык запросов JSONPath.

Имеется и индексирование документов JSON. Это позволяет комбинировать реляционные возможности PostgreSQL с возможностями, предоставляемыми NoSQL-базами.

https://postgrespro.ru/docs/postgresql/16/datatype-json

https://postgrespro.ru/docs/postgresql/16/functions-json

https://github.com/postgrespro/jsquery

Типы данных для JSON



Json

хранение в виде обычного текста + синтаксическая проверка сохраняется исходное форматирование необходимость повторного разбора при каждом запросе

Jsonb

внутренний формат, исключающий повторный разбор поддержка SQL/JSON (язык запросов JSONPath) поддержка индексирования

10

Имеются два типа данных для представления документов JSON: json и jsonb.

Первый появился раньше и, по сути, просто хранит документ в виде текстовой строки (при этом, конечно, проверяется, что строка является корректным документом JSON). Но при любом обращении к части документа JSON его приходится заново разбирать. Это вызывает большие накладные расходы. Кроме того, для формата json не реализован язык JSONPath и не работает индексирование. Поэтому json применяется редко.

Обычно используется тип jsonb (b — binary). Этот формат сохраняет однажды разобранную иерархию элементов, что позволяет эффективно работать с документом. Следует учитывать, что исходный вид документа при этом не сохраняется: нарушается порядок следования элементов, пропадают отступы и дублирующиеся ключи.

https://postgrespro.ru/docs/postgresql/16/datatype-json#DATATYPE-JSONPATH

JSON: типы данных json и jsonb

```
Документ, описывающий компоненты компьютера, может выглядеть в JSON так:
```

```
=> SELECT $js$
{ "motherboard": {
    "cpu": "Intel® Core™ i7-7567U",
    "ram": [
      { "type": "dimm",
        "size_gb": 32,
        "model": "Crucial DDR4-2400 SODIMM"
    ]
  },
  "disks": [
    { "type": "ssd",
      "size_gb": 512,
"model": "Intel 760p Series"
    { "type": "hdd",
      "size gb": 3000,
      "model": "Toshiba Canvio"
    }
 ]
$js$ AS json \gset
Формат json хранит документ как обычный текст:
=> SELECT :'json'::json;
                    ison
 { "motherboard": {
     "cpu": "Intel® Core™ i7-7567U",
     "ram": [
       { "type": "dimm",
         "size_gb": 32,
         "model": "Crucial DDR4-2400 SODIMM"+
       }
    ]
   },
   "disks": [
     { "type": "ssd",
       "size_gb": 512,
       "model": "Intel 760p Series"
     { "type": "hdd",
       "size_gb": 3000,
       "model": "Toshiba Canvio"
   ]
}
(1 row)
при выводе документ составляется заново в эквивалентном, но ином виде:
```

В jsonb документ разбирается и записывается во внутреннем формате, сохраняющем структуру разбора. Из-за этого

```
=> SELECT :'json'::jsonb \gx
-[ RECORD 1 ]------
jsonb | {"disks": [{"type": "ssd", "model": "Intel 760p Series", "size_gb": 512},
{"type": "hdd", "model": "Toshiba Canvio", "size_gb": 3000}], "motherboard": {"cpu": "Intel® Core™ i7-7567U", "ram": [{"type": "dimm", "model": "Crucial DDR4-2400 SODIMM",
"size_gb": 32}]}}
```

Чтобы вывести документ в человекочитаемом виде, можно использовать специальную функцию:

```
=> SELECT jsonb_pretty(:'json'::jsonb);
```

```
jsonb_pretty
{
     "disks": [
         {
             "type": "ssd",
             "model": "Intel 760p Series",
             "size gb": 512
         },
             "type": "hdd",
             "model": "Toshiba Canvio",
             "size_gb": 3000
     ],
     "motherboard": {
         "cpu": "Intel® Core™ i7-7567U",
         "ram": [
             {
                 "type": "dimm",
                 "model": "Crucial DDR4-2400 SODIMM"
                 "size gb": 32
             }
         ]
    }
(1 row)
```

Дальше мы будем работать с типом jsonb, который предоставляет больше возможностей.

.....

JSON: выражения JSONPath и другие средства

Для получения части JSON-документа стандарт SQL:2016 определил язык запросов JSONPath. Вот некоторые примеры.

Так же, как и XPath, JSONPath позволяет спускаться по дереву элементов. Часть документа, соответствующая пути от корня:

```
=> SELECT jsonb_pretty(jsonb_path_query(:'json', '$.motherboard.ram'));
                 isonb pretty
[
         "type": "dimm".
         "model": "Crucial DDR4-2400 SODIMM",+
         "size gb": 32
     }
(1 row)
Элементы массива указываются в квадратных скобках:
=> SELECT jsonb_pretty(jsonb_path_query(:'json', '$.disks[0]'));
           jsonb_pretty
{
     "type": "ssd", + model": "Intel 760p Series",+
     "size_gb": 512
}
(1 row)
Можно получить и все элементы сразу:
=> SELECT jsonb_pretty(jsonb_path_query(:'json', '$.disks[*]'));
```

```
jsonb_pretty
 {
     "type": "ssd",
     "model": "Intel 760p Series"
     "size_gb": 512
 }
 {
     "type": "hdd",
"model": "Toshiba Canvio",
     "size_gb": 3000
(2 rows)
Условия фильтрации записываются в скобках после вопросительного знака. Символ @ обозначает текущий путь.
Найдем диски, объем памяти которых начинается от 1000 гигабайт:
=> SELECT jsonb_pretty(
    jsonb_path_query(:'json', '$.disks ? (@.size_gb > 1000)')
          jsonb_pretty
 {
     "type": "hdd",
     "model": "Toshiba Canvio",+
     "size gb": 3000
 }
(1 row)
Условия являются частью пути, который можно продолжить дальше. Выберем только модель:
=> SELECT jsonb_pretty(
    jsonb_path_query(:'json', '$.disks ? (@.size_gb > 1000).model')
   jsonb pretty
"Toshiba Canvio"
(1 row)
В пути может быть и несколько условий:
=> SELECT jsonb_pretty(
    jsonb_path_query(
        :'json',
        '$.disks ? (@.size_gb > 128).model ? (@ starts with "Intel")'
    )
);
   jsonb_pretty
"Intel 760p Series"
(1 row)
Кроме средств JSONPath, можно применять и «традиционную» стрелочную нотацию.
Переходим к ключу motherboard, затем к ключу ram, затем берем первый (нулевой) элемент массива:
=> SELECT jsonb_pretty( (:'json'::jsonb)->'motherboard'->'ram'->0 );
               jsonb pretty
-----
 {
     "type": "dimm",
     "model": "Crucial DDR4-2400 SODIMM",+
     "size_gb": 32
 }
(1 row)
Двойная стрелка возвращает не jsonb, а текстовое представление (необходимые фильтрации придется выполнять
уже на уровне SQL):
```

=> SELECT (:'json'::jsonb)->'motherboard'->'ram'->0->>'model';

```
?column?
Crucial DDR4-2400 SODIMM
(1 row)
Начиная с версии PostgreSQL 14 для работы с jsonb можно использовать индексную нотацию:
=> SELECT (:'json'::jsonb)['disks'][1]['model'];
     isonb
 "Toshiba Canvio"
(1 row)
JSON: преобразование в реляционный вид и обратно
Стандарт определяет функцию jsontable, но ее реализация ожидается только в PostqreSQL 17. Разумеется, можно
выйти из положения и теми средствами, которые существуют. Сначала выделим все диски:
=> TRUNCATE TABLE disks;
TRUNCATE TABLE
=> WITH dsk(d) AS (
    SELECT jsonb_path_query(:'json', '$.disks[*]')
SELECT d FROM dsk;
                               d
{"type": "ssd", "model": "Intel 760p Series", "size_gb": 512}
 {"type": "hdd", "model": "Toshiba Canvio", "size_gb": 3000}
(2 rows)
На основе этого запроса несложно сделать вставку в таблицу:
=> INSERT INTO disks(drive_type, name, capacity)
WITH dsk(d) AS (
    SELECT jsonb_path_query(:'json', '$.disks[*]')
SELECT d->>'type', d->>'model', (d->>'size gb')::integer FROM dsk;
Для обратного преобразования удобно воспользоваться функцией row to json:
=> SELECT row_to_json(disks) FROM disks;
                         row_to_json
 {"drive type":"ssd","name":"Intel 760p Series","capacity":512}
 {"drive type": "hdd", "name": "Toshiba Canvio", "capacity": 3000}
(2 rows)
Соединить строки в общий JSON-массив можно, например, так:
=> SELECT json_agg(disks) FROM disks;
                             json_agg
```

Здесь отдельные строки преобразуются в объекты JSON автоматически.

(1 row)


[{"drive_type":"ssd","name":"Intel 760p Series","capacity":512}, +
{"drive_type":"hdd","name":"Toshiba_Canvio","capacity":3000}]

Метод доступа GIN



Инвертированный индекс

метод применим для сложносоставных значений (массив, текст) АРІ метода доступа определяет, как выделять элементы значения



Идея метода доступа GIN (Generalized Inverted Index) основана на том, что для сложносоставных значений имеет смысл использовать в качестве ключей элементы значений, а не значения целиком.

Представьте предметный указатель в конце книги. Страницы книги — сложносоставные значения (текст), а указатель позволяет ответить на вопрос «на каких страницах встречается такой-то термин?».

Для хранения элементов в GIN используется обычное В-дерево, поэтому элементы должны принадлежать к сортируемому типу данных. Основные отличия от В-дерева состоят в следующем:

- Когда нужно проиндексировать новое значение, это значение разбивается на элементы и индексируются сразу все элементы. Поэтому в индекс добавляется не один элемент, а сразу несколько (обычно много).
- Каждый элемент индекса ссылается на множество табличных строк.
- Хотя элементы и организованы в В-дерево, классы операторов GIN не поддерживают операции сравнения «больше», «меньше».

Таким образом, GIN оптимизирован для других условий использования, нежели В-дерево. (Но имеется расширение btree_gin, реализующее классы операторов GIN для обычных типов данных.)

https://postgrespro.ru/docs/postgresql/16/gin

https://postgrespro.ru/docs/postgresql/16/datatype-json#JSON-INDEXING

Метод доступа GIN для индексирования JSON

```
Пусть теперь таблица с дисками будет содержать JSON-документы.
=> DROP TABLE disks;
DROP TABLE
=> CREATE TABLE disks(
    id integer PRIMARY KEY GENERATED ALWAYS AS IDENTITY,
    disk jsonb
);
CREATE TABLE
Заполним ее разными моделями, от 10 до 1000 Гбайт:
=> INSERT INTO disks(disk)
WITH rnd(r) AS (
    SELECT (10+random()*990)::integer FROM generate_series(1,100000)
dsk(type, model, capacity, plates) AS (
    SELECT 'hdd', 'NoName '||r||' GB', r, (1 + random()*9)::integer
    FROM rnd
SELECT row_to_json(dsk) FROM dsk;
INSERT 0 100000
=> ANALYZE disks;
ANALYZE
Вот что получилось:
=> SELECT * FROM disks LIMIT 3;
                                             disk
id |
 1 | {"type": "hdd", "model": "NoName 528 GB", "plates": 3, "capacity": 528}
2 | {"type": "hdd", "model": "NoName 984 GB", "plates": 10, "capacity": 984}
3 | {"type": "hdd", "model": "NoName 509 GB", "plates": 3, "capacity": 509}
Сколько всего моделей имеют емкость 10 Гбайт и сколько времени займет поиск?
=> \timing on
Timing is on.
Оператор @? проверяет, есть ли в документе JSON заданный путь.
=> SELECT count(*) FROM disks WHERE disk @? '$ ? (@.capacity == 10)';
 count
   64
(1 row)
Time: 39,237 ms
=> \timing off
Timing is off.
Как выполняется этот запрос?
=> EXPLAIN (costs off)
SELECT count(*) FROM disks WHERE disk @? '$ ? (@.capacity == 10)';
                             QUERY PLAN
 Aggregate
   -> Seq Scan on disks
          Filter: (disk @? '$?(@."capacity" == 10)'::jsonpath)
(3 rows)
```

Конечно, используется полное сканирование таблицы — у нас нет подходящего индекса.

Документы JSONB можно индексировать с помощью метода GIN. Для этого есть два доступных класса операторов:

Класс по умолчанию, jsonb_ops, более универсален, но менее эффективен. Этот класс операторов помещает в индекс все ключи и значения. Из-за этого поиск получается неточным: значение 10 может быть найдено не только в контексте емкости (ключ capacity), но и как число пластин (ключ plates). Зато такой индекс поддерживает и другие операции с JSONB.

Попробуем.

```
=> CREATE INDEX disks_json_idx ON disks USING gin(disk);
CREATE INDEX
=> \timing on
Timing is on.
=> SELECT count(*) FROM disks WHERE disk @? '$ ? (@.capacity == 10)';
count
   64
(1 row)
Time: 6,038 ms
=> \timing off
Timing is off.
Доступ, тем не менее, ускоряется.
=> EXPLAIN (costs off)
SELECT count(*) FROM disks WHERE disk @? '$ ? (@.capacity == 10)';
                            QUERY PLAN
______
Aggregate
   -> Bitmap Heap Scan on disks
        Recheck Cond: (disk @? '$?(@."capacity" == 10)'::jsonpath)
        -> Bitmap Index Scan on disks_json_idx
             Index Cond: (disk @? '$?(@."capacity" == 10)'::jsonpath)
(5 rows)
```

Другой класс операторов, jsonb_path_ops, помещает в индекс значения вместе с путем, который к ним ведет. За счет этого поиск становится более точным, хотя поддерживаются не все операции.

Проверим и этот способ:

```
Еще один вариант — построить индекс на основе В-дерева по выражению. Вот так:
=> CREATE INDEX disks_btree_idx ON disks( (disk->>'capacity') );
CREATE INDEX
=> \timing on
Timing is on.
=> SELECT count(*) FROM disks WHERE disk->>'capacity' = '10';
 count
   64
(1 row)
Time: 0,566 ms
=> \timing off
Timing is off.
```

Но такой способ, конечно, менее универсален — под каждый запрос потребуется создавать отдельный индекс.

Сравним размер индексов (для сравнения выводится и размер таблицы):

```
=> SELECT indexname,
    pg_size_pretty(pg_total_relation_size(indexname::regclass))
FROM pg_indexes
WHERE tablename = 'disks'
UNION ALL
SELECT 'disks', pg_size_pretty(pg_table_size('disks'::regclass));
                    | pg_size_pretty
      indexname
                   | 2208 kB
| 1904 kB
disks_pkey
 disks json idx
 disks_json_path_idx | 1408 kB
disks_btree_idx | 712 kB
disks | 13 MB
disks
(5 rows)
```

Итоги



PostgreSQL поддерживает слабоструктурированные типы Частичная поддержка XML

формат теряет популярность

Полноценная поддержка JSON

направление активно развивается

Индексирование на основе метода доступа GIN

14

Практика 🖤



- 1. Часть сведений о книгах (ISBN, аннотация и другие) выводятся приложением только на отдельной странице. Сейчас эти данные хранятся в таблице books, но не передаются приложению. Измените функцию, реализующую API приложения, так, чтобы сведения передавались в виде одного объекта JSON. Проверьте реализацию в приложении.
- 2. Многочисленные столбцы, хранящие дополнительные сведения о книгах, никак не используются в серверной части приложения. Замените их на один столбец, в котором сведения будут храниться в формате JSON. Сделайте это прозрачно для приложения.

15

1. Сведения должны передаваться в объекте JSON следующего формата:

```
{ "ISBN": isbn,
  "Аннотация": abstract,
  "Издательство": publisher,
  "Год выпуска": year,
  "Гарнитура": typeface,
  "Издание": edition,
  "Серия": series
}
```

2. Действуйте в предположении, что во время замены столбцов приложение работает и должно корректно выполнять запросы пользователей. Не забудьте, что вместе с заменой столбцов на один общий необходимо исправить и интерфейсную функцию приложения.

Кроме того, считайте, что одновременно с работой приложения могут изменяться как данные о существующих книгах, так и добавляться новые книги.

Дополнительные сведения о книгах

Приложение рассчитывает получить дополнительные сведения о книгах в столбце additional таблицы, возвращаемой вызовом webapi.get_catalog, которая, в свою очередь, обращается за данными к public.get_catalog. Последняя получает дополнительные атрибуты через отдельную функцию, которая сейчас возвращает пустой документ:

```
=> \sf get_additional
CREATE OR REPLACE FUNCTION public.get additional(book books)
RETURNS jsonb
LANGUAGE sql
IMMUTABLE
RETURN NULL::jsonb
Изменим функцию следующим образом:
=> CREATE OR REPLACE FUNCTION public.get_additional(book books) RETURNS jsonb
LANGUAGE sql STABLE
RETURN jsonb_build_object(
        'ISBN',
                         book.isbn,
        'Аннотация',
                        book.abstract.
        'Издательство', book.publisher,
        'Год выпуска', book.year,
        'Год выпус.
'Гарнитура', book.cype.
book.edition,
                        book.typeface,
        'Серия',
                       book.series
    );
CREATE FUNCTION
```

Замена нескольких столбцов на один формата JSON

```
Добавим к таблице books необходимый столбец:
```

```
=> ALTER TABLE books ADD additional jsonb;
```

ALTER TABLE

Если данные о книгах могут изменяться в процессе наших действий, мы можем создать триггер, который будет переносить изменения в новый столбец:

```
=> CREATE FUNCTION fill_additional() RETURNS trigger
AS $$
BEGIN
   NEW.additional := jsonb_build_object(
                      NEW.isbn,
        'ISBN',
        'Аннотация',
                       NEW.abstract.
        'Издательство', NEW.publisher,
        'Год выпуска', NEW.year,
        'Гарнитура', NEW.typeface,
        'Издание',
                       NEW.edition.
        'Серия',
                       NEW.series
    ):
    RETURN NEW;
$$ LANGUAGE plpgsql;
CREATE FUNCTION
=> CREATE TRIGGER books additional
BEFORE INSERT OR UPDATE OF
   isbn, abstract, publisher, year, typeface, edition, series
ON books
FOR EACH ROW
EXECUTE FUNCTION fill_additional();
CREATE TRIGGER
Теперь перенесем в новый столбец исторические данные:
=> UPDATE books
SET additional = get_additional(books)
WHERE additional IS NULL;
UPDATE 100
```

Начиная с этого момента старые столбцы менять нельзя. Если бы у нас была процедура загрузки новых

поступлений, ее следовало бы переделать на заполнение нового столбца.

Переключим приложение на использование нового столбца:

```
=> CREATE OR REPLACE FUNCTION public.get_additional(book books) RETURNS jsonb
LANGUAGE sql STABLE
RETURN book.additional;
CREATE FUNCTION
Теперь можно удалить временный триггер:
=> DROP TRIGGER books_additional ON books;
DROP TRIGGER
=> DROP FUNCTION fill_additional;
DROP FUNCTION
И можно удалить ненужные теперь столбцы таблицы:
=> ALTER TABLE books
    DROP isbn,
    DROP abstract,
    DROP publisher,
    DROP year,
DROP typeface,
    DROP edition,
    DROP series;
```

ALTER TABLE

Удаление столбцов происходит быстро, поскольку данные фактически не удаляются, а только становятся невидимыми. Поэтому размер таблицы не уменьшится до тех пор, пока строки не будет физически перезаписаны, например, при обновлениях.

Практика+



- 1. В базе данных имеются таблицы пользователей и их заказов, связанные отношением «один ко многим». Напишите функцию, которая по идентификатору пользователя возвращает документ JSON, содержащий все сведения о пользователе вместе с массивом его заказов.
- 2. В пользовательском интерфейсе необходимо выводить названия городов, хранящиеся в базе данных, на выбранном языке. Один из способов хранить все переводы названий в объекте JSON в виде пар «код языка название». Реализуйте такой способ. Для удобства создайте представление, показывающее название городов на языке, заданном в конфигурационном параметре сервера.

16

1. Таблицы могут быть следующими:

```
CREATE TABLE users(
  id integer PRIMARY KEY GENERATED ALWAYS AS IDENTITY,
  name text);

CREATE TABLE orders(
  id integer PRIMARY KEY GENERATED ALWAYS AS IDENTITY,
  user_id integer REFERENCES users(id),
  amount numeric);

Peзультат должен иметь вид:

{ "user_id": ...,
  "name": ...,
  "orders": [ { "order_id": ..., "amount": ... }, ... ]
}
```

Для того чтобы сформировать объект JSON из нескольких полей, воспользуйтесь функцией jsonb_build_object.

2. Название пользовательского конфигурационного параметра должно содержать точку в своем имени, например, «translation.lang».

Получить текущее значение параметра можно функцией current_setting.

1. Формирование JSON

```
=> CREATE DATABASE ext_semistruct;
CREATE DATABASE
=> \c ext_semistruct
You are now connected to database "ext_semistruct" as user "student".
Создадим таблицы и тестовые данные:
=> CREATE TABLE users(
    id integer PRIMARY KEY GENERATED ALWAYS AS IDENTITY,
    name text
);
CREATE TABLE
=> CREATE TABLE orders(
   id integer PRIMARY KEY GENERATED ALWAYS AS IDENTITY,
    user_id integer REFERENCES users(id),
    amount numeric
);
CREATE TABLE
=> INSERT INTO users(name) VALUES ('alice'), ('bob'), ('charlie');
INSERT 0 3
=> INSERT INTO orders(amount, user_id)
    SELECT round( (random()*1000)::numeric, 2), u.id
    FROM users u, generate_series(1,3);
INSERT 0 9
Функция использует jsonb_build_object для создания объекта и jsonb_agg для создания массива:
=> CREATE FUNCTION get users w orders(user_id integer) RETURNS jsonb
LANGUAGE sql STABLE
RETURN (SELECT jsonb build object(
    'user_id', u.id,
    'name', u.name,
'orders', jsonb_agg(jsonb_build_object(
        'order_id', o.id,
        'amount', o.amount
    ))
FROM users u
    JOIN orders o ON o.user_id = u.id
WHERE u.id = get_users_w_orders.user_id
GROUP BY u.id);
CREATE FUNCTION
Проверим:
=> SELECT jsonb_pretty(get_users_w_orders(1));
```

```
jsonb_pretty
 {
     "name": "alice",
     "orders": [
        {
             "amount": 186.75,+
             "order_id": 1 +
         },
         {
             "amount": 557.79,+
             "order id": 4
         },
         {
             "amount": 449.75,+
             "order_id": 7 +
         }
     "user_id": 1
(1 row)
2. Хранение переводов
Таблица с городами:
=> CREATE TABLE cities ml(
    id integer PRIMARY KEY GENERATED ALWAYS AS IDENTITY,
);
CREATE TABLE
=> INSERT INTO cities_ml(data) VALUES
    ('{ "ru": "Москва<sup>"</sup>,
        "en": "Moscow"
       "it": "Mosca" }'),
    ('{ "ru": "Санкт-Петербург",
"en": "Saint Petersburg",
        "it": "San Pietroburgo" }');
INSERT 0 2
Представление может быть устроено следующим образом:
=> CREATE VIEW cities AS
SELECT c.id,
       c.data ->> current_setting(
                      'translation.lang', /* missing_ok */true
                  ) AS name
FROM cities_ml c;
CREATE VIEW
Проверим результат с разными значениями параметра:
=> SET translation.lang = 'ru';
SET
=> SELECT * FROM cities;
id |
        name
 1 | Москва
 2 | Санкт-Петербург
(2 rows)
=> SET translation.lang = 'en';
=> SELECT * FROM cities;
        name
id |
 1 | Moscow
 2 | Saint Petersburg
```

(2 rows)

Таким образом приложение может установить язык один раз в начале сеанса, и затем запросы не будут зависеть с выбора пользователя.	ıΤ